

Regresní analýza dat - 01RAD

ZS 2025/26, 2+2 z,zk

Tomáš Hobza

Katedra matematiky, FJFI, Trojanova 13, 107c

tomas.hobza@fjfi.cvut.cz



Literatura



Golberg, M. Cho, H.A.: Introduction to Regression Analysis. WITpress, Southampton 2010.



Víšek, J. Á.: Statistická analýza dat. Vydavatelství ČVUT v Praze, Praha 1998.



Zvára, K.: Regrese. Matfyzpress, Praha 2008.



Olive, D.: Linear Regression. Springer, 2017.

Stručný obsah přednášky

- 1 Úvod - regresní analýza
- 2 Jednorozměrná lineární regrese
- 3 Vícerozměrná regrese
- 4 Rezidua, diagnostika a transformace
- 5 Výběr regresního modelu
- 6 Kolinearita (multikolinearita)

1. Úvod - regresní analýza

- jedna z nejužívanějších statistických metod pro analýzu vztahu mezi proměnnými
- pro svou flexibilitu, užitečnost, interpretovatelnost → **základní statistický nástroj**
- pro úspěšnou a efektivní aplikaci je třeba získat náhled a pochopení

a) příslušné teorie, b) její praktické aplikace.

ad a) **základy teorie lineární regrese** (bude navazovat **ZLMA**)

ad b) **ilustrace teorie na příkladech** - cvičení v 

Historie:

- slovo "**regrese**": sir *Francis Galton* (1822-1911), studie dědičnosti (1885)
- základní matematický nástroj: **metoda nejmenších čtverců**

Carl Friedrich Gauss (1777 - 1855) *Adrien-Marie Legendre* (1752 - 1833)

myšlenka: minimalizace součtu čtverců deviací pozorovaných hodnot a hodnot predikovaných modelem

odůvodnění: Gauss - Markov theorem

Použití regresní analýzy:

- a) **Popis dat** zkoumání případně vyvrácení vztahů mezi proměnnými
- b) **Interpretace** získání souhrnu nebo interpretace dat pomocí modelu prokládajícího data křivkou/plochou
- c) **Inference** hledání nebo vylepšení teoretických modelů
statistické techniky: **odhady parametrů**, **testy hypotéz**, **predikce**



DATA: základní součást regresní analýzy

Essentially, all models are wrong, but some are useful. The practical question is how wrong do they have to be to not be useful.

George E. P. Box (1919 - 2013)



2. Jednorozměrná lineární regrese



Model jednorozměrné regrese

Sledujeme dvě fyzikální veličiny x a y , mezi kterými existuje lineární závislost

$$y = \beta_0 + \beta_1 x, \quad \text{kde } \beta_0, \beta_1 \text{ nejsou známy.}$$

Experiment $\longrightarrow$ hodnoty dvojic (x, y)

- měření hodnot x často probíhá prakticky zcela přesně (například x se nastavuje na předem dané úrovni)
- y se měří s určitou chybou, chyba může být náhodná, y budeme chápat jako náhodnou veličinu (zn. Y).

Pro dvojice $(x_1, Y_1), \dots, (x_n, Y_n)$ se zavádí **model**

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n, \quad (*)$$

kde

- Y_i se nazývá **vysvětlovaná (závislá) proměnná**
- x_i se nazývá **vysvětlující (nezávislá) proměnná**, někdy také prediktor nebo regresor
- β_0, β_1 jsou neznámé regresní parametry
- e_i je tzv. **náhodný šum (náhodná chyba)**, předpoklad: $e_1, \dots, e_n$ nezávislé a $e_i \sim (0, \sigma^2)$.

Model jednorozměrné regrese

- měřeními se získají data $(x_1, y_1), \dots, (x_n, y_n)$
- **cíl statistické analýzy:** určit, zda model $(*)$ dobře popisuje pozorovanou variabilitu v y

První krok: odhad neznámých parametrů β_0, β_1 a σ^2

Proložení dat přímkou - několik způsobů, zásadní bude znalost rozdělení e_i a tedy Y_i

Dvě možnosti:

- 1 odhadnout β_0, β_1 pomocí metody nezávislé na rozdělení chyb
- 2 udělat věrohodný předpoklad o rozdělení chyb, odhadnout β_0, β_1 a potom ověřit předpoklad

POZNÁMKA 2.1

Speciální případ $e_i \sim N(0, \sigma^2)$: MLE vede na LSE, LSE může být použito i pro jiný druh chyb

Odhady parametrů pro normální chyby

A) předpokládáme, že $e_1, \dots, e_n$ jsou *i.i.d.* $N(0, \sigma^2)$, tzn

$$Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2) \quad \text{a} \quad Y_1, \dots, Y_n \text{ nezávislé}$$

MLE odhady:

Odhady parametrů pro normální chyby

Odvodili jsme MLE:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \text{a} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.1)$$

kde

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad \text{je predikce modelu (odhad } EY_i)$$

a

$$\hat{e}_i = y_i - \hat{y}_i \quad \text{je } i - \text{té reziduum}$$

POZNÁMKA 2.2

Pro odhad σ^2 se častěji používá

$$s_n^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n-2} SSE$$

což je nestranný odhad σ^2 (pro lib. rozdělení chyb)

POZNÁMKA 2.3

Odhad směrodatné odchylky σ :

$$s_n = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \text{standardní chyba (standard error)}$$

už není nestranný !

Obecná vlastnost odhadů rozptylu:

$$s^2 \text{ nestranný odhad } \sigma^2 \quad \Rightarrow \quad Es \leq \sigma$$

Odhady parametrů

B) bez předpokladu normality chyb, tzn.

$$e_1, \dots, e_n \text{ nezávislé (nekorelované)} \quad \text{a} \quad Ee_i = 0, \text{ Var}(e_i) = \sigma^2$$

Pro odhad β_0, β_1 lze použít minimalizaci

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

geometrická interpretace:

- $y_i - \beta_0 - \beta_1 x_i$ je vertikální vzdálenost bodu (x_i, y_i) od přímky $y = \beta_0 + \beta_1 x$
- S - "míra" jak dobře přímka prokládá data

Minimalizací S získáme $\hat{\beta}_0, \hat{\beta}_1$

- stejné jako u MLE pro normální data
- nazývají se ale **odhady metodou nejmenších čtverců** (least squares estimators - LSE)

POZNÁMKA 2.4

Existuje více měr vhodnosti přímky, použití LSE pro lib. rozdělení chyb má dvě zdůvodnění

- 1 pro normální chyby LSE splývá s MLE
- 2 LSE odhad je navíc Best Linear Unbiased Estimator (BLUE)

Vlastnosti odhadů $\hat{\beta}_0, \hat{\beta}_1, s_n^2$

VĚTA 2.1

Nechť $\hat{\beta}_0, \hat{\beta}_1$ jsou LSE odhady parametrů β_0, β_1 v lineárním modelu

$$Y_i = \beta_0 + \beta_1 x_i + e_i \quad i = 1, \dots, n,$$

kde $e_i \sim (0, \sigma^2)$ jsou nezávislé náhodné veličiny (postačí i nekorelovanost). Potom platí:

- ❶ $E[\hat{\beta}_0] = \beta_0, \quad E[\hat{\beta}_1] = \beta_1, \quad (\text{nestranné odhady})$
- ❷ $\text{Var}[\hat{\beta}_1] = \frac{\sigma^2}{S_{xx}}, \quad \text{kde} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$
- ❸ $\text{Var}[\hat{\beta}_0] = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right),$
- ❹ Pokud navíc platí, že $e_i \sim N(0, \sigma^2), \quad i = 1, \dots, n$ potom $\hat{\beta}_j \sim N(\beta_j, \text{Var}[\hat{\beta}_j]) \quad j = 0, 1.$

Důkaz:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

VĚTA 2.2

Za předpokladů věty 2.1 platí

$$E(s_n^2) = \sigma^2. \quad (s_n^2 \text{ je nestranný odhad } \sigma^2)$$

Důkaz:

Tvrzení 2.1

Nechť platí předpoklady věty 2.1 a necht' $e_1, \dots, e_n$ jsou *i.i.d.* $N(0, \sigma^2)$. Potom platí:

a) $\frac{(n-2)s_n^2}{\sigma^2} \sim \chi^2(n-2)$

b) odhad s_n^2 je nezávislý na $\hat{\beta}_0$ a $\hat{\beta}_1$.

POZNÁMKA 2.5

Spočetli jsme

$$\sigma^2(\hat{\beta}_0) \triangleq \text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right] \quad \text{a} \quad \sigma^2(\hat{\beta}_1) \triangleq \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}$$

Nestranné odhady jsou:

$$\hat{\sigma}^2(\hat{\beta}_0) = s_n^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right] = s_n^2 \delta_0, \quad \hat{\sigma}^2(\hat{\beta}_1) = \frac{s_n^2}{S_{xx}} = s_n^2 \delta_1,$$

Odhady směrodatné odchylky veličin $\hat{\beta}_0$ a $\hat{\beta}_1$ pak jsou

$$\hat{\sigma}(\hat{\beta}_0) = s_n \sqrt{\delta_0} \quad \text{a} \quad \hat{\sigma}(\hat{\beta}_1) = s_n \sqrt{\delta_1}, \quad (\text{standardní chyby odhadů } \hat{\beta}_0, \hat{\beta}_1)$$

Gauss-Markov theorem

- Chyby normální $\Rightarrow$ LSE pro $\hat{\beta}_0, \hat{\beta}_1$ je MLE (eficientní odhad)
- Pokud nejsou chyby normální, jaké je opodstatnění použít LSE?
Ukážeme, že LSE jsou **BLUE** (best linear unbiased estimators), tedy **lineární nestranné odhady s minimálním rozptylem**
- můžou ale existovat nelineární nebo vychýlené odhady parametrů β_0, β_1 , které jsou eficientnější než LSE (pokud se rozdělení chyb liší výrazně od normálního)

DEFINICE 2.2

Lineární odhad parametru β , založený na pozorováních $Y_1, \dots, Y_n$, je statistika tvaru

$$\hat{\beta} = \sum_{i=1}^n c_i Y_i,$$

kde c_i jsou dané reálné konstanty, $i = 1, \dots, n$.

Uvažujme model

$$Y_i = \beta_0 + \beta_1 x_i + e_i, \quad i = 1, \dots, n, \quad (*)$$

VĚTA 2.3 (Gauss-Markov theorem)

Nechť $e_1, \dots, e_n$ v modelu (*) jsou nekorelované, mají stejný rozptyl $\text{Var}(e_i) = \sigma^2$ a $Ee_i = 0$, $i = 1, \dots, n$. Potom LSE $\hat{\beta}_j$ ($j = 0, 1$) je BLUE parametru β_j .

Důkaz:

Intervaly spolehlivosti pro β_0, β_1

- IS poskytují jistou "míru přesnosti" bodových odhadů
- pro jejich konstrukci potřebujeme znát rozdělení pravděpodobnosti bodového odhadu
- budeme tedy uvažovat normalitu chyb
- spočtené IS se ale často používají, i když rozdělení chyb **není normální**
zdůvodnění: LSE odhady par. β jsou lineární funkcí $Y_i, i = 1, \dots, n$, aplikace CLT vede na asymptotickou normalitu $\hat{\beta}_0, \hat{\beta}_1$

V modelu (*) platí:

$$\hat{\beta}_i \sim N(\beta_i, \sigma^2(\hat{\beta}_i)), \quad \frac{(n-2)s_n^2}{\sigma^2} \sim \chi^2(n-2) \quad (\text{a nezávisí na } \hat{\beta}_0, \hat{\beta}_1).$$

Tedy

$$T_i = \frac{\frac{\hat{\beta}_i - \beta_i}{\sigma(\hat{\beta}_i)}}{\frac{s_n}{\sigma}} = \frac{\hat{\beta}_i - \beta_i}{\hat{\sigma}(\hat{\beta}_i)} \sim t(n-2), \quad i = 0, 1.$$

To znamená

$$P \left[-t_{1-\alpha/2}(n-2) \leq \frac{\hat{\beta}_i - \beta_i}{\hat{\sigma}(\hat{\beta}_i)} \leq t_{1-\alpha/2}(n-2) \right] = 1 - \alpha$$

a vyjádřením β_i dostaneme

$$P \left[\hat{\beta}_i - t_{1-\alpha/2}(n-2) \hat{\sigma}(\hat{\beta}_i) \leq \beta_i \leq \hat{\beta}_i + t_{1-\alpha/2}(n-2) \hat{\sigma}(\hat{\beta}_i) \right] = 1 - \alpha$$

a tedy $(\hat{\beta}_i \pm t_{1-\alpha/2}(n-2) \hat{\sigma}(\hat{\beta}_i))$ je $100(1 - \alpha)\%$ IS pro $\beta_i, i = 0, 1$.

Dosazením za $\hat{\sigma}(\hat{\beta}_i)$ dostaneme

$$100(1 - \alpha)\% \text{ IS pro } \beta_0: \left(\hat{\beta}_0 \pm t_{1-\alpha/2}(n-2) \cdot s_n \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \right)$$

$$100(1 - \alpha)\% \text{ IS pro } \beta_1: \left(\hat{\beta}_1 \pm t_{1-\alpha/2}(n-2) \cdot s_n \frac{1}{\sqrt{S_{xx}}} \right)$$

POZNÁMKA 2.6

- IS pro β_0 bude ve většině praktických případů širší než IS pro β_1
- Někdy se konstruuji simultánní IS pro oba parametry. Zmíníme podrobněji u vícerozměrné regrese.

Testy hypotéz o parametrech β_0, β_1

- chtěli bychom ověřit platnost předpokladu lineárního vztahu mezi x a y
- předpokládejme, že model je lineární a že x je jediná dostupná vysvětlující proměnná
- otázkou je, zda je x užitečná ve vysvětlení variability y
- chceme tedy rozhodnout mezi dvěma modely:

$$Y_i = \beta_0 + e_i \quad \text{a} \quad Y_i = \beta_0 + \beta_1 x_i + e_i$$

tzn. otestovat hypotézu $H_0 : \beta_1 = 0$ $\times$ $H_1 : \beta_1 \neq 0$.

- nezamítnutí $H_0 \rightarrow x$ nevysvětluje nic z variability y a není v modelu významné
- zamítnutí $H_0 \rightarrow x$ je v modelu významné.

POZNÁMKA 2.7

Tyto závěry jsou správné pouze za předpokladu, že je model lineární!

- nezamítnutí H_0 nemusí znamenat, že x není užitečná (vztah mezi y a x nemusí být lineární)
- zamítnutí H_0 naopak říká, že existuje lineární trend mezi x a y (mohou tam ale být i jiné typy závislosti)

Pro konstrukci testů využijeme odvozené IS.

Opakování: mějme testovat $H_0 : \theta = \theta_0$ × $H_1 : \theta \neq \theta_0$ a necht' $(\underline{\theta}, \bar{\theta})$ je $100(1 - \alpha)\%$ IS pro θ

Pak $W = \{x | \theta_0 \notin (\underline{\theta}, \bar{\theta})\}$ je kritický obor testu na hladině α .

$H_0 : \beta_1 = 0$ **zamítneme**, pokud $0 \notin \left(\hat{\beta}_1 \pm t_{1-\alpha/2}(n-2) \cdot \frac{s_n}{\sqrt{s_{xx}}} \right)$, tzn.

$$\text{bud' } \hat{\beta}_1 + t_{1-\alpha/2}(n-2) \cdot \frac{s_n}{\sqrt{s_{xx}}} < 0 \iff \hat{\beta}_1 \frac{\sqrt{s_{xx}}}{s_n} < -t_{1-\alpha/2}(n-2)$$

$$\text{nebo } \hat{\beta}_1 - t_{1-\alpha/2}(n-2) \cdot \frac{s_n}{\sqrt{s_{xx}}} > 0 \iff \hat{\beta}_1 \frac{\sqrt{s_{xx}}}{s_n} > t_{1-\alpha/2}(n-2)$$

zapsáno dohromady

$$|T_1| = |\hat{\beta}_1| \frac{\sqrt{s_{xx}}}{s_n} > t_{1-\alpha/2}(n-2).$$

POZNÁMKA 2.8 (Intuitivní interpretace)

$$|T_1| = |\hat{\beta}_1| \frac{\sqrt{s_{xx}}}{s_n} = \frac{|\hat{\beta}_1|}{\hat{\sigma}(\hat{\beta}_1)} \text{ je převrácená hodnota relativní chyby } \frac{\hat{\sigma}(\hat{\beta}_1)}{|\hat{\beta}_1|}.$$

POZNÁMKA 2.9

Někdy dopředu známe kandidáta b_1 jako hodnotu parametru β_1 a chtěli bychom testovat $H_0 : \beta_1 = b_1 \quad \times \quad H_1 : \beta_1 \neq b_1$. Test bude: **zamítnout H_0** , pokud

$$\left| \hat{\beta}_1 - b_1 \right| \cdot \frac{\sqrt{S_{xx}}}{s_n} > t_{1-\alpha/2}(n-2).$$

Test významnosti interceptu:

Otázka je, zda přímka prochází počátkem $(0,0)$, tedy $H_0 : \beta_0 = 0 \quad \times \quad H_1 : \beta_0 \neq 0$.

Nezamítnutí H_0 znamená, že jednodušší model $y = \beta_1 x + e$ lépe popisuje data, než $y = \beta_0 + \beta_1 x + e$.

H_0 zamítneme, pokud

$$|T_0| = \frac{|\hat{\beta}_0|}{\hat{\sigma}(\hat{\beta}_0)} = |\hat{\beta}_0| \frac{1}{s_n \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}} > t_{1-\alpha/2}(n-2).$$

PŘÍKLAD 2.1 (Měření rychlosti zvuku v závislosti na teplotě)

teplota	-20	0	20	50	100
rychlost (m/s)	323	327	340	364	386

$$\bar{x} = 30, \quad \bar{y} = 348, \quad \sum_{i=1}^n x_i y_i = 57140, \quad \sum_{i=1}^n x_i^2 = 13300,$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 8800, \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - 5\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - 5\bar{x}^2} = 0.561, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 331.16,$$

$$s_n^2 = \frac{1}{5-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 18.95, \quad s_n = 4.35, \quad \hat{\sigma}(\hat{\beta}_0) = 2.394, \quad \hat{\sigma}(\hat{\beta}_1) = 0.046$$

$$t_{0.975}(5-2) = 3.18 \Rightarrow 95\% \text{ IS pro } \beta_0 : (323.5, 338.8), \quad 95\% \text{ IS pro } \beta_1 : (0.414, 0.709)$$

Testy hypotéz:

$$H_0 : \beta_0 = 0 \quad |T_0| = \frac{331.16}{2.394} = 138.3 > 3.18 \Rightarrow \text{zamítáme } H_0$$

$$H_0 : \beta_1 = 0 \quad |T_1| = \frac{0.561}{0.046} = 12.1 > 3.18 \Rightarrow \text{zamítáme } H_0$$

```
mod <- lm(rychlost~teplota)
```


```
summary(mod)
```

```
## Call:
## lm(formula = rychlost ~ teplota)
##
## Residuals:
##      1       2       3       4       5
## 3.068 -4.159 -2.386  4.773 -1.295
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 331.15909    2.39363   138.3 8.33e-07 ***
## teplota      0.56136     0.04641    12.1  0.00122 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.354 on 3 degrees of freedom
## Multiple R-squared:  0.9799,    Adjusted R-squared:  0.9732
## F-statistic: 146.3 on 1 and 3 DF,  p-value: 0.001216
```

```
confint(mod)
```

```
##              2.5 %      97.5 %
## (Intercept) 323.541507 338.7766749
## teplota      0.413665   0.7090623
```

Rychlost vs teplota



ANOVA přístup pro testování

- odvodili jsme t -test významnosti koeficientů, odvodíme ekvivalentní F -test, který může být zobecněn na test celkové významnosti vícerozměrného regresního modelu
- **myšlenka metody (ANOVA)**: určit, kolik variability v pozorováních $(y_1, y_2, \dots, y_n)$ je „vysvětleno“ regresním modelem
- míra variability v datech: **total sum of squares (SST)** - celkový součet čtverců

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

- pokud regresní přímka $y = \hat{\beta}_0 + \hat{\beta}_1 x$ dobře prokládá data, tedy $\hat{y}_i \approx y_i$, bude platit

$$\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2 \approx \sum_{i=1}^n (y_i - \bar{y})^2$$

ukážeme, že $\bar{\hat{y}} = \bar{y}$ a tak

$$\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \text{SSR} \quad \text{regression sum of squares - regresní součet čtverců}$$

- Podíl

$$R^2 = \frac{SSR}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

vyjadřuje podíl variability v $(y_1, \dots, y_n)$ vysvětlené regresním modelem

- R^2 - koeficient determinace (coefficient of determination) (pro dobrý model $R^2 \approx 1$)
- ukážeme, že $R^2 = \varrho^2(\mathbf{x}, \mathbf{y})$, tzn. R^2 je míra „dobré shody“
- R^2 by šla použít pro test $H_0 : \beta_1 = 0$ (zamítnutí pokud $R^2 \approx 1$)
- každá monotonní funkce R^2 vede na ekvivalentní test, budeme uvažovat statistiku

$$F = \frac{(n-2)R^2}{1-R^2}$$

VĚTA 2.4

Předpokládejme, že v modelu (*) je splněno $SST \neq 0$. Potom platí

- 1) $0 \leq R^2 \leq 1$,
- 2) $R^2 = 1 - \frac{SSE}{SST}$, kde $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ je reziduální součet čtverců,
- 3) $R^2 = 1 \iff \hat{y}_i = y_i, \forall i \in \hat{n}$ (všechna data leží na přímce),
- 4) pokud označíme $\mathbf{x} = (x_1, \dots, x_n)$ a $\mathbf{y} = (y_1, \dots, y_n)$, potom

$$R^2 = \varrho^2(\mathbf{x}, \mathbf{y}), \quad \text{kde } \varrho(\mathbf{x}, \mathbf{y}) = \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sqrt{S_{xx}S_{yy}}},$$

$$5) F = \frac{(n-2)R^2}{1-R^2} = \frac{SSR}{s_n^2} = T_1^2,$$

- 6) pokud jsou chyby $e_1, \dots, e_n$ i.i.d. $N(0, \sigma^2)$ a platí $H_0 : \beta_1 = 0$, potom $F \sim F(1, n-2)$.

POZNÁMKA 2.10

- Z bodů 5) a 6) vyplývá, že použití lib. stat. T_1, R^2 nebo F vede na ekvivalentní test významnosti regrese.
- R^2 poskytuje hrubou představu o kvalitě modelu, čím je blíže 1, tím lépe přímka prokládá data (nicméně je třeba jisté obezřetnosti, jak uvidíme později)
- F lze chápat jako statistiku pro test významnosti velkých hodnot R^2 .

Důkaz věty bude založen na rozkladu

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad \text{neboli} \quad SST = SSR + SSE$$

Lemma 2.1

Nechť $\hat{e}_i = y_i - \hat{y}_i$ značí rezidua, kde $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ a $\hat{\beta}_0, \hat{\beta}_1$ jsou LSE v modelu (*). Potom platí

$$1) \sum_{i=1}^n \hat{e}_i = 0, \quad 2) \bar{\hat{y}} = \bar{y}, \quad 3) \sum_{i=1}^n \hat{e}_i \hat{y}_i = 0.$$

Důkaz.



Důkaz věty 2.4.

Tabulka ANOVA

Výsledky se většinou uvádí ve formě tabulky ANOVA:

Source	df	SS	MS	F
Regression	1	SSR	$MSR = \frac{SSR}{1}$	$\frac{MSR}{MSE}$
Residual	$n - 2$	SSE	$MSE = \frac{SSE}{n-2} = s_n^2$	
Total	$n - 1$	SST		

$$R^2 = \frac{SSR}{SST}$$

Source – zdroj součtu čtverců, **df** – počet stupňů volnosti, **SS** – součet čtverců
MS – "mean squares", průměr čtverců, ($MS = \frac{SS}{df}$)

POZNÁMKA 2.11

$H_0 : \beta_1 = 0$ je zamítnuta, pokud $F > F_{1-\alpha}(1, n - 2)$

(v jednorozměrném případě je to ekvivalentní t -testu, neboť $F = T_1^2$).

VĚTA 2.5

Nechť $e_1, \dots, e_n$ i.i.d. $N(0, \sigma^2)$. Za platnosti $H_0 : \beta_1 = 0$ je splněno, že

$$\frac{SSR}{\sigma^2} \sim \chi^2(1), \quad \frac{SSE}{\sigma^2} \sim \chi^2(n-2), \quad \frac{SST}{\sigma^2} \sim \chi^2(n-1).$$

POZNÁMKA 2.12

Proto se v tabulce ANOVA uvádí df po řadě 1, $n-2$, $n-1$.

Používají se však i v případě jiného rozdělení chyb. Představit si je lze takto:

- 1 $SSE = \sum_{i=1}^n \hat{e}_i^2$, na n -reziduí $\hat{e}_1, \dots, \hat{e}_n$ máme 2 podm. $\sum_{i=1}^n \hat{e}_i = 0$ a $\sum_{i=1}^n x_i \hat{e}_i = 0 \Rightarrow n-2$ stupňů vol.
- 2 $SST = \sum_{i=1}^n (y_i - \bar{y})^2$, $y_i - \bar{y}$ musí splňovat $\sum_{i=1}^n (y_i - \bar{y}_n) = 0 \Rightarrow n-1$ stupňů volnosti
- 3 $SSR = SST - SSE$, počet stupňů volnosti je $(n-1) - (n-2) = 1$

Důkaz.

PŘÍKLAD 2.2 (Měření rychlosti zvuku v závislosti na teplotě)

teplota	-20	0	20	50	100
rychlost (m/s)	323	327	340	364	386

```
mod <- lm(rychlost~teplota)

anova(mod)

## Analysis of Variance Table
##
## Response: rychlost
##          Df Sum Sq Mean Sq F value    Pr(>F)
## teplota   1 2773.14  2773.14   146.3 0.001216 **
## Residuals 3   56.86    18.95
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Připomenutí: $s_n^2 = 18.95$, $T_1^2 = (12.096)^2 = 146.3$.

POZNÁMKA 2.13 (R^2 statistika - pozor na zjednodušené hodnocení kvality modelu!)

- nízké hodnoty R^2 nemusí znamenat, že regresní model není významný
v datech jen může být velké množství nevysvětlitelné náhodné variability
(např. opakované hodnoty regresoru x snižují hodnotu R^2 oproti modelům s různými x)
- velké hodnoty R^2 mohou být způsobeny velkým měřítkem dat (S_{xx} je velké)
 - platí totiž

$$E(R^2) \approx \frac{\beta_1^2 S_{xx}}{\beta_1^2 S_{xx} + \sigma^2} \quad (\text{rostoucí funkce } S_{xx})$$

- velký rozptyl ($x_1, \dots, x_n$) může mít za následek velké R^2 , přitom nic neříká o kvalitě modelu
- $E(R^2)$ je také rostoucí funkcí β_1^2 , modely s „velkou“ směrnici tedy budou mít obecně větší R^2 , než modely s „malou“ směrnici

Při hodnocení kvality modelu potřebujeme více kritérií. Mezi ně patří například

- 1) „velká“ hodnota R^2 ,
- 2) „velké“ hodnoty statistik F nebo $|T_1|$,
- 3) „malé“ hodnoty s_n^2 vzhledem k $\bar{y}$ (další kritéria později)

PŘÍKLAD 2.3

- velká hodnota R^2 indikuje přibližně lineární vztah mezi x a y
- vysoký stupeň korelace ale nemusí znamenat příčinný vztah!

Data: 1924-1937

y_i - počet mentálních onemocnění na 100000 obyvatel Anglie.

x_i - počet rádií v populaci.

Model: $y_i = \beta_0 + \beta_1 x_i + e_i$

$$\hat{\beta}_0 = 4.5822, \quad \hat{\beta}_1 = 2.2042, \quad R^2 = 0.984$$

tzn. velmi významný lineární vztah mezi x a y

Závěr: rádia způsobují mentální onemocnění (???)

věrohodnější vysvětlení: x i y rostou lineárně s časem, tzn. y roste lineárně s x

(Rádia byla s časem dostupnější, lepší diagnostické procedury umožňovaly identifikovat více lidí s mentálními problémy.)

POZNÁMKA 2.14 (korelace $\times$ příčinnost)


a)

$$\begin{array}{ccc} x & \longrightarrow & y \\ x & \longleftarrow & y \end{array}$$

Causal link (příčinná spojitost)

i když je příčinná spojitost mezi x a y , korelace samotná nám neřekne, zda x ovlivňuje y nebo naopak


c)



Confounding factor (zavádějící faktor)

skrytá proměnná z i x ovlivňují y , výsledky tedy závisí i na z

b)



Hidden cause (skrytá příčinnost)

skrytá veličina z ovlivňuje x i y , což způsobuje jejich korelovanost

d)



Coincidence (shoda okolností)

korelace je náhodná

Regresní model procházející počátkem

Existují případy, kdy přípustný model vyžaduje $\beta_0 = 0$, tj.

$$Y_i = \beta_1 x_i + e_i, \quad i = 1, \dots, n,$$


např.

- je to předem známo na základě fyzikálních úvah ($EY_0 = \beta_0 = 0$), potom nemá smysl odhadovat β_0 , obecně to snižuje přesnost odhadu σ^2 a tím i β_1
- na začátku předpokládáme $\beta_0 \neq 0$ a t-test nezamítne $H_0 : \beta_0 = 0$, potom β_0 může být z modelu odstraněno

POZNÁMKA 2.15

- v praxi často není jisté, že model platí i blízko počátku
- část statistiků trvá na přítomnosti interceptu v modelu, i když je nevýznamný
- položit $\beta_0 = 0$ apriorně může být chybné, i když $EY_0 = 0$, pokud totiž nevíme jistě, že model je lineární na okolí 0, volba $\beta_0 = 0$ může vést k vychýleným odhadům β_1 , pokud jsou nezávislé proměnné daleko od 0

Příklad: porodní váha a gestační stáří



Odhady a testy v případě $\beta_0 = 0$

- LSE parametru β_1 dostaneme minimalizací $S = \sum_{i=1}^n (y_i - \beta_1 x_i)^2$ ve tvaru $\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$
- pokud $e_1, \dots, e_n$ i.i.d. $N(0, \sigma^2)$, potom

$$E\hat{\beta}_1 = \beta_1, \quad \text{Var}\hat{\beta}_1 = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}, \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n x_i^2}\right),$$

$$s_n^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-1} = \frac{SSE}{n-1} \text{ je nestranný odhad } \sigma^2, \quad \frac{SSE}{\sigma^2} \sim \chi^2(n-1) \text{ a nezávisí na } \hat{\beta}_1$$

- $H_0 : \beta_1 = 0$ lze otestovat pomocí $T = \frac{\hat{\beta}_1}{\frac{s_n}{\sqrt{\sum_{i=1}^n x_i^2}}} \sim t(n-1)$

- 100(1 - α)% IS pro β_1 je $\left(\hat{\beta}_1 \pm t_{1-\alpha/2}(n-1) s_n / \sqrt{\sum_{i=1}^n x_i^2}\right)$

POZNÁMKA 2.16

- zatím vše podobné jako pro případ $\beta_1 \neq 0$
- rozdíl ale bude v tabulce ANOVA a R^2 statistice, neplatí totiž rozklad $SST = SSR + SSE$
- odvodíme nový rozklad (platí v obou modelech, dokážeme jen pro $\beta_0 = 0$)

VĚTA 2.6

V modelu s $\beta_0 = 0$ platí $\sum_{i=1}^n y_i^2 = \sum_{i=1}^n \hat{y}_i^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$.

Důkaz.

Pokud vezmeme $\sum_{i=1}^n y_i^2$ jako míru variability v datech, analogie R^2 bude: $R^2 = \frac{\sum_{i=1}^n \hat{y}_i^2}{\sum_{i=1}^n y_i^2}$

potom

$$1 - R^2 = \frac{\sum_{i=1}^n y_i^2 - \sum_{i=1}^n \hat{y}_i^2}{\sum_{i=1}^n y_i^2} = \frac{\sum_{i=1}^n \hat{e}_i^2}{\sum_{i=1}^n y_i^2}, \quad \text{a definicí} \quad F = \frac{(n-1)R^2}{1 - R^2}$$

dostaneme

$$F = \frac{\sum_{i=1}^n \hat{y}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2} = \frac{\hat{\beta}_1^2 \sum_{i=1}^n x_i^2}{s_n^2} = T^2$$

vztah mezi R^2, F, T je tedy stejný jako pro $\beta_0 \neq 0$

POZNÁMKA 2.17

Tato definice R^2 se ale moc nepoužívá, protože neumožňuje přímé srovnání modelů *bez* a *s* interceptem

$$\beta_0 = 0: R^2 = 1 - \frac{SSE}{\sum_{i=1}^n y_i^2}$$

$$\beta_0 \neq 0: R^2 = 1 - \frac{SSE}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

obecně ale $\sum_{i=1}^n (y_i - \bar{y})^2 < \sum_{i=1}^n y_i^2$, R^2 modelu s $\beta_0 = 0$ tak bude větší než R^2 modelu s $\beta_0 \neq 0$ (i když jsou jejich SSE srovnatelné)

- definice vhodné R^2 pro $\beta_0 = 0$ vyvolává jistou kontroverzi a ex. několik verzí
- možná volba je

$$R^2 = \varrho^2(\mathbf{y}, \hat{\mathbf{y}}),$$

kde $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_n)$ (platí i pro $\beta_0 \neq 0$)

- další možnost: srovnat modely pomocí s_n^2

Tabulka ANOVA pro $\beta_0 = 0$.

Source	df	SS	MS	F
Regression	1	$SSR = \sum_{i=1}^n \hat{y}_i^2$	$MSR = \frac{SSR}{1}$	$\frac{SSR}{s_n^2}$
Residual	$n - 1$	$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	$MSE = \frac{SSE}{n-1} = s_n^2$	
Total	n	$SST = \sum_{i=1}^n y_i^2$		

$$R^2 = \varrho^2(\mathbf{y}, \hat{\mathbf{y}})$$

PŘÍKLAD 2.4 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age)
summary(mod)
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -1485.0      852.6   -1.742   0.0955 .
## Age           115.5       22.1    5.228 3.04e-05 ***
## Residual standard error: 192.6 on 22 degrees of freedom
## Multiple R-squared:  0.554,    Adjusted R-squared:  0.5338
## F-statistic: 27.33 on 1 and 22 DF,  p-value: 3.04e-05
```

```
y.mod <- predict(mod)
cor(y.mod, Weight)^2
## 0.5540268
```

Model bez interceptu:

```
mod.bez <- lm(Weight ~ Age - 1)
summary(mod.bez)

## Coefficients:
##      Estimate Std. Error t value Pr(>|t|)
## Age    77.081      1.063   72.51  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

## Residual standard error: 200.9 on 23 degrees of freedom
## Multiple R-squared:  0.9956,    Adjusted R-squared:  0.9955
## F-statistic: 5258 on 1 and 23 DF,  p-value: < 2.2e-16

anova(mod.bez)

## Analysis of Variance Table
##
## Response: Weight
##      Df    Sum Sq  Mean Sq F value    Pr(>F)
## Age      1 212270368 212270368  5257.6 < 2.2e-16 ***
## Residuals 23   928596    40374
## ---

y.mod.bez <- predict(mod.bez)

cor(y.mod.bez,Weight)^2

## 0.5540268
```

Predikce

Jakmile máme model, často bývá cílem odhadnout hodnoty veličiny Y_0 pro nové x_0 , které není v původních datech.

Budeme uvažovat dva typy predikce:

- 1) predikce střední hodnoty $\mu_0 = E[Y_0]$ v bodě x_0 ,
- 2) predikce hodnoty nového pozorování Y_0 v bodě x_0 .

Pro oba typy použijeme bodový odhad

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0,$$

intervalové odhady se ale budou lišit.

Ad 1) $\mu_0 = \beta_0 + \beta_1 x_0$ je vlastně parametr, lze pro něj odvodit IS (za předpokladu normality chyb).

Spočteme $\text{Var}(\hat{Y}_0)$:

Shrnutí: $100(1 - \alpha)\%$ IS pro μ_0

$$\hat{Y}_0 \pm t_{1-\frac{\alpha}{2}}(n-2) \cdot \hat{\sigma}(\hat{Y}_0), \quad \text{kde} \quad \hat{\sigma}^2(\hat{Y}_0) = s_n^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]$$

$\hat{\sigma}(\hat{Y}_0)$ se obvykle nazývá **standardní chyba predikce v bodě x_0**

POZNÁMKA 2.18

Z tvaru IS je vidět, že bude nejkratší pro $x_0 = \bar{x}$ a s rostoucí vzdáleností $|x_0 - \bar{x}|$ se prodlužuje.

- Speciálně potom čím dále jsme od oblasti, kde jsou naše data x , tím méně spolehlivé jsou naše predikce.
- Je třeba opatrnosti při predikci hodnot Y mimo interval $(\min x_i, \max x_i)$.

Ad 2)

Intervalové odhady pro Y_0 nejsou IS, protože Y_0 není parametr $\longleftrightarrow$ intervaly predikce.

Potřebujeme rozptyl $Y_0 - \hat{Y}_0$:

Shrnutí: $100(1 - \alpha)\%$ interval predikce pro Y_0

$$\hat{Y}_0 \pm t_{1-\frac{\alpha}{2}}(n-2) \cdot s_p, \quad \text{kde} \quad s_p = s_n \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

POZNÁMKA 2.19

Přesnost predikce

- a) roste s rostoucím n a rostoucím rozsahem x naměřeným pomocí S_{xx} ,
- b) klesá s rostoucím $|x_0 - \bar{x}|$.

Pokud je možno předem zvolit $x_1, \dots, x_n$, lze přesnost predikce zvýšit volbou dostatečně rozptýlených hodnot x .

To ale může zvyšovat R^2 a někdy vést k horšímu modelu.

⇒ **základní rozpor v regresní analýze:**


- dobrý model nemusí poskytovat dobré predikce,
- dobré predikce mohou vycházet z méně přesných modelů.

POZNÁMKA 2.20

- odvozené výsledky platí za předpokladu normality chyb
- za podmínek regularity jsou ale odhady $\hat{\beta}_0, \hat{\beta}_1$ asymptoticky normální, tzn. **IS pro EY_0** budou použitelné pro velká n i pro nenormální chyby
- **IP pro Y_0** ale závisí na normalitě chyb i pro velká n , tzn. mohou tedy být nepřesné pro nenormální chyby

PŘÍKLAD 2.5 (Clark County population data)

x	Year	Population
0	1920	4859
1	1930	8539
2	1940	16414
3	1950	48589
4	1960	127016
5	1970	273288
6	1980	463087



1. lineární model pro původní data: $Y_i = \beta_0 + \beta_1 x_i + e_i$

$$\hat{\beta}_0 = -81\,328, \quad p_{val} = 0.22, \quad \hat{\beta}_1 = 71\,957, \quad p_{val} = 0.007, \quad R^2 = 0.80, \quad F = 19.96$$

x	Year	Population	Fitted.value
0	1920	4859	-81328
1	1930	8539	-9371
2	1940	16414	62585
3	1950	48589	134542
4	1960	127016	206498
5	1970	273288	278455
6	1980	463087	350411

Predikce pro rok 1990:

$$\hat{y}_{1990} = \hat{\beta}_0 + \hat{\beta}_1 \cdot 7 = 422\,368$$

a) 95% IS: (237 233, 607 502)

b) 95% IP: (135 559, 709 177)

Skutečná hodnota v roce 1990: 768 203

2. lineární model pro log-transformovaná data: $\log(Y_i) = \beta_0 + \beta_1 x_i + e_i$

$$\hat{\beta}_0 = 8.33, p_{val} < 10^{-4}, \hat{\beta}_1 = 0.809, p_{val} < 10^{-4}, R^2 = 0.991, F = 550.9$$

Predikce pro rok 1990 na log. škále:

$$\widehat{\log y}_{1990} = \hat{\beta}_0 + \hat{\beta}_1 \cdot 7 = 14.0004$$

a) 95% IS: (13.604, 14.397)

b) 95% IP: (13.387, 14.614)


Predikce pro rok 1990 na původní škále:

$$\hat{y}_{1990} = 1\,203\,161$$

a) 95% IS: (809 576, 1 788 092)

b) 95% IP: (651 269, 2 222 733)

Skutečná hodnota v roce 1990: 768 203



Intervaly predikce v R

```
mod.lin <- lm(pop ~ year)


new <- data.frame(year=seq(0,6,0.1))

# predikce y
y.hat <- predict(lm(pop ~ year), new)

# 95% intervaly spolehlivosti
CI<-predict(mod.lin, new, interval = "confidence")

# 95% intervaly predikce
PI<-predict(mod.lin, new, interval = "prediction")

# obrazek
matplot(new$year, cbind(CI, PI[, -1]),
        lty = c(1,2,2,3,3), col = c(1,2,2,3,3),
        type = "l", lwd=2, ylab="", xlab = "Year",
        axes = FALSE, ylim=c(-400000,600000))
axis(side=1, at=0:6, labels=Year)
axis(side=2, las=2)
points(pop ~ year, col="blue", lwd=2)
```




Ověření adekvátnosti modelu

- důležitá součást analýzy
- mělo by předcházet interpretaci modelu případně přijímání závěrů založených na modelu
- výsledky odvozeny za předpokladu **linearity modelu**, případně **normality chyb**

Základní procedury:

1) Prozkoumání scatter plotu dvojic (x_i, y_i)

Např.



může indikovat, že lepší model bude

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + e_i.$$

(může být zavádějící)

2) Analýza hodnot testovacích statistik

- např. malá hodnota R^2 společně s významnou hodnotou t -statistiky pro parametr β_1 naznačuje, že skutečný model obsahuje i jiné proměnné x
- velká hodnota R^2 a významná t -statistika ale samo o sobě neznamená, že je model lineární.

3) Obrázky reziduí

- efektivní diagnostický nástroj
- rezidua odhadují, kolik variability v datech zůstane po odstranění lineární části v x
- dá se očekávat, že budou užitečné pro detekci odchylek od normality

Ad 3) - Analýza reziduí

- intuitivně, pokud je náš model správný, měla by se rezidua chovat jako náhodný výběr z $N(0, \sigma^2)$
- pokud se tak nechovají, může to znamenat neadekvátnost modelu
- ukážeme grafické nástroje, začneme ale vlastnostmi reziduí

VĚTA 2.7

Nechť $\hat{e}_i$ jsou rezidua modelu (*) odhadnutého metodou nejmenších čtverců. Potom platí:

- 1) $E(\hat{e}_i) = 0, \quad i = 1, \dots, n$
- 2) $\text{Var}(\hat{e}_i) = \sigma_{\hat{e}_i}^2 = \sigma^2 \left[1 - \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}} \right) \right] \quad (\approx \sigma^2 \text{ pro velká } n)$
- 3) $\text{Cov}(\hat{e}_i, \hat{e}_j) = -\sigma^2 \left[\frac{1}{n} + \frac{(\bar{x} - x_i)(\bar{x} - x_j)}{S_{xx}} \right]$
- 4) $\text{Cov}(\hat{e}_i, \hat{Y}_i) = 0, \quad i = 1, \dots, n$
- 5) Pokud jsou $e_1, \dots, e_n$ i.i.d. $N(0, \sigma^2)$, potom platí: $\hat{Z}_i = \frac{\hat{e}_i}{\sigma_{\hat{e}_i}} \sim N(0, 1).$

Důkaz.

POZNÁMKA 2.21

- bod 3) věty $\Rightarrow \text{Cov}(\hat{e}_i, \hat{e}_j) \approx 0$ pro velké n
- pokud jsou tedy e_i i.i.d. $N(0, \sigma^2)$, měla by se *standardizovaná rezidua* $\hat{Z}_i = \frac{\hat{e}_i}{\hat{\sigma}_{e_i}}$ chovat pro velké n jako náhodný výběr z $N(0, 1)$ rozdělení
- budeme potřebovat odhad σ^2 pro výpočet $\hat{Z}_i$
- nejznámější procedura: odhadnout σ^2 pomocí s_n^2 , potom

$$\hat{r}_i = \frac{\hat{e}_i}{s_n \sqrt{1 - \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}} \right)}} \quad \text{studentizovaná rezidua}$$

- pro velká n by se opět měla $\hat{r}_i$ chovat jako náh. výběr z $N(0, 1)$.

POZNÁMKA 2.22




- $\hat{e}_i, \hat{r}_i$ se užívají pro grafickou analýzu
- jiná třída reziduí – **PRESS rezidua** (negrafické metody zkoumání reziduí):
ozn. $\hat{\beta}_{0(-i)}, \hat{\beta}_{1(-i)}$ odhady parametrů β_0, β_1 , pokud je vynecháno i -té pozorování
pak i -té PRESS reziduum je definováno jako

$$\hat{e}_{(-i)} = y_i - \hat{y}_{(-i)}, \quad \text{kde } \hat{y}_{(-i)} = \hat{\beta}_{0(-i)} + x_i \hat{\beta}_{1(-i)}.$$

(podrobněji se jim budeme věnovat později)

Grafy reziduí

1) histogram reziduí




2) kvantilový graf (Q-Q plot) studentizovaných reziduí

- seřadíme dle velikosti:

$$\hat{r}_{(1)} \leq \hat{r}_{(2)} \leq \dots \leq \hat{r}_{(n)} \quad \text{a vyneseme oproti} \quad \Phi^{-1}\left(\left(i - \frac{1}{2}\right)\frac{1}{n}\right), i = 1, \dots, n$$

- body by měly ležet přibližně na přímce ($E(r_{(i)}) \approx \Phi^{-1}\left(\left(i - \frac{1}{2}\right)\frac{1}{n}\right)$ pro normální chyby)
- použití:** ověření normality, detekce odlehlých pozorování




3) studentizovaná rezidua vs. jednotlivé vysvětlující proměnné x


$\hat{r}_i$ nezávisí na σ , graf $\hat{r}_i \times x_i$ lze použít pro detekci nelinearity nebo nekonstantního rozptylu

4) studentizovaná rezidua $\hat{r}_i$ vs. predikované hodnoty $\hat{y}_i$


- $\text{Cov}(\hat{e}_i, \hat{Y}_i) = 0$, tedy $\hat{r}_i$ a $\hat{Y}_i$ by měly být nekorelované, pokud platí model (*)
- tzn. graf $\hat{r}_i \times \hat{y}_i$ by měl být náhodně rozptýlený kolem osy x
- navíc $\hat{r}_i$ by měla ležet v $(-3, 3)$ ($\hat{r}_i \approx N(0, 1)$)



(a)




(b)



(c)

5) studentizovaná rezidua vs. pořadí pozorování

možná detekce řadové korelace mezi pozorováními



Obrázek: Studentizovaná rezidua $\hat{r}_i$ proti pořadí pozorování i .

01RAD - přednáška 5, 14.10.2025

3. Vícerozměrná regrese

- předp., že kromě y_i máme pro každé $i \in \hat{n}$ k dispozici také m nezávislých prom. $x_{i1}, x_{i2}, \dots, x_{im}$
- model:

$$Y_i = \beta_0 + \sum_{j=1}^m x_{ij}\beta_j + e_i, \quad i = 1, \dots, n,$$

kde $e_1, \dots, e_n$ jsou nezávislé (nekorelované) chyby a $e_i \sim (0, \sigma^2)$

- na základě pozorování $(x_{i1}, \dots, x_{im}, y_i), i = 1, \dots, n$, chceme odhadnout par. $\beta = (\beta_0, \beta_1, \dots, \beta_m)^T$
- předpoklad: $n > m + 1$
- maticový zápis: $\mathbf{Y} = (Y_1, \dots, Y_n)^T, \quad \mathbf{y} = (y_1, \dots, y_n)^T, \quad \mathbf{e} = (e_1, \dots, e_n)^T,$

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1m} \\ 1 & x_{21} & \cdots & x_{2m} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{pmatrix} \quad \text{matice modelu (regresní matice)}$$

Model:

$$\mathbf{Y}_{n \times 1} = \mathbf{X}_{n \times (m+1)} \beta_{(m+1) \times 1} + \mathbf{e}_{n \times 1} \quad (**)$$

Nejdříve budeme předpokládat $e_1, \dots, e_n$ nezávislé, $e_i \sim N(0, \sigma^2)$, tzn.

$$\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad \text{a} \quad \mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

Věrohodnostní funkce:

Pro pevné σ^2 je

$$\max_{\boldsymbol{\beta}} L(\boldsymbol{\beta}, \sigma^2) \quad \Longleftrightarrow \quad \min_{\boldsymbol{\beta}} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \min_{\boldsymbol{\beta}} g(\boldsymbol{\beta}).$$

VĚTA 3.1

Uvažujme model $(**)$ a necht' $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$. Potom $\hat{\beta}$ je MLE parametru β právě tehdy, když $\hat{\beta}$ je řešením soustavy rovnic

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}. \quad (\text{soustava normálních rovnic}) \quad (3.1)$$

Je-li matice $\mathbf{X}^T \mathbf{X}$ nesingulární, má tato soustava jednoznačné řešení ve tvaru

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Důkaz.

Lemma 3.1

Soustava lineárních rovnic $\mathbf{Ax} = \mathbf{y}$ má řešení $\iff \langle \mathbf{y}; \mathbf{z} \rangle = 0$ pro všechna $\mathbf{z}$ splňující $\mathbf{A}^T \mathbf{z} = \mathbf{0}$.

VĚTA 3.2

Soustava normálních rovnic $\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y}$ má vždy alespoň jedno řešení.

Důkaz.



POZNÁMKA 3.1

- z vět plyne, že MLE $\hat{\boldsymbol{\beta}}$ může být nalezen řešením $m + 1$ lineárních rovnic o $m + 1$ neznámých
- málokdy existuje analytické řešení, je třeba použít numerické metody
- matice $\mathbf{X}^T \mathbf{X}$ může být špatně podmíněná, což ovlivňuje numerickou přesnost $\hat{\boldsymbol{\beta}}$
- často se užívají metody jako Choleského rozklad, QR rozklad, singulární rozklad (SVD)

- odvodili jsme pro normální chyby, minimalizace $g(\beta)$ lze ale použít i pro jiné druhy chyb
- nalezené $\hat{\beta}$ se pak nazývá **ordinary least squares estimate (OLS)**

Jak poznat, že existuje jednoznačné řešení NR bez nutnosti výpočtu $\mathbf{X}^T \mathbf{X}$?

VĚTA 3.3

Matice $\mathbf{X}^T \mathbf{X}$ je nesingulární $\iff$ jsou sloupce matice $\mathbf{X}$ lineárně nezávislé.

Důkaz.



POZNÁMKA 3.2

- $n > m + 1$, $h(\mathbf{X}) = m + 1 \implies$ ex. jednoznačné řešení NR a to $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$,
- pokud navíc $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, je to MLE

POZNÁMKA 3.3

- pokud jsou sloupce $\mathbf{X}$ LZ, je $\mathbf{X}^T \mathbf{X}$ singulární (většinou detekováno num. metodou výpočtu $\hat{\beta}$)
- horší situace je, pokud jsou sloupce $\mathbf{X}$ „téměř“ LZ, tzv. **multikolinearita**
- způsobuje problémy při výpočtu $\hat{\beta}$, protože $\mathbf{X}^T \mathbf{X}$ je „téměř“ singulární
- jak detekovat a řešit multikolinearitu probereme na konci přednášky

Odhad parametru σ^2

- pro normální chyby získáme MLE σ^2 derivací $\ln L(\beta, \sigma^2)$, tedy

$$\sigma^2 = \frac{1}{n} SSE = \frac{1}{n} (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

kde $\hat{y}_i = (\mathbf{X}\hat{\beta})_i = \mathbf{x}_i^T \hat{\beta}$, $i = 1, \dots, n$, a $\mathbf{x}_i^T$ značí i -tý řádek matice $\mathbf{X}$

- jedná se o vychýlený odhad, proto se obecně používá nestranný odhad



$$s_n^2 = \frac{1}{n - (m + 1)} SSE = \frac{1}{n - m - 1} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

a $s_n = \sqrt{s_n^2}$ jako odhad σ

- pro $e_i \sim (0, \sigma^2)$ se také používají statistiky s_n^2, s_n

PŘÍKLAD 3.1 (Umělá data)

x1	x2	y
2	1	10
3	2	17
4	5	48
1	2	27
5	6	55
6	4	26
7	3	9
8	4	16



Jednorozměrné modely:

$$y = \beta_0 + \beta_1 x_1 + e: \quad \hat{\beta}_0 = 28.5, \quad p_{val} = 0.093, \quad \hat{\beta}_1 = -0.57, \quad p_{val} = 0.847, \quad R^2 = 0.00668$$

$$y = \beta_0 + \beta_1 x_2 + e: \quad \hat{\beta}_0 = -1.34, \quad p_{val} = 0.891, \quad \hat{\beta}_1 = 8.10, \quad p_{val} = 0.018, \quad R^2 = 0.6356$$

Dvourozměrný model:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + e: \quad \hat{\beta}_0 = 8, \quad \hat{\beta}_1 = -5, \quad \hat{\beta}_2 = 12, \quad p_{val} = 0.000, \quad R^2 = 1$$

PŘÍKLAD 3.2 (Porodní váha a gestační stáří)

Sex	Age	Weight
boy	40	2968
boy	38	2795
girl	40	3163
⋮	⋮	⋮

Definujeme proměnné:

$$y = \text{Weight}, \quad x_1 = \text{Age}, \quad x_2 = \begin{cases} 0, & \text{Sex} = \text{boy}; \\ 1, & \text{Sex} = \text{girl}. \end{cases} \quad (\text{dummy variable})$$

Model: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + e$

Uvažujeme vlastně dvě rovnoběžné přímky

$$Y_b = \beta_0 + \beta_1 x_1 + e \quad \text{pro chlapce}, \quad Y_g = (\beta_0 + \beta_2) + \beta_1 x_1 + e \quad \text{pro dívky}$$

Pro různé směrnice, můžeme přidat **interakci** x_1 a x_2 , tj. $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + e$

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
```

```

      Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age          111.98      29.05   3.855 0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl   18.42     41.76   0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101

```

3.1 Vlastnosti odhadů $\hat{\beta}$, s_n^2

VĚTA 3.4

Nechť $\hat{\beta}$ je OLS odhad parametru β v modelu (**), kde $h(\mathbf{X}) = m + 1$ a $e_1, \dots, e_n$ jsou nekorelované a $e_i \sim (0, \sigma^2)$. Potom platí

- 1) $E(\hat{\beta}) = \beta$, ($\hat{\beta}$ je nestranný)
- 2) $\text{Cov}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$,
- 3) $E(s_n^2) = \sigma^2$, (s_n^2 je nestranný)
- 4) pokud navíc $e_i \sim N(0, \sigma^2)$, $i = 1, \dots, n$, potom $\hat{\beta} \sim N_{m+1}(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$,
speciálně $\hat{\beta}_i \sim N(\beta_i, \sigma^2 v_i)$, kde $v_i = (\mathbf{X}^T \mathbf{X})_{ii}^{-1}$.

Důkaz.

POZNÁMKA 3.4 (Vlastnosti projekční matice $\mathbf{H}$)

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T, \quad \hat{\mathbf{Y}} = \mathbf{H} \mathbf{Y}, \quad \mathbf{H}^T = \mathbf{H}, \quad (\mathbf{I}_n - \mathbf{H})^T = (\mathbf{I}_n - \mathbf{H}) \quad (\text{symetrie})$$

$$\mathbf{H}^2 = \mathbf{H}, \quad (\mathbf{I}_n - \mathbf{H})^2 = (\mathbf{I}_n - \mathbf{H}), \quad (\text{idempotentnost})$$

$$\mathbf{H} \mathbf{X} = \mathbf{X}, \quad \mathbf{H}(\mathbf{I}_n - \mathbf{H}) = (\mathbf{I}_n - \mathbf{H})\mathbf{H} = \mathbf{0}, \quad \text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii} = m + 1.$$

VĚTA 3.5

Nechť $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ je LM (**), kde $h(\mathbf{X}) = m + 1$ a $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$. Potom

- 1) $\hat{\boldsymbol{\beta}}$ a s_n^2 jsou nezávislé náhodné veličiny,
- 2) $(n - m - 1) \frac{s_n^2}{\sigma^2} \sim \chi^2(n - m - 1)$,
- 3) jestliže $v_i = (\mathbf{X}^T \mathbf{X})_{ii}^{-1}$, potom $T_i = \frac{\hat{\beta}_i - \beta_i}{s_n \sqrt{v_i}} \sim t(n - m - 1)$.
- 4) Nechť $\mathbf{C} \in \mathbb{R}^{r, m+1}$ takové, že $h(\mathbf{C}) = r$. Potom kvadratická forma

$$\frac{q}{\sigma^2} = \frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{C}^T \left[\mathbf{C}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{C}^T \right]^{-1} \mathbf{C}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{\sigma^2} \sim \chi^2(r).$$

Důkaz.

Výsledky z LA:

- **Spektrální rozklad matice:**

$\mathbf{A}_{n \times n}$ symetrická matice $\Rightarrow$ existuje ortogonální matice $\mathbf{Q}$ a diagonální matice $\mathbf{\Lambda}$ tak, že $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$, sloupce $\mathbf{Q}$ jsou ON vlastní vektory matice $\mathbf{A}$ a diagonální prvky matice $\mathbf{\Lambda}$ jsou jim odpovídající vlastní čísla.

- $\mathbf{A}_{n \times n}$ idempotentní matice $\Rightarrow$ vlastní čísla jsou pouze 0 nebo 1 a $\text{h}(\mathbf{A}) = \text{tr}(\mathbf{A})$

Vlastnosti vektoru reziduí $\hat{\mathbf{e}}$

VĚTA 3.6

Uvažujme model $\mathbf{Y} = \mathbf{X}\beta + \mathbf{e}$, kde $e_1, \dots, e_n$ jsou nekorelované a $e_i \sim (0, \sigma^2)$. Nechť $\hat{\beta}$ je OLS β a $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\mathbf{Y}}$ je vektor reziduí. Potom platí:

- 1) $E\hat{\mathbf{e}} = \mathbf{0}$, $\text{Cov}(\hat{\mathbf{e}}) = \sigma^2(\mathbf{I}_n - \mathbf{H})$,
- 2) pokud navíc $\mathbf{e} \sim N_n(0, \sigma^2\mathbf{I}_n)$, potom $\hat{\mathbf{e}} \sim N_n(\mathbf{0}, \sigma^2(\mathbf{I}_n - \mathbf{H}))$,
- 3) jestliže má model intercept, tj. $\beta_0 \neq 0$, potom $\sum_{i=1}^n \hat{e}_i = 0$,
- 4) $\sum_{i=1}^n \hat{e}_i \hat{y}_i = 0$.

DŮSLEDEK: Použitím bodů 3) a 4) dostaneme (stejně jako u jednorozměrné regrese)

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

tedy

$$SST = SSR + SSE$$

(v modelu s interceptem)

Důkaz.

3.2 Gauss-Markov theorem

- e_i i.i.d $N(0, \sigma^2) \Rightarrow$ OLS $\hat{\beta}$ je MLE, tzn. je eficientní (MVUE par. β)
- nenormální chyby:
 - ukážeme, že OLS $\hat{\beta}$ je **BLUE** (best linear unbiased estimator) par. β (za jistých podmínek)
 - mohou ale existovat lepší lineární vychýlené odhady nebo nelineární odhady

DEFINICE 3.1

Nechť β je vektor regresních parametrů v LM. Řekneme, že $\hat{\beta}$ je **lineární odhad** β , jestliže každé $\hat{\beta}_j$ je LK pozorování Y_i , $i = 1, \dots, n$, tedy

$$\hat{\beta}_j = \sum_{i=1}^n a_{ij} Y_i, \quad j = 0, \dots, m.$$

V maticovém zápisu $\hat{\beta} = \mathbf{A}\mathbf{Y}$, kde $\mathbf{A}^T = (a_{ij})$, $i = 1, \dots, n$, $j = 0, \dots, m$.

POZNÁMKA: Pokud v modelu (**) platí $h(\mathbf{X}) = m + 1$, potom je OLS $\hat{\beta}$ lineární, neboť $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$.

VĚTA 3.7 (Gauss-Markov)

Uvažujme model $\mathbf{Y} = \mathbf{X}\beta + \mathbf{e}$, kde matice $\mathbf{X}$ má plnou hodnotu, $e_1, \dots, e_n$ jsou nekorelované a $e_i \sim (0, \sigma^2)$. Potom OLS odhad $\hat{\beta}$ je BLUE parametru β .

Důkaz.

3.3 Testování modelu - tabulka ANOVA

Celkový F-test (overall F-test)

- Je model statisticky signifikantní? Tj. je alespoň jeden z koeficientů $\beta_1, \dots, \beta_m$ nenulový?
- Mohli bychom testovat jednotlivé koeficienty $H_0 : \beta_j = 0$ pomocí alternativy t-testu.
- Celková chyba I. druhu by takto ale mohla být velká, pokud máme hodně proměnných. Museli bychom hodně snížit α pro jednotlivé testy, což zvýší pravděpodobnost chyby II. druhu
- Navíc je zde problém **multikolinearity**, jejíž jedním efektem jsou velké stand. chyby odhadů. To může vést k akceptování všech koeficientů jeho 0, i když je model celkově významný.

Bylo by dobré mít jednu statistiku pro test

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0 \quad \times \quad H_1 : \exists i \in \hat{m}, \beta_i \neq 0$$

ANOVA přístup pro jedn. regresi naznačuje, že statistika

$$F = \frac{\frac{SSR}{m}}{s_n^2}$$

by mohla být užitečná (vyplyne i z obecnějších přístupů k testování později)

Označení: $\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$ – průměr j -tého sloupce matice $\mathbf{X}$,

$$\bar{\mathbf{X}} = \begin{pmatrix} \bar{x}_0 & \bar{x}_1 & \cdots & \bar{x}_m \\ \vdots & \vdots & & \vdots \\ \bar{x}_0 & \bar{x}_1 & \cdots & \bar{x}_m \end{pmatrix}_{n \times m+1} \quad (\mathbf{X}_c)_{ij} = x_{ij} - \bar{x}_j, \quad i = 1, \dots, n, \quad j = 1, \dots, m$$

VĚTA 3.8

V modelu $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ tvaru (**), kde $h(\mathbf{X}) = m + 1$, e_i jsou nekorelované a $e_i \sim (0, \sigma^2)$, $i = 1, \dots, n$, platí

$$E \left[\frac{SSR}{m} \right] = \sigma^2 + \frac{\boldsymbol{\beta}^T (\mathbf{X} - \bar{\mathbf{X}})^T (\mathbf{X} - \bar{\mathbf{X}}) \boldsymbol{\beta}}{m} = \sigma^2 + \frac{\boldsymbol{\beta}_s^T \mathbf{X}_c^T \mathbf{X}_c \boldsymbol{\beta}_s}{m},$$

kde $\boldsymbol{\beta}_s = (\beta_1, \dots, \beta_m)^T$.

Věta z PRA: Nechť $Z = \mathbf{Y}^T \mathbf{A} \mathbf{Y}$ je kvadratická forma a nechť $E\mathbf{Y} = \boldsymbol{\mu}$ a $\text{Cov}\mathbf{Y} = \boldsymbol{\Sigma}$. Potom platí:

$$EZ = \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \boldsymbol{\mu}^T \mathbf{A} \boldsymbol{\mu}.$$

Důkaz.

POZNÁMKA 3.5

- pokud $\beta_s = 0$, potom $E\left(\frac{SSR}{m}\right) = \sigma^2 = E s_n^2$, $\beta_s \neq 0$ implikuje, že $E\left(\frac{SSR}{m}\right) > \sigma^2$
- tedy velké hodnoty $F = \frac{SSR/m}{s_n^2}$ budou znamenat zamítnutí $H_0 : \beta_s = 0$

VĚTA 3.9

Nechť v modelu $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ tvaru (**) platí $h(\mathbf{X}) = m + 1$ a $e_1, \dots, e_n$ jsou i.i.d. $N(0, \sigma^2)$. Pokud $\beta_s = \mathbf{0}$, tj. $\beta_1 = \beta_2 = \dots = \beta_m = 0$, potom

$$F \sim F(m, n - m - 1).$$

Důkaz.

TEST: zamítnout $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$ pokud $F > F_{1-\alpha}(m, n - m - 1)$

POZNÁMKA: Odvozeno pro $e_i \sim N(0, \sigma^2)$. Obecně se používá, i když to nevíme, pro velké n může být často zdůvodněno pomocí CLV.

Tabulka ANOVA

Source	df	SS	MS	F
Regression	m	SSR	$MSR = \frac{SSR}{m}$	$\frac{MSR}{MSE}$
Residual	$n - m - 1$	SSE	$MSE = \frac{SSE}{n - m - 1} = s_n^2$	
Total	$n - 1$	SST		
		R^2	$\bar{R}^2$	

Koeficient (vícenásobné) determinace R^2 :

Podobně jako u jednorozměrné regrese, lze F-test chápat jako test významnosti R^2 , definovaného jako

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (SST = SSR + SSE)$$

POZNÁMKA 3.6

- R^2 je možno zvětšovat přidáváním nových proměnných x , i když jsou statisticky nevýznamné (Pro n LN proměnných x a n pozorování dostaneme "perfect fit") (overfitting)
- Vysvětlení: $R^2 = 1 - \frac{SSE}{SST}$, kde
 - SST je pevně dáno daty y , ale SSE může být snížena přidáním proměnných x
 - minimalizujeme totiž $(\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta)$ přes větší množinu β
 - to znamená, že $\frac{SSE}{SST}$ je nerostoucí funkce a R^2 je neklesající funkce počtu proměnných

Upravený koeficient determinace (adjusted coefficient of determination):

$$\bar{R}^2 = R_{adj}^2 = 1 - \frac{\frac{SSE}{n - m - 1}}{\frac{SST}{n - 1}} = 1 - \frac{n - 1}{n - m - 1} \frac{SSE}{SST}.$$

PŘÍKLAD 3.3 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age          111.98     29.05   3.855 0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl   18.42     41.76   0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101

SSR <- sum((predict(mod)-mean(Weight))^2)
SSE <- sum((predict(mod)-(Weight))^2)
F <- (SSR/3)/(SSE/(24-3-1)); F

## 12.03152

anova(mod)

## Analysis of Variance Table
## Response: Weight
##      Df Sum Sq Mean Sq F value    Pr(>F)
## Age    1 1013799 1013799 31.0779 1.862e-05 ***
## Sex     1  157304  157304  4.8221  0.04006 *
## Age:Sex 1    6346    6346  0.1945  0.66389
## Residuals 20 652425    32621
## ---
```

3.4 Intervaly spolehlivosti a t -testy pro parametry

- pokud se model ukáže jako významný, bude nás zajímat, které koeficienty přispívají
- lze použít IS a TH stejně, jako u jednorozměrné regrese
- výsledky jsou odvozeny pro normální chyby
- v praxi se používají i pro jiné typy chyb

Pro konstrukci použijeme dokázanou vlastnost

$$T_j = \frac{\hat{\beta}_j - \beta_j}{s_n \sqrt{v_j}} \sim t(n - m - 1), \quad \text{kde} \quad v_j = (\mathbf{X}^T \mathbf{X})_{jj}^{-1}$$

100(1 - α)% IS pro β_j je

$$(\hat{\beta}_j - t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j}, \hat{\beta}_j + t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j})$$

S pomocí IS lze odvodit kritický obor pro test $H_0 : \beta_j = b_j \times H_1 : \beta_j \neq b_j$ ve tvaru

$$\frac{|\hat{\beta}_j - b_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

Pro $b_j = 0$ dostaneme test významnosti β_j , tzn. $H_0 : \beta_j = 0$ zamítneme, pokud

$$\frac{|\hat{\beta}_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

POZNÁMKA 3.7

- pokud nejsou porušeny předpoklady modelu nebo není přítomna kolinearita, lze zvážit odstranění všech nevýznamných proměnných (dle t-testu)
- v případě kolinearit, může být model významný (dle celkového F-testu), ale všechny nebo téměř všechny proměnné se mohou jevit jako nevýznamné (dle t-testů)
- naopak, pokud má model velký počet možných proměnných, některé proměnné se mohou jevit významné, i když jsou náhodným šumem
- při použití t-testů je třeba postupovat obezřetně

PŘÍKLAD 3.4 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138  0.268492
## Age          111.98     29.05    3.855  0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542  0.593952
## Age:Sexgirl   18.42     41.76    0.441  0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101
```

```
vif(mod)
## Age      Sex      Age:Sex
## 1.96444 477.55172 483.47306
```

```
mod0 <- lm(Weight ~ Age + Sex)
summary(mod0)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1610.28    786.08  -2.049   0.0532 .
## Age          120.89     20.46    5.908 7.28e-06 ***
## Sexgirl      -163.04     72.81  -2.239   0.0361 *
## ---
## Residual standard error: 177.1 on 21 degrees of freedom
## Multiple R-squared:  0.64,    Adjusted R-squared:  0.6057
## F-statistic: 18.67 on 2 and 21 DF,  p-value: 2.194e-05
```

```
vif(mod0)
## Age      Sex
## 1.013904 1.013904
```

PŘÍKLAD 3.5 (Data cement)

	x1	x2	x3	x4	y
1	7	26	6	60	78.5
2	1	29	15	52	74.3
3	11	56	8	20	104.3
4	11	31	8	47	87.6
5	7	52	6	33	95.9
6	11	55	9	22	109.2
7	3	71	17	6	102.7
8	1	31	22	44	72.5
9	2	54	18	22	93.1
10	21	47	4	26	115.9
11	1	40	23	34	83.8
12	11	66	9	12	113.3
13	10	68	8	12	109.4

```
mod <- lm(y ~ x1 + x2 + x3 + x4)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  62.4054    70.0710   0.891   0.3991
## x1           1.5511     0.7448   2.083   0.0708 .
## x2           0.5102     0.7238   0.705   0.5009
## x3           0.1019     0.7547   0.135   0.8959
## x4          -0.1441     0.7091  -0.203   0.8441
## ---
## Residual standard error: 2.446 on 8 degrees of freedom
## Multiple R-squared:  0.9824,    Adjusted R-squared:  0.9736
## F-statistic: 111.5 on 4 and 8 DF,  p-value: 4.756e-07
```

```
vif(mod)
##           x1           x2           x3           x4
## 38.49621 254.42317  46.86839 282.51286
```

```
mod1 <- lm(y ~ x1)
summary(mod1)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  81.4793     4.9273  16.54 4.07e-09 ***
## x1           1.8687     0.5264   3.55 0.00455 **
## ---
## Residual standard error: 10.73 on 11 degrees of freedom
## Multiple R-squared:  0.5339,    Adjusted R-squared:  0.4916
## F-statistic: 12.6 on 1 and 11 DF,  p-value: 0.004552
```

```

mod12 <- lm(y ~ x1 + x2)
summary(mod12)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 52.57735    2.28617   23.00 5.46e-10 ***
## x1          1.46831    0.12130   12.11 2.69e-07 ***
## x2          0.66225    0.04585   14.44 5.03e-08 ***
## ---
## Residual standard error: 2.406 on 10 degrees of freedom
## Multiple R-squared:  0.9787,    Adjusted R-squared:  0.9744
## F-statistic: 229.5 on 2 and 10 DF,  p-value: 4.407e-09

vif(mod12)
##           x1           x2
## 1.055129 1.055129

```

POZNÁMKA 3.8

- statistiky F , R^2 a t jsou užitečné pro rozkrytí efektů jednotlivých proměnných
- nemohou být ale používány úplně automaticky

3.5 Obecná lineární hypotéza

Hypotézy uvažované v F-testu a t-testech jsou speciálním případem **obecné lineární hypotézy**

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{b} \quad \times \quad H_1 : \mathbf{C}\boldsymbol{\beta} \neq \mathbf{b},$$

kde $\mathbf{C} \in \mathbb{R}^{r \times (m+1)}$ a $h(\mathbf{C}) = r$ (tzn. $r \leq m+1$)

Rovnice $\mathbf{C}\boldsymbol{\beta} = \mathbf{b}$ reprezentuje r lineárně nezávislých podmínek

$$\sum_{j=0}^m c_{ij}\beta_j = b_i, \quad i = 1, \dots, r.$$

POZNÁMKA 3.9

a) volba $\mathbf{b} = (0, \dots, 0)^T$ a $\mathbf{C} = \left(\begin{array}{c|cccc} 0 & 1 & 0 & \dots & 0 \\ \hline 0 & 0 & 1 & & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 0 & 0 & \dots & 0 & 1 \end{array} \right)_{m \times (m+1)}$ vede na test

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{0} \quad \Leftrightarrow \quad H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0,$$

b) volba $\mathbf{b} = \mathbf{0}$ a $\mathbf{C} = (0, \dots, 0, 1, 0, \dots, 0)$ vede na test $H_0 : \beta_j = 0$,

c) v modelu $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + e$ chceme testovat zároveň, že $\beta_2 = 0$ a $\beta_3 = \beta_4$,

to lze udělat volbou $\mathbf{C} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{pmatrix}$, $\mathbf{b} = (0, 0)^T$.

Pro test H_0 naladíme 2 modely:

1) **plný model** (full model) - bez podmínek na $\mathbf{C}\beta$,

2) **redukovaný model** (reduced model) - za předpokladu, že platí $H_0 : \mathbf{C}\beta = \mathbf{b}$.

Označme příslušné reziduální součty čtverců SSE_F a SSE_R ($SSE_F \leq SSE_R$)

- pokud neplatí H_0 , dá se očekávat, že $\Delta SSE = SSE_R - SSE_F$ bude významně větší, než náhodná chyba σ^2
- H_0 tedy budeme zamítat, pokud $\frac{\Delta SSE}{s_n^2}$ bude velké
- zobecnění F-testu, za platnosti H_0 ukážeme pro normální chyby vztah

$$F = \frac{\frac{\Delta SSE}{r}}{s_n^2} \sim F(r, n - m - 1)$$

PŘÍKLAD 3.6

Uvažujme F-test pro $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$ v plném modelu (**).

VĚTA 3.10

Nechť v modelu $(**)$ platí, že $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ a $h(\mathbf{X}) = m + 1$. Označme SSE_F reziduální s.č. plného modelu a SSE_R reziduální s.č. modelu, kde platí $H_0: \mathbf{C}\boldsymbol{\beta} = \mathbf{b}$. Potom je za platnosti H_0 splněno

$$F = \frac{\frac{\Delta SSE}{r}}{s_n^2} \sim F(r, n - m - 1), \quad \text{kde } \Delta SSE = SSE_R - SSE_F.$$

Lemma 3.2

Označme $\hat{\boldsymbol{\beta}}_F$ a $\hat{\boldsymbol{\beta}}_R$ LSE parametru $\boldsymbol{\beta}$ v plném a redukovaném modelu. Potom platí

- 1) $\hat{\boldsymbol{\beta}}_R = \hat{\boldsymbol{\beta}}_F - (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{C}^T \mathbf{A} (\mathbf{C} \hat{\boldsymbol{\beta}}_F - \mathbf{b})$, kde $\mathbf{A} = \left(\mathbf{C} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{C}^T \right)^{-1}$,
- 2) $\Delta SSE = SSE_R - SSE_F = \left(\mathbf{C} \hat{\boldsymbol{\beta}}_F - \mathbf{b} \right)^T \mathbf{A} \left(\mathbf{C} \hat{\boldsymbol{\beta}}_F - \mathbf{b} \right).$

Důkaz.

Důkaz Věty 3.10.



POZNÁMKA 3.10

- použitím rozkladu $SST = SSE + SSR$ dostaneme

$$\Delta SSE = SSR_F - SSR_R.$$

interpretace: nárůst regresního součtu čtverců díky neplatnosti H_0

- dále

$$SSR_F = SSR_R + \Delta SSE,$$

kde ΔSSE se nazývá **extra sum of squares** (přidaný k SSR díky neplatnosti H_0)

- např. pokud $\beta_R = (\beta_0, \beta_1, \dots, \beta_{m-1}, 0)$, tzn. $\beta_m = 0$ a skutečný model má $\beta = \beta_F$, potom ΔSSE je extra regresní součet čtverců získaný díky přidání β_m do modelu
- umožňuje rozklad SSR plného modelu na jednotlivé části $(x_1, x_2 | x_1, x_3 | x_2 x_1, \dots)$

PŘÍKLAD 3.7 (Porodní váha)

```
mod <- lm(Weight ~ Age + Sex + Sex:Age)
anova(mod)
```

```
## Analysis of Variance Table
## Response: Weight
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Age         1 1013799 1013799 31.0779 1.862e-05 ***
## Sex         1  157304  157304   4.8221  0.04006 *
## Age:Sex      1    6346    6346   0.1945  0.66389
## Residuals  20  652425   32621
```

```
mod0 <- lm(Weight ~ Age + Sex)
anova(mod0,mod)
```

```
## Analysis of Variance Table
## Model 1: Weight ~ Age + Sex
## Model 2: Weight ~ Age + Sex + Sex:Age
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1       21 658771
## 2       20 652425   1    6346.2 0.1945 0.6639
```

```
SSR <- sum((predict(mod)-mean(y))^2)
SSR0 <- sum((predict(mod0)-mean(y))^2)
D.SSE <- SSR-SSR0; D.SSE
## 6346.225
MSE<- sum((predict(mod)-Weight)^2)
F<- D.SSE/MSE*(24-3-1); F
## 0.1945428
```

PŘÍKLAD 3.8 (Data cement)

```
mod <- lm(y ~ x1 + x2 + x3 + x4)
anova(mod)
```

```
## Analysis of Variance Table
## Response: y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## x1         1 1450.08 1450.08 242.3679 2.888e-07 ***
## x2         1 1207.78 1207.78 201.8705 5.863e-07 ***
## x3         1    9.79    9.79   1.6370  0.2366
## x4         1    0.25    0.25   0.0413  0.8441
## Residuals   8   47.86    5.98
## ---
```

```
y.hat <- predict(mod)
SSR <- sum((y.hat-mean(y))^2); SSR
## 2667.899
```

3.6 Predikce

a) Intervaly spolehlivosti pro $E(Y_{\mathbf{x}})$

- nechť $\mathbf{x}_0 = (1, x_{0,1}, \dots, x_{0,m})^T$ je nový bod proměnné $\mathbf{x}$
- bodový odhad $E(Y_{\mathbf{x}_0})$ je roven

$$\hat{Y}_{\mathbf{x}_0} = \hat{\beta}_0 + \sum_{j=1}^m x_{0,j} \hat{\beta}_j = \mathbf{x}_0^T \hat{\boldsymbol{\beta}}$$

- tzn. $\text{Var}(\hat{Y}_{\mathbf{x}_0}) = \mathbf{x}_0^T \cdot \text{Var}(\hat{\boldsymbol{\beta}}) \cdot \mathbf{x}_0 = \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0$
- a může být odhadnut pomocí

$$\hat{\sigma}^2(\hat{Y}_{\mathbf{x}_0}) = s_n^2 [\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0] \quad (\text{rozptyl predikce})$$

- speciálně pokud $\mathbf{x}_0^T = \mathbf{x}_i^T$ (i -tý řádek matice $\mathbf{X}$)

$$\hat{\sigma}^2(\hat{Y}_{\mathbf{x}_i}) = s_n^2 [\mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i] = s_n^2 h_{ii} \quad \text{kde} \quad h_{ii} = (\mathbf{H})_{ii} \quad \text{a} \quad \mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

- pro normální chyby lze odvodit interval spolehlivosti pro $E(Y_{\mathbf{x}_0}) = \mu_{\mathbf{x}_0}$

- $\hat{Y}_{\mathbf{x}_0}$ má totiž normální rozdělení (je to LK složek vektoru $\hat{\beta}$) a platí

$$E(\hat{Y}_{\mathbf{x}_0}) = \mu_{\mathbf{x}_0} = \mathbf{x}_0^T \beta \quad \text{a} \quad \text{Var}(\hat{Y}_{\mathbf{x}_0}) = \sigma^2 \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0$$

- tzn.

$$\frac{\hat{Y}_{\mathbf{x}_0} - \mu_{\mathbf{x}_0}}{\sigma \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}} \sim N(0, 1)$$

a díky nezávislosti $\hat{\beta}$ a s_n^2

$$\frac{\hat{Y}_{\mathbf{x}_0} - \mu_{\mathbf{x}_0}}{s_n \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}} \sim t(n - m - 1)$$

- 100(1 - α)% IS pro $\mu_{\mathbf{x}_0}$ tedy je:

$$\left(\hat{Y}_{\mathbf{x}_0} \pm t_{1-\frac{\alpha}{2}}(n - m - 1) \cdot s_n \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0} \right)$$

POZNÁMKA: Intervaly spolehlivosti v 

95% intervaly spolehlivosti

```
CI<-predict(mod.lin, new, interval = "confidence")
```

b) Intervaly predikce pro $Y_{\mathbf{x}_0}$

- bodový odhad je opět $\hat{Y}_{\mathbf{x}_0}$
- pokud $Y_{\mathbf{x}_0}$ je skutečná hodnota $Y_{\mathbf{x}}$ v bodě $\mathbf{x} = \mathbf{x}_0$, potom $Y_{\mathbf{x}_0}$ a $\hat{Y}_{\mathbf{x}_0}$ budou nezávislé za předpokladu, že pozorování $Y_{\mathbf{x}_0}, Y_1, \dots, Y_n$ jsou nezávislá (což předpokládáme)
- potom

$$\text{Var}(\hat{Y}_{\mathbf{x}_0} - Y_{\mathbf{x}_0}) = \text{Var}(\hat{Y}_{\mathbf{x}_0}) + \text{Var}(Y_{\mathbf{x}_0}) = \sigma^2(1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0),$$

- takže

$$\frac{\hat{Y}_{\mathbf{x}_0} - Y_{\mathbf{x}_0}}{\sigma\sqrt{1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0}} \sim N(0, 1) \quad \text{a} \quad \frac{\hat{Y}_{\mathbf{x}_0} - Y_{\mathbf{x}_0}}{s_n\sqrt{1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0}} \sim t(n - m - 1)$$

(za předpokladu normality chyb)

- $100(1 - \alpha)\%$ IP pro $Y_{\mathbf{x}_0}$ tedy je

$$\left(\hat{Y}_{\mathbf{x}_0} \pm t_{1-\frac{\alpha}{2}}(n - m - 1) \cdot s_n \sqrt{1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0} \right)$$

POZNÁMKA: 95% Intervaly predikce v :


```
PI<-predict(mod.lin, new, interval = "prediction")
```

POZNÁMKA 3.11 (Extrapolace)

- u jednoduché LR kvalita predikce závisela na vzdálenosti x_0 od $\bar{x}$
- je třeba si dát pozor na predikce mimo $\langle x_{min}, x_{max} \rangle$
- podobné závěry platí i pro vícerozměrnou LR
- protože rozptyl predikce je úměrný $\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0$, v bodech s velkými hodnotami této veličiny nebude predikce spolehlivá
- speciálně pokud $\mathbf{x}_i$ jsou pozorovaná data, můžeme očekávat, že body s nejvyššími hodnotami $\mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i = h_{ii}$ budou na hranici množiny, kde je predikce spolehlivá
- tzn., že vnitřek elipsoidu


$$\mathbf{x}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x} \leq \max_{1 \leq i \leq n} h_{ii}$$

může být považován za **přípustný obor predikce**



4. Rezidua, diagnostika a transformace

- je třeba ověřit adekvátnost modelu
máme R^2 , t , F statistiky, byly odvozeny za předpokladu linearity modelu a dalších podmínek
pro ověření je důležitý nástroj **analýza reziduí**
- je také třeba ověřit vliv jednotlivých pozorování na model
analýza odlehlých (outliers) a **vlivných pozorování** (influential observations)



- při detekci problémů s modelem
mohou pomoci **transformace proměnných** nebo **metoda na korekci nekonstantního rozptylu**

4.1 Rezidua

Připomenutí:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{H}\mathbf{y}, \quad \text{kde} \quad \mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T, \quad \hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I}_n - \mathbf{H})\mathbf{y} = (\mathbf{I}_n - \mathbf{H})\mathbf{e}$$

Dále jsme ukázali:

$$E(\hat{\mathbf{e}}) = \mathbf{0}, \quad \text{Cov}(\hat{\mathbf{e}}) = \sigma^2(\mathbf{I}_n - \mathbf{H}), \quad \text{pokud } \mathbf{e} \sim N_n(\mathbf{0}, \sigma^2\mathbf{I}_n) \text{ potom } \hat{\mathbf{e}} \sim N_n(\mathbf{0}, \sigma^2(\mathbf{I}_n - \mathbf{H}))$$

Při označení $h_{ij} = \mathbf{H}_{ij}$ tedy platí $\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii})$ a $\text{Cov}(\hat{e}_i, \hat{e}_j) = -\sigma^2 h_{ij}$

Obecně bývá výhodnější pracovat s normovanými rezidui

$$r_i = \frac{\hat{e}_i}{\sigma\sqrt{1 - h_{ii}}}, \quad \text{pro která platí } \text{Var}(r_i) = 1$$

- pokud σ^2 odhadneme pomocí $s_n^2 = \frac{1}{(n-m-1)} SSE$, dostaneme

$$\hat{r}_i = \frac{\hat{e}_i}{s_n\sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n, \quad \text{tzv. interně studentizovaná rezidua}$$

někdy také **standardizovaná rezidua**, funkce v : `rstandard(mod)`

- pokud σ^2 odhadneme na základě modelu, ve kterém bylo vynecháno i -té pozorování, ozn. $\hat{\sigma}_{(-i)}^2$, dostaneme

$$\hat{t}_i = \frac{\hat{e}_i}{\hat{\sigma}_{(-i)} \sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n, \quad \text{tzv. externě studentizovaná rezidua}$$

někdy také **studentizovaná rezidua**, funkce v : `rstudent(mod)`

např. $\hat{\sigma}_{(-i)}^2 = \frac{1}{n-m-2} SSE_{(-i)}$ je nestranný odhad σ^2 v modelu bez i -tého pozorování

POZNÁMKA 4.1

- pokud je h_{ii} malé, pro velká n by se měla $\hat{e}_i, \hat{r}_i, \hat{t}_i$ chovat přibližně stejně a $\hat{r}_i, \hat{t}_i \approx N(0, 1)$
- pro malá n ($n < 20$) a/nebo $h_{ii} \approx 1$ je preferováno použití $\hat{r}_i$ nebo $\hat{t}_i$
- častěji bývá doporučováno $\hat{t}_i$
- h_{ii} hraje zásadní roli v diagnostice modelu, probereme jeho základní vlastnosti

Leverage h_{ii} - potenciál i -tého pozorování

leverage point - pákový bod, vzdálený bod

Vlatnosti potenciálu h_{ii}

- $\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii}) \geq 0 \Rightarrow h_{ii} \leq 1$
- $\mathbf{H}^2 = \mathbf{H} \Rightarrow h_{ii} = \sum_{j=1}^n h_{ij}h_{ji} = \sum_{j=1}^n (h_{ij})^2$ tedy $h_{ii} > 0$ (dá se ukázat: $h_{ii} \geq \frac{1}{n}$)
- $\mathbf{HX} = \mathbf{X} \Rightarrow \sum_{j=1}^n h_{ij}x_{j1} = \sum_{j=1}^n h_{ij} = x_{i1} = 1$ tedy $\sum_{j=1}^n h_{ij} = 1, \forall i \in \hat{n}$ (v mod. s interceptem)
- význam h_{ii} vyplýne z následujících úvah: $\hat{\mathbf{y}} = \mathbf{Hy} \Rightarrow \hat{y}_i = \sum_{j=1}^n h_{ij}y_j = h_{ii}y_i + \sum_{j=1, j \neq i}^n h_{ij}y_j$
 - pokud $h_{ii} \approx 1$, potom $\hat{y}_i \approx y_i$ a model je nucen proložit přímkou bodem $(\mathbf{x}_i, y_i)$ i když když tam neplatí
 - body s „velkým h_{ii} “ - **body s velkým potenciálem** (high leverage points)
 - tyto body by měly být detekovány pro další zkoumání
- otázka je, jaká hodnota h_{ii} je „velká“
Heuristické pravidlo: $\sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{H}) = m + 1$, tzn. $\frac{m+1}{n}$ je průměrná hodnota h_{ii}
 i -té pozorování má velký potenciál, jestliže $h_{ii} > \frac{3(m+1)}{n}$

4.2 Grafy reziduí

A) ověření normality - histogramy, Q-Q plots

tyto obrázky nezávisí na počtu nezávislých proměnných x , vše stejné jako v jednorozměrné LR
testy normality: Shapiro-Wilk, Lilliefors, Anderson-Darling

B) pro ověření funkční formy pro $E(Y_x)$ a / nebo konstantního rozptylu se nejčastěji používají:

- 1) grafy $\hat{e}_i, \hat{r}_i$ nebo $\hat{t}_i$ oproti $\mathbf{x}_j^c$, $j = 1, \dots, m$, kde $\mathbf{x}_j^c$ je j -tý sloupec $\mathbf{X}$
- 2) grafy $\hat{e}_i, \hat{r}_i$ nebo $\hat{t}_i$ oproti $\hat{y}_i$
- 3) partial residual plots

testy konstantního rozptylu: Breusch-Pagan, Levene

POZNÁMKA 4.2

Zdůvodnění 1): normální rovnice $\mathbf{X}^T(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0$ implikují $\mathbf{X}^T(\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{X}^T\hat{\mathbf{e}} = 0$

připomenutí: $\mathbf{Y}_i = \beta_1 x_i + e_i$,
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\|^2}$$

- pro LR model bez interceptu pro $\hat{\mathbf{e}}$ v závislosti na $\mathbf{x}_j^c$ bude odhad směrnice

$$\hat{\beta}_j^* = \frac{(\mathbf{x}_j^c)^T \hat{\mathbf{e}}}{\|\mathbf{x}_j^c\|^2} = 0$$

- graf $\hat{e}_i, \hat{r}_i, \hat{t}_i$ oproti $\mathbf{x}_j^c$ by měl dávat náhodně rozptýlené body kolem osy x (bez trendů, $\hat{r}_i, \hat{t}_i$ uvnitř $\approx \pm 2$)
- pokud tomu tak není, může to naznačovat nelinearitu v $\mathbf{x}_j$ nebo nekonstantní rozptyl

Zdůvodnění 2): ukázali jsme $\sum_{i=1}^n \hat{y}_i \hat{e}_i = 0$

- pro LM bez interceptu pro $\hat{e}_i$ oproti $\hat{y}_i$ tedy platí

$$\hat{\beta} = \frac{\hat{\mathbf{e}}^T \hat{\mathbf{y}}}{\|\hat{\mathbf{y}}\|^2} = 0$$

- body by opět měly být náhodně rozptýlené kolem osy x
- trychtýřovitý tvar indikuje nekonstantní rozptyl
- trendy indikují nelinearitu

Ad 3) Partial residual plots

- i když grafy $\hat{\mathbf{e}}$ oproti $\mathbf{x}_j^c$ a $\hat{\mathbf{y}}$ mohou indikovat nedostatky modelu, nemusí být zřejmé, jaké ty nedostatky jsou
- V SLR graf $\hat{e}_i$ oproti x_i lze použít pro detekci nelinearity
- ale v MLR tyto grafy mohou být zavádějící, protože $\hat{\mathbf{e}}$ závisí na všech prediktorech, nemusí být tedy izolován efekt dané proměnné při odstranění efektů ostatních
- pro zkoumání efektů j -té proměnné lze použít **partial residual plots**
 - lze je chápat jako ekvivalent scatterplotů v SLR
- definujme $\hat{\mathbf{e}}_j^* = \hat{\mathbf{e}} + \hat{\beta}_j \mathbf{x}_j^c$,
kde $\hat{\mathbf{e}}$ je vektor reziduí modelu, $\hat{\beta}_j$ je LSE parametru β_j , $\mathbf{x}_j^c$ je j -tý sloupec $\mathbf{X}$
- **partial residual plot (PRP)**: graf $\hat{\mathbf{e}}_j^*$ oproti $\mathbf{x}_j^c$, $j = 1, \dots, m$
- pokud je model správný, měly by být body náhodně rozmístěné kolem přímky se směrnici $\hat{\beta}_j$

Zdůvodnění:





- vztah mezi $\hat{\mathbf{e}}_j^*$ a $\mathbf{x}_j^c$ má formu SLR bez interceptu
- pokud je model správný, platí $E(\hat{\mathbf{e}}_i) = 0$ a $\text{Var}(\hat{\mathbf{e}}_i) = \sigma^2(1 - h_{ii})$
- má tedy smysl uvažovat regresní model pro $\hat{\mathbf{e}}_j^*$ oproti $\mathbf{x}_j^c$ ($\hat{\mathbf{e}}_j^* = \gamma_j \mathbf{x}_j^c + \mathbf{e}$)
- pro odhad koeficientu platí

$$\hat{\gamma}_j = \frac{(\hat{\mathbf{e}}_j^*)^T \mathbf{x}_j^c}{\|\mathbf{x}_j^c\|^2} = \frac{(\hat{\mathbf{e}} + \hat{\beta}_j \mathbf{x}_j^c)^T \mathbf{x}_j^c}{\|\mathbf{x}_j^c\|^2} = \frac{\hat{\mathbf{e}}^T \mathbf{x}_j^c + \hat{\beta}_j \|\mathbf{x}_j^c\|^2}{\|\mathbf{x}_j^c\|^2} = \hat{\beta}_j$$

PŘÍKLAD 4.1 (Housing Price Data)

	Feet2	Age	Price
1	1800	1	120000
2	1650	7	110000
3	2750	12	150000
4	1550	8	90000
⋮	⋮	⋮	⋮

```
mod <- lm(Price ~ Feet2 + Age)
summary(mod)
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) 13238.600   7677.183   1.724 0.110273
## Feet2       60.589     3.644   16.625 1.19e-09 ***
## Age       -1726.762    364.172  -4.742 0.000479 ***
## ---
## Residual standard error: 7763 on 12 degrees of freedom
## Multiple R-squared:  0.9586,    Adjusted R-squared:  0.9517
## F-statistic: 139 on 2 and 12 DF, p-value: 5.021e-09
```





```
termplot(mod, partial.resid=TRUE, terms="Feet2")
```

```
termplot(mod, partial.resid=TRUE, terms="Age")
```

PŘÍKLAD 4.2 (Porodní váha)

```
mod <- lm(Weight ~ Age + Sex)
termplot(mod, partial.resid=TRUE, terms="Age")
termplot(mod, partial.resid=TRUE, terms="SEX")
```



- PRPs jsou někdy kritizovány za nadhodnocování efektu $\mathbf{x}_j^c$
- alternativa: **partial regression plot (added variable plot)**
- motivace: ptáme se, zda přidat novou proměnnou do modelu a chceme odhadnout její efekt

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \gamma\mathbf{w} + \mathbf{e}, \quad \text{kde } \mathbf{w} \text{ je nový vektor regresorů}$$

lze zapsat jako

$$\mathbf{Y} = [\mathbf{X} \ \mathbf{w}] \begin{bmatrix} \boldsymbol{\beta} \\ \gamma \end{bmatrix} + \mathbf{e} = \mathbf{X}_w \boldsymbol{\beta}_w + \mathbf{e}$$

požitím normálních rovnic lze odvodit

$$\hat{\gamma} = \frac{\hat{\mathbf{e}}^T (\mathbf{I} - \mathbf{H}) \mathbf{w}}{\|(\mathbf{I} - \mathbf{H}) \mathbf{w}\|^2} \quad (4.1)$$

$\hat{\gamma}$ je směrnice RM pro $\hat{\mathbf{e}}$ v závislosti na $\mathbf{w}_{res} = (\mathbf{I} - \mathbf{H}) \mathbf{w}$

- uvažujme teď naopak, že $\mathbf{w}$ je sloupec původní matice, např. $\mathbf{x}_j^c$ a ozn. $\mathbf{X}_{(-j)}$ matici $\mathbf{X}$ bez sl. j
- v předchozím modelu položíme $\mathbf{X} = \mathbf{X}_{(-j)}$ a $\mathbf{w} = \mathbf{x}_j^c$, potom LSE parametru β_j je

$$\hat{\beta}_j = \frac{\hat{\mathbf{e}}_{(-j)}^T \mathbf{x}_{j,res}^c}{\|\mathbf{x}_{j,res}^c\|^2}, \quad \text{kde } \hat{\mathbf{e}}_{(-j)} \text{ jsou rezidua modelu bez } \mathbf{x}_j^c$$


a $\mathbf{x}_{j,res}^c = (\mathbf{I} - \mathbf{H}_{(-j)}) \mathbf{x}_j^c$, tedy jsou to rezidua modelu pro $\mathbf{x}_j^c$ v závislosti na ostatních proměnných

Added variable plot: graf $\hat{e}_{(-j)}$ proti $x_{j,res}^c$, $j = 1, \dots, m$

- pokud je model správný, body by měly být náhodně rozptýlené kolem přímky se směrnici $\hat{\beta}_j$ procházející počátkem
- pokud závislost na x_j^c není lineární, projeví se to odklonem bodů od přímky
- funkce v **R**: `avPlots()` knihovna `car`

PŘÍKLAD 4.3 (Housing Price Data)

```
mod <- lm(Price ~ Feet2 + Age)
avPlots(mod)
```



- pokud budeme chtít model použít nejen k vysvětlení vztahu mezi proměnnými, ale také pro predikci, hodila by se míra vyjadřující, jak dobře model predikuje
- šlo by použít IS nebo IP, museli bychom předem znát body, ve kterých chceme predikovat
- nejjednodušší přístup, jak měřit prediktivní přesnost modelu, by byl analýza reziduí pro predikce hodnot v nových $\mathbf{x}$
obecně ale nemáme data y v těchto bodech
- jedna možnost je použít data, která máme k dispozici
postup: vynecháme jedno pozorování, naladíme model bez tohoto pozorování a porovnáme predikovanou a pozorovanou hodnotu pro vynechané pozorování
- předp., že vynecháme i -té pozorování a označme

$\hat{\beta}_{(-i)}$ - odhad β v modelu s vynechaným i -tým pozorováním ($M_{(-i)}$)

$\hat{y}_{(-i)}$ - predikovanou hodnotu modelem $M_{(-i)}$ v bodě $\mathbf{x}_i^T$, tzn. $\hat{y}_{(-i)} = \mathbf{x}_i^T \hat{\beta}_{(-i)}$

potom

$$\hat{e}_{(-i)} = y_i - \hat{y}_{(-i)}, \quad i = 1, \dots, n,$$

nazýváme i -té PRESS reziduum

POZNÁMKA 4.3

Otázka je, jak počítat $\hat{e}_{(-i)}$, $i = 1, \dots, n$

- pro n velké, se to zdá náročný problém, pro každé i je třeba naladit nový model
- naštěstí to nebude nutné, ukážeme totiž $\hat{e}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}}$

Označme $\mathbf{x}_i^T$ i -tý řádek matice $\mathbf{X}$, $\mathbf{X}_{(-i)}$ matici $\mathbf{X}$ bez i -tého řádku a $h_{ii} = \mathbf{H}_{ii}$.

VĚTA 4.1

Jestliže $h_{ii} \neq 1$, potom
$$\left(\mathbf{X}_{(-i)}^T \mathbf{X}_{(-i)}\right)^{-1} = (\mathbf{X}^T \mathbf{X})^{-1} + \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1}}{1 - h_{ii}}.$$

Důkaz.

Věta z LA: (Sherman-Morrison-Woodbury)

Nechť $\mathbf{A}$ je $n \times n$ invertibilní matice a nechť $\mathbf{z}$ je $n \times 1$ sloupcový vektor. Jestliže $\mathbf{z}^T \mathbf{A}^{-1} \mathbf{z} \neq 1$, potom matice $\mathbf{B} = \mathbf{A} - \mathbf{z}\mathbf{z}^T$ je invertibilní a platí

$$\mathbf{B}^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1} \mathbf{z} \mathbf{z}^T \mathbf{A}^{-1}}{1 - \mathbf{z}^T \mathbf{A}^{-1} \mathbf{z}}.$$

VĚTA 4.2

Nechť $\hat{e}_{(-i)}$ je i -té PRESS reziduum. Potom $\hat{e}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}}, \quad i = 1, \dots, n.$

Důkaz.

VĚTA 4.3

- 1) Nechť $\hat{\beta}_{(-i)}$ značí *LSE* parametru β v modelu bez i -tého pozorování. Potom platí

$$\hat{\beta} - \hat{\beta}_{(-i)} = \frac{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \hat{e}_i}{1 - h_{ii}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \hat{e}_{(-i)}.$$

- 2) Pro součet residuálních čtverců $SSE_{(-i)}$ v modelu bez i -tého pozorování platí

$$SSE_{(-i)} = \sum_{j=1}^n \hat{e}_j^2 - \frac{\hat{e}_i^2}{1 - h_{ii}}.$$

Důkaz.

Důsledek 4.1

V modelu $(**)$ s $m + 1$ parametry β a bez i -tého pozorování platí

$$E[SSE_{(-i)}] = (n - m - 2)\sigma^2, \quad \text{to znamená} \quad \hat{\sigma}_{(-i)}^2 = \frac{SSE_{(-i)}}{n - m - 2} \quad \text{je nestranný odhad } \sigma^2.$$

Dále pak

$$\hat{\sigma}_{(-i)}^2 = \frac{(1 - h_{ii})(n - m - 1)s_n^2 - \hat{e}_i^2}{(1 - h_{ii})(n - m - 2)} = \frac{1}{n - m - 2} \left(SSE - \frac{\hat{e}_i^2}{1 - h_{ii}} \right),$$

kde $s_n^2 = \frac{1}{n - m - 1} SSE$ (pro plný model).

Důkaz.

POZNÁMKA 4.4

- dá se ukázat, že $SSE_{(-i)}$ a $\hat{e}_i$ jsou nezávislé náhodné veličiny
- protože $\frac{SSE_{(-i)}}{\sigma^2} \sim \chi^2(n - m - 2)$ a $\frac{\hat{e}_i}{\sigma\sqrt{1 - h_{ii}}} \sim N(0, 1)$
- dostaneme $\frac{\hat{e}_i}{\hat{\sigma}_{(-i)}\sqrt{1 - h_{ii}}} \sim t(n - m - 2)$

Tvrzení 4.1

Uvažujme model (**), kde $h(\mathbf{X}) = m + 1$ a $\mathbf{e} \sim N_n(0, \sigma^2 \mathbf{I}_n)$. Necht' pro $i \in \hat{n}$ platí, že $h_{ii} \neq 1$.
Potom i -té (externě) studentizované reziduum

$$\hat{t}_i \sim t(n - m - 2).$$

POZNÁMKA 4.5

- $\hat{t}_i$ lze použít pro test hypotézy, zda je i -té pozorování odlehlé (outlier), tedy

$$H_0 : i\text{-té pozorování není odlehlé v modelu } M \quad \times \quad H_1 : i\text{-té pozorování je odlehlé v } M,$$

- kde **odlehle** značí odlehlé vzhledem k M : $\mathbf{Y} \sim N_n(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$:
 - a) střední hodnota i -tého pozorování se nerovná té dané modelem,
 - b) pozorovaná hodnota Y_i je neobvyklá za platnosti M .
- H_0 zamítneme, pokud $|\hat{t}_i| > t_{1-\frac{\alpha}{2}}(n - m - 2)$
- pokud test použijeme na všechna pozorování, je potřeba aplikovat nějakou korekci na vícenásobné testování, např. Bonferroni

POZNÁMKA 4.6 (Vztah mezi $\hat{e}_{(-i)}$ a $\hat{t}_i$)

- $\hat{e}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}} \Rightarrow E\hat{e}_{(-i)} = 0, \quad \text{Var}\hat{e}_{(-i)} = \frac{\sigma^2}{1 - h_{ii}}$
- standardizované PRESS reziduum $\frac{\hat{e}_{(-i)}}{\sqrt{\text{Var}\hat{e}_{(-i)}}} = \frac{\frac{\hat{e}_i}{1 - h_{ii}}}{\frac{\sigma}{\sqrt{1 - h_{ii}}}} = \frac{\hat{e}_i}{\sigma\sqrt{1 - h_{ii}}} = r_i$
- pokud použijeme $\hat{\sigma}_{(-i)}^2$ jako odhad σ^2 , pak **studentizovaná PRESS rezidua**

$$\frac{\hat{e}_i}{\hat{\sigma}_{(-i)}\sqrt{1 - h_{ii}}} = \hat{t}_i$$

POZNÁMKA 4.7

- $\hat{e}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}} \Rightarrow$ pokud i -té pozorování má velké h_{ii} , bude $\hat{e}_{(-i)}$ mnohem větší, než $\hat{e}_i$,
 - pozorování s velkým h_{ii} jsou dobře modelována, ale měřeno $\hat{e}_{(-i)}$ mohou špatně predikovat
 - to je další ukázka **fit/prediction** dilema
- stejný efekt nastává také pro $\hat{\beta} - \hat{\beta}_{(-i)} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \hat{e}_{(-i)}$
rozdíl může být „malý“, pokud je „fit“ dobrý, ale může být také „velký“, pokud je h_{ii} velké.

Míry influence

- i pro perfektní model mohou dva různé vzorky $(\mathbf{x}, \mathbf{y})$ a $(\mathbf{x}', \mathbf{y}')$ vést k různým závěrům
- většinou máme k dispozici jen originální data
- bude nás zajímat vliv i -tého řádku $\mathbf{X}$ na model
- už víme, že velké h_{ii} indikuje, že i -té pozorování má velký vliv a velká rezidua naznačují možnou neadekvátnost modelu
- míry, které zavedeme, budou kombinovat tyto dva faktory
- přístup z PRESS reziduí, tzn. jak velký vliv má vynechání i -tého pozorování na $\hat{\beta}$ a $\hat{\mathbf{y}}$

DFBETAS:

vliv vynechání i -tého pozorování na odhad $\hat{\beta}$ měří rozdíl

$$\hat{\beta} - \hat{\beta}_{(-i)} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i \frac{\hat{e}_i}{1 - h_{ii}},$$

bude tedy základem pro naši analýzu

a) vliv i -tého pozorování na $\hat{\beta}_j$:

- $\hat{\beta}_j - \hat{\beta}_{(-i)j} = \frac{r_{ji} \hat{e}_i}{1 - h_{ii}}$, kde r_{ji} je (j, i) -tý prvek matice $\mathbf{R} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$
- i -té pozorování budeme považovat za **influenční** na β_j , pokud $\hat{\beta}_j - \hat{\beta}_{(-i)j}$ bude velké
- protože $\hat{\beta}_j$ je náhodná veličina, „velké“ bychom měli měřit relativně vzhledem k $s.d.(\hat{\beta}_j) = \sigma \sqrt{v_j}$, kde $v_j = (\mathbf{X}^T \mathbf{X})_{jj}^{-1}$
- pokud ji odhadneme pomocí $\hat{\sigma}_{(-i)} \sqrt{v_j}$, dostaneme definici

$$\text{DFBETAS}_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{(-i)j}}{\hat{\sigma}_{(-i)} \sqrt{v_j}} = \frac{r_{ji} \hat{e}_i}{\sqrt{v_j} \hat{\sigma}_{(-i)} (1 - h_{ii})} = \frac{r_{ji}}{\sqrt{v_j}} \frac{\hat{t}_i}{\sqrt{1 - h_{ii}}},$$

kde $\hat{t}_i$ je (ext.) studentizované reziduum

- kombinuje efekt velkého rezidua $\hat{t}_i$ a velkého h_{ii}
- jedna možnost pro limitní hodnoty: i -té pozorování je považováno za **influenční** na odhad β_j , pokud

$$|\text{DFBETAS}_{j,i}| > \frac{2}{\sqrt{n}}$$

- máme $(m + 1) \times n$ hodnot pro srovnání, zjednodušíme

b) vliv i -tého pozorování na celý vektor $\hat{\beta}$:

- použití nějaké normy na vektor $\hat{\beta} - \hat{\beta}_{(-i)}$
- Cook navrhl

$$D_i = \frac{(\hat{\beta} - \hat{\beta}_{(-i)})^T \mathbf{M} (\hat{\beta} - \hat{\beta}_{(-i)})}{(m+1)c},$$

kde $\mathbf{M}$ je PD matice a c normalizační konstanta

- nejužívanější volba je $\mathbf{M} = \mathbf{X}^T \mathbf{X}$ a $c = s_n^2$
- **Cookova vzdálenost:**

$$D_i = \frac{(\hat{\beta} - \hat{\beta}_{(-i)})^T \mathbf{X}^T \mathbf{X} (\hat{\beta} - \hat{\beta}_{(-i)})}{(m+1)s_n^2}$$

- dosazením dostaneme

$$D_i = \frac{1}{(m+1)s_n^2} \left(\frac{\hat{e}_i}{1 - h_{ii}} \right)^2 \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_i = \frac{1}{m+1} \frac{h_{ii}}{1 - h_{ii}} \frac{\hat{e}_i^2}{s_n^2 (1 - h_{ii})}$$

- výpočetní tvar potom je

$$D_i = \frac{\hat{r}_i^2}{m+1} \left(\frac{h_{ii}}{1 - h_{ii}} \right) \quad (\hat{r}_i \text{ jsou interně studentizovaná (standardizovaná) rezidua})$$

POZNÁMKA 4.8

- $100(1 - \alpha)\%$ simultánní IS pro β je:

$$C(\alpha) = \left\{ \beta \mid \frac{(\hat{\beta} - \beta)^T \mathbf{X}^T \mathbf{X} (\hat{\beta} - \beta)}{(m+1)s_n^2} \leq F_{1-\alpha}(m+1, n-m-1) \right\}$$

- tzn. $\hat{\beta}_{(-i)} \in C(\alpha) \Leftrightarrow D_i \leq F_{1-\alpha}(m+1, n-m-1)$
- to je motivace pro **RULE OF THUMB**:

i -té pozorování je influenční, jestliže $D_i > F_{\frac{1}{2}}(m+1, n-m-1)$

(pro většinu m, n je $F_{\frac{1}{2}} \approx 1$, zjednodušení pravidla $D_i > 1$)

POZNÁMKA 4.9

Také platí, že

$$D_i = \frac{(\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(-i)})^T (\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(-i)})}{(m+1)s_n^2},$$

tzn. D_i se dá chápat jako míra influence na celkovou predikci

DFFITS: vliv i -tého pozorování na $\hat{y}_i$

$$\text{DFFITS}_i = \frac{\hat{y}_i - \hat{y}_{(-i)}}{\hat{\sigma}_{(-i)}\sqrt{h_{ii}}} = \dots = \hat{t}_i \sqrt{\frac{h_{ii}}{1 - h_{ii}}}$$

RULE OF THUMB: i -té pozorování je influenční, pokud $|\text{DFFITS}_i| > 3\sqrt{\frac{m+1}{n-m-1}}$

POZNÁMKA 4.10 (Míry influence v )

- DFBETAS - `dfbetas()`, DFFITS - `dffits()`,
- Cookova vzdálenost D_i - `cooks.distance()`, potenciál h_{ii} - `hatvalues()`
- vše shrnuje funkce `influence.measures()`
- používaná pravidla: i -té pozorování je označeno za influenční, pokud

$$|\text{DFBETAS}_{j,i}| > 1, \quad |\text{DFFITS}_i| > 3\sqrt{\frac{m+1}{n-m-1}}, \quad D_i > F_{\frac{1}{2}}(m+1, n-m-1), \quad h_{ii} > 3\frac{m+1}{n}.$$

4.4 Transformace

- pokud není splněn některý z předpokladů modelu - **linearita, normalita chyb, homoskedasticita**
- jednou z možností je pokusit se transformovat proměnné, aby transformovaný model předpoklady alespoň „přibližně“ splňoval

A) Transformace vysvětlované proměnné y

hledáme funkci $h(\cdot)$ tak, aby model $Y_i^* = h(Y_i) = \beta_0 + \sum_{j=1}^m x_{ij}\beta_j + e_j$ předpoklady splňoval

3 hlavní důvody pro transformaci y :

1) transformace škály měření tak, aby pokrývala celé **R**

(což může odstranit problémy spodmínkami na β)

- např. studie kapacity plic (FEV data, $FEV > 0$), chtěli bychom, aby model nepredikoval záporné hodnoty
- lze obejít modelováním $y^* = \ln FEV$
- pokud y jsou počty a 0 je možná hodnota, často se používá $y^* = \ln(y + 1)$ nebo obecně $y^* = \ln(y + c)$

2) transformace Y , aby její rozdělení bylo „více“ normální

- typicky se snažíme udělat rozdělení hodnot y více symetrické
- často se setkáváme s rozděleními vychýlenými vpravo
- transformace $y^* = \ln y$ nebo $y^* = y^\lambda$, $\lambda < 1$ budou redukovat toto vychýlení
- **typický postup:** začít s hodnotou $\lambda \approx 1$ a pak snižovat, dokud není dosaženo „přibližné“ symetrie reziduí

3) možná nejzásadnější motivace: pokusit se dosáhnout konstantní rozptyl

- např. pro fyzikální veličinu s kladnými hodnotami se často stane, že rozptyl bude malý pro $\mu \approx 0$ a větší pro μ velké (tzv. **positive mean-variance relationship**)
- nepřesnost měření kladných veličin se často vyjadřuje pomocí koeficientu variace $CV(Y) = \frac{s.d.Y}{EY}$
- bývá více konstantní než s.d. (variabilitu vyjadřujeme relativně)
- matematicky to znamená, že $\text{Var}Y = \varphi(EY)^2 = \varphi\mu^2$ pro nějaké φ
- pro odstranění vztahu mezi EY a $\text{Var}Y$ se často používají transformace $y^* = y^\lambda$ (pro $y > 0$)

Transformace:	$\longleftarrow$	$\cdots$	y^3	y^2	y	$\sqrt{y}$	$\ln y$	$\frac{1}{\sqrt{y}}$	$\frac{1}{y}$	$\frac{1}{y^2}$	$\cdots$	$\longrightarrow$
Box-Cox λ :			3	2	1	$\frac{1}{2}$	0	$-\frac{1}{2}$	-1	-2		

• pokud $\text{Var} Y$ klesá

• pokud $\text{Var} Y$ roste s rostoucí EY

s rostoucí EY

OBECNĚ: předpokládejme vztah $\text{Var} Y = \varphi V(\mu)$ a uvažujme transformaci $y^* = h(y)$

Taylorův rozvoj 1. řádu funkce $h(y)$ v bodě μ

$$y^* = h(y) \approx h(\mu) + h'(\mu)(y - \mu)$$

z čehož plyne, že $\text{Var} Y^* \approx (h'(\mu))^2 \cdot \text{Var} Y$

transformace $y^* = h(y)$ bude přibližně stabilizovat rozptyl, pokud $h'(\mu)$ je úměrné $(\text{Var} Y)^{-\frac{1}{2}} = V^{-\frac{1}{2}}(\mu)$

• pokud $V(\mu) = \mu^2 \Rightarrow$ transformace stabilizující rozptyl je $h(y) = \ln y$ ($h'(\mu) = \frac{1}{\mu}$)

• pokud $V(\mu) = \mu \Rightarrow$ transformace stabilizující rozptyl je $h(y) = \sqrt{y}$ ($h'(\mu) = \frac{1}{2\sqrt{\mu}}$)

- asi nejvíce užívanou transformací je $y^* = \ln y$ (dobrá interpretovatelnost parametrů β)

POZNÁMKA 4.11 (Interpretace parametrů lineárního modelu)

a) **klasický LM:** $EY = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$

jednotková změna proměnné $x_j \Rightarrow$ změnu EY o β_j jednotek
(při ostatních proměnných stejných)

b) **LM pro $\ln Y$:** $\ln Y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + e, \quad e \sim N(0, \sigma^2)$

- pokud je to správný model, $\ln Y \sim N(\mu, \sigma^2) \Rightarrow Y \sim LN(\mu, \sigma^2)$ a $EY = e^{\mu + \frac{\sigma^2}{2}}$

predikce pro $E \ln Y$ je $\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m$

predikce pro EY je $e^{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m + \frac{\sigma^2}{2}}$

- uvažujme opět jednotkovou změnu proměnné x_j ($x_j \rightarrow x_j + 1$)

$$\frac{EY_{\text{new}}}{EY} = \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j x_j + \beta_j + \dots + \beta_m x_m + \frac{\sigma^2}{2}}}{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \frac{\sigma^2}{2}}} = e^{\beta_j}$$

jednotková změna proměnné $x_j \Rightarrow$ multiplikativní změnu EY e^{β_j} -krát

jinak zapsáno: $100(e^{\beta_j} - 1)$ je procentní změna EY spojená s jednotkovou změnou x_j

Box-Cox transformace

- pokud chyby nemají normální rozdělení, hledáme transformaci Y , která by nejenom linearizovala model, ale také transformovala chyby, aby byly přibližně normální
- užitečná třída transformací (**power family**)

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \text{pokud } \lambda \neq 0 \\ \ln y, & \text{pokud } \lambda = 0 \end{cases}, \quad \left(\lim_{\lambda \rightarrow 0} \frac{y^\lambda - 1}{\lambda} = \ln y \right)$$

která předpokládá, že data y jsou kladná

- pro nalezení vhodného λ budeme předpokládat, že transformované veličiny $Y_i^{(\lambda)}$, $i = 1, \dots, n$, splňují podmínky RM, tj.

$$Y_i^{(\lambda)} = \mathbf{x}_i^T \boldsymbol{\beta} + \mathbf{e} \quad \text{kde} \quad \mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad (Y_i^{(\lambda)} \sim N(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma^2), Y_i^{(\lambda)} \text{ nezávislé})$$

- úkol je odhadnout zároveň $\lambda, \boldsymbol{\beta}, \sigma^2$, použijeme MLE

Dostali jsme tedy tzv. **profile log - likelihood**

$$\ell_p^{(\lambda)} = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) - \frac{n}{2} + \ln J(\lambda) = C - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) + (\lambda - 1) \sum_{i=1}^n \ln y_i,$$

kde

$$\hat{\beta}(\lambda) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}^{(\lambda)}, \quad \hat{\sigma}^2(\lambda) = \frac{1}{n} \sum_{i=1}^n (y_i^{(\lambda)} - \hat{y}_i^{(\lambda)})^2,$$

a

$$\mathbf{y}^{(\lambda)} = (y_1^{(\lambda)}, \dots, y_n^{(\lambda)})^T, \quad \hat{y}_i^{(\lambda)} = \mathbf{x}_i^T \hat{\beta}^{(\lambda)}.$$

POZNÁMKA:

- kvůli komplikované závislosti $\ell_p^{(\lambda)}$ na λ bude třeba numerická metoda pro maximalizaci
- lze přepsat do tvaru, kde bude možné využít metody LR

Celkem: $\max_{\lambda} \ell_p(\lambda) \iff \min_{\lambda} s_{\lambda}^2,$

kde

$$s_{\lambda}^2 = \frac{\hat{\sigma}^2(\lambda)}{[(\dot{y})^{\lambda-1}]^2} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} - \frac{\hat{y}_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} \right)^2,$$

tzn. s_{λ}^2 je reziduální součet čtverců (SSE/n) v modelu $\frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}}$ v závislosti na $\mathbf{x}_i^T$
(tzn. s_{λ}^2 lze snadno získat pomocí funkce `lm()`)

Algoritmus:

- 1) zvolit oblast hodnot λ , $I = \langle \lambda_{min}, \lambda_{max} \rangle$, a body $\lambda \in I$
(typicky $I = \langle -2, 2 \rangle$ a 10-20 rovnoměrně rozdělených bodů)
- 2) naladit model $\frac{y^{(\lambda)}}{(\dot{y})^{\lambda-1}} \sim x$ a spočítat $\frac{1}{n} SSE = s_{\lambda}^2$.
- 3) z grafu (λ, s_{λ}^2) vybrat $\hat{\lambda}$, které minimalizuje s_{λ}^2
- 4) pro zvolené $\hat{\lambda}$ naladit model $y^{(\hat{\lambda})} \sim x$ a pokračovat standardní analýzou

Intervaly spolehlivosti pro λ :

- snadno lze odvodit LRT test pro test $H_0 : \lambda = \lambda_0$
($H_0 : \lambda = 1$ zda je třeba transformace, pokud zamítneme $H_0 \Rightarrow$ transformace pomocí $\hat{\lambda}$)
- LRT statistika: $\Lambda = -2 \ln \frac{L(\lambda_0)}{L(\hat{\lambda})} = 2(\ell_p(\hat{\lambda}) - \ell_p(\lambda_0))$, víme že $\Lambda \xrightarrow{L} \chi^2(1)$
- invertováním přípustné oblasti LRT testu, dostaneme **as. $100(1 - \alpha)\%$ IS pro λ**

$$\left\{ \lambda \in \mathbb{R} \mid n \cdot \ln \frac{s_{\hat{\lambda}}^2}{s_{\lambda}^2} \leq \chi_{1-\alpha}^2(1) \right\}, \quad \text{kde } \hat{\lambda} \text{ je MLE } \lambda$$



POZNÁMKA 4.12

Kvůli jednoduchosti interpretace se často doporučuje zaokrouhlit $\hat{\lambda}$ na nejbližší $\frac{1}{4}$ nebo $\frac{1}{3}$.

PŘÍKLAD 4.4 (Data TREES)

	Girth	Height	Volume
1	8	70	10
2	9	65	10
3	9	63	10
4	10	72	16
⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮

```
mod <- lm(Volume ~ Girth + Height)
summary(mod)
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -57.9877      8.6382  -6.713 2.75e-07 ***
## Girth         4.7082      0.2643  17.816 < 2e-16 ***
## Height        0.3393      0.1302   2.607  0.0145 *
## ---
## Residual standard error: 3.882 on 28 degrees of freedom
## Multiple R-squared:  0.948,    Adjusted R-squared:  0.9442
## F-statistic: 255 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat <- predict(mod)
st.res <- rstudent(mod)
plot(y.hat, st.res, pch = c(1), col = c("red"), lwd=2)
```



```
bc<- boxcox(mod, lambda = seq(-2,2,1/10))
```

```
lambda.hat <- bc$x[which.max(bc$y)]; lambda.hat
## 0.3030303
```

```
Vol.lambda <- (Volume^lambda.hat-1)/lambda.hat
```


```
mod.t <- lm(Vol.lambda ~ Girth + Height)
summary(mod.t)
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.733542    0.500080  -5.466 7.77e-06 ***
## Girth        0.409448    0.015299  26.764 < 2e-16 ***
## Height       0.039685    0.007535   5.267 1.34e-05 ***
## ---
## Residual standard error: 0.2247 on 28 degrees of freedom
## Multiple R-squared: 0.9775, Adjusted R-squared: 0.9759
## F-statistic: 609.6 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat.t <- predict(mod.t)
st.res.t <- rstudent(mod.t)

plot(y.hat.t, st.res.t, pch = c(1), col = c("red"), lwd=2)
```



B) Transformace vysvětlujících proměnných $\mathbf{x}$

- pokud diagnostika modelu naznačuje, že vztah mezi $\mathbf{y}$ a $\mathbf{X}$ není lineární pro jeden nebo více regresorů, může být vhodné přeformulovat model pomocí transformací proměnných $\mathbf{x}$
- předpokládejme, že v modelu $Y = \beta_0 + \sum_{j=1}^m \beta_j x_j + e$ máme podezření na nelinearitu v j -té proměnné x_j
- jednou z možností jak postupovat je nahrazení x_j proměnnou $z_j = f(x_j)$, model tedy bude

$$Y = \beta_0 + \beta_1 x_1 + \cdots + \beta_j z_j + \cdots + \beta_m x_m + e$$

- pokud je f známé, jedná se o model LR a lze ho analyzovat standardně, pokud je tato transformace vhodná, mělo by se to projevit ve zlepšení statistik R^2 , t , F a zlepšení grafu reziduí pro z_j oproti těm pro x_j
- bohužel f většinou známá není, možný přístup je parametrizovat nějak tuto funkci a pak odhadnout tyto parametry společně s β
 - **typická parametrizace:** $z_j = x_j^\lambda$, kde $\lambda \in \mathbb{R}$ vhodné
 - aproximace f pomocí polynomu vhodného stupně, tzn. $z_j = \sum_{k=1}^l r_k x_j^k$, kde r_k musí být odhadnuty
 - další možností je použití trigonometrických funkcí nebo splines (piecewise polynomials)

Zaměříme se na $z_j = x_j^\lambda$:

- možnost je opět zvolit jistou množinu hodnot λ , naladit modely pro všechna λ a vybrat model s nejlepší shodou s daty, např. s nejmenší SSE nebo největší R^2 nebo F
- může být časově náročné, můžeme minout vhodnou hodnotu λ , pokud nebyla v původní množině (nevíme jak R^2, F, SSE závisí na λ)

Box-Tidwell metoda

- předpokládejme, že λ se příliš neliší od $\lambda = 1$, Taylorův rozvoj 1. řádu kolem $\lambda = 1$ dává

$$x^\lambda \approx x^1 + (\lambda - 1) \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1}, \quad \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1} = x^\lambda \ln x \Big|_{\lambda=1} = x \ln x, \quad \text{tedy} \quad x^\lambda \approx x + (\lambda - 1)x \ln x$$

- dosazením do modelu

$$\begin{aligned} Y &= \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j (x_j + (\lambda - 1)x_j \ln x_j) + \dots + \beta_m x_m + e \\ &= \beta_0 + \sum_{k=1}^m \beta_k x_k + \underbrace{\beta_j (\lambda - 1)}_{\beta_{m+1}(\lambda)} x_j \ln x_j + e \end{aligned}$$

- máme lineární model pro parametry β_k , $0 \leq k \leq m+1$, protože $\beta_{m+1} = (\lambda - 1)\beta_j$, můžeme (λ, β_j) odhadnout následovně

- 1) naladíme původní model a spočteme $LSE \hat{\beta}_j$ parametru β_j
- 2) naladíme rozšířený model s $x_{m+1} = x_j \ln x_j$ a spočteme $\hat{\beta}_{m+1}$
- 3) z rovnosti $\hat{\beta}_{m+1} = (\hat{\lambda} - 1)\hat{\beta}_j$ dostaneme $\hat{\lambda} = \frac{\hat{\beta}_{m+1}}{\hat{\beta}_j} + 1$
 - tento postup umožňuje testovat potřebu transformace $H_0 : \lambda = 1 \quad \times \quad H_1 : \lambda \neq 1$
pomocí t-testu pro $H_0 : \beta_{m+1} = 0$

POZNÁMKA 4.13

- pokud model s $\hat{\lambda}$ vypadá neadekvátně, lze postupovat iterativně a získat posloupnost $\hat{\lambda}(l)$, $l \geq 1$
- $\hat{\lambda}(0) = \hat{\lambda}$ a rozvineme x_j^λ kolem $\hat{\lambda}(0)$, tzn. $x_j^\lambda \approx x_j^{\hat{\lambda}(0)} + (\lambda - \hat{\lambda}(0))x_j^{\hat{\lambda}(0)} \ln x_j$
- dosazením do rovnice modelu

$$Y = \beta_0 = \sum_{\substack{k=1 \\ k \neq j}}^m \beta_k x_k + \beta_j x_j^{\hat{\lambda}(0)} + \underbrace{\beta_j (\lambda - \hat{\lambda}(0))}_{\beta_{m+1}} x_j^{\hat{\lambda}(0)} \ln x_j + e$$

- naladíme tento model s a bez přidané proměnné $x_{m+1} = x_j^{\hat{\lambda}(0)} \ln x_j$, označíme $\hat{\beta}_j(1)$ a $\hat{\beta}_{m+1}(1)$ příslušné odhady

- potom

$$\hat{\lambda}(1) = \hat{\lambda}(0) + \frac{\hat{\beta}_{m+1}(1)}{\hat{\beta}_j(1)}$$

- můžeme dále iterovat do konvergence nebo skončit po pevném počtu iterací

POZNÁMKA 4.14 (Další užívané transformace v $\mathbf{x}$, $\mathbf{y}$)

a) centrované proměnné: $\mathbf{X}_C$ a $\mathbf{y}_C$

$$(\mathbf{X}_C)_{ij} = x_{ij} - \bar{x}_j, \quad i \in \hat{n}, \quad j \in \hat{m}, \quad \text{kde } \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad (\mathbf{y}_C)_i = y_i - \bar{y}$$

$$1) \hat{\beta}_1, \dots, \hat{\beta}_m \text{ je řešením } \mathbf{X}_C^T \mathbf{X}_C \boldsymbol{\beta} = \mathbf{X}_C^T \mathbf{y}_C, \quad 2) \hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \hat{\beta}_j \bar{x}_j$$

b) centrované a škálované proměnné $\mathbf{X}_{SC}$ a $\mathbf{y}_C$ ($\mathbf{y}_{SC}$):

škálování sloupců tak, aby jejich norma byla 1,

tzn. každý prvek j -tého sloupce matice $\mathbf{X}$ podělíme $s_j = \left(\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \right)^{\frac{1}{2}}$

centrovaná a škálovaná matice $\mathbf{X}_{SC}$ pak bude $\mathbf{X}_{SC} = \mathbf{X}_C \mathbf{S}$, $\mathbf{S} = \text{diag}\left(\frac{1}{s_1}, \dots, \frac{1}{s_m}\right)$

model bude $\mathbf{Y}_C = \mathbf{X}_{SC} \boldsymbol{\beta}_s + \mathbf{e}$

(lze použít i $\mathbf{Y}_{SC}$, tedy centrované a škálované $\mathbf{Y}$)

4.5 Vážené nejmenší čtverce (weighted least squares - WLS)

- budeme předpokládat, že chyby e_i jsou normální, nezávislé, ale $\text{Var}(e_i) = \sigma_i^2$ závisí na i
- konkrétně $\sigma_i^2 = \frac{\sigma^2}{w_i}$, kde $w_i > 0$, $i \in \hat{n}$, se nazývají **váhy**
- uvažujeme tedy model

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \text{kde} \quad \mathbf{e} \sim N_n(0, \sigma^2 \mathbf{W}) \quad \text{a} \quad \mathbf{W} = \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right) \quad (4.2)$$

- pokud jsou váhy w_i známé, lze MLE odhady parametru $\boldsymbol{\beta}$ a σ^2 nalézt následovně

$$\mathbf{W} = \mathbf{K}\mathbf{K}^T, \quad \text{kde} \quad \mathbf{K} = \mathbf{W}^{\frac{1}{2}} = \text{diag}\left(\frac{1}{\sqrt{w_1}}, \dots, \frac{1}{\sqrt{w_n}}\right)$$

- definujeme $\mathbf{Z} = \mathbf{K}^{-1}\mathbf{Y}$, $\mathbf{M} = \mathbf{K}^{-1}\mathbf{X}$ a $\boldsymbol{\varepsilon} = \mathbf{K}^{-1}\mathbf{e}$
- dostaneme model

$$\mathbf{Z} = \mathbf{M}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \text{kde} \quad \boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{I}_n), \quad (4.3)$$

$$(\text{protože } \text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{K}^{-1}\sigma^2\mathbf{W}(\mathbf{K}^{-1})^T = \sigma^2\mathbf{K}^{-1}\mathbf{K}\mathbf{K}^T(\mathbf{K}^T)^{-1} = \sigma^2\mathbf{I}_n)$$

- to už je standardní model LR, ve kterém platí

$$\begin{aligned}\hat{\beta}_w &= (\mathbf{M}^T \mathbf{M})^{-1} \mathbf{M}^T \mathbf{z} = (\mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{y} \\ &= (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{y}\end{aligned}$$

$$\hat{\sigma}_w^2 = \frac{1}{n} \sum_{i=1}^n (z_i - \hat{z}_i)^2 = \frac{1}{n} \sum_{i=1}^n w_i (y_i - \hat{y}_i)^2 = \frac{1}{n} SSE_w,$$

kde SSE_w je vážený součet čtverců, $z_i = \sqrt{w_i} y_i$ a $\hat{z}_i = \sqrt{w_i} \mathbf{x}_i^T \hat{\beta}_w = \sqrt{w_i} \hat{y}_i$

- dále platí

a) $E\hat{\beta}_w = (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} E\mathbf{Y} = \beta$, tzn. $\hat{\beta}_w$ je nestranný odhad β

b) $E\left(\frac{SSE_w}{n-m-1}\right) = \sigma^2$, tedy $s_w^2 = \frac{SSE_w}{n-m-1}$ je nestranný odhad σ^2

VĚTA 4.4

Nechť $\hat{\beta}_w$ je WLS odhad β , jestliže $\text{Cov}(\mathbf{e}) = \sigma^2 \mathbf{W} = \sigma^2 \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right)$. Potom platí:

- 1) $\text{Cov}(\hat{\beta}_w) = \sigma^2 (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$
- 2) nechť δ_i je i -tý diagonální prvek $(\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$, jestliže $e_i \sim N\left(0, \frac{\sigma^2}{w_i}\right)$, $i \in \hat{n}$, potom

$$T_i = \frac{\hat{\beta}_{w,i} - \beta_i}{s_w \sqrt{\delta_i}} \sim t(n - m - 1)$$

- 3) pro $\hat{\mathbf{Y}}_w = \mathbf{X} \hat{\beta}_w$ platí $E \hat{\mathbf{Y}}_w = \mathbf{X} \beta$ a $\text{Cov}(\hat{\mathbf{Y}}_w) = \sigma^2 \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T$
- 4) Nechť $\hat{\mathbf{e}}_w = \mathbf{Y} - \hat{\mathbf{Y}}_w$ jsou rezidua v modelu (4.2) a $\hat{\mathbf{e}}_w = \mathbf{Z} - \hat{\mathbf{Z}} = \mathbf{Z} - \mathbf{M} \hat{\beta}_w$ jsou rezidua v transformovaném modelu (4.3). Potom

$$\hat{\mathbf{e}}_w = \sqrt{\mathbf{W}^{-1}} \hat{\mathbf{e}}_w = \mathbf{W}^{-\frac{1}{2}} \hat{\mathbf{e}}_w \quad \text{a} \quad E(\hat{\mathbf{e}}_w) = E(\hat{\mathbf{e}}_w) = \mathbf{0}.$$

- 5) nechť $\mathbf{H}_w = \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1}$ je vážená projekční matice, potom

$$\hat{\mathbf{e}}_w = (\mathbf{I} - \mathbf{H}_w) \mathbf{e}, \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 (\mathbf{I} - \mathbf{H}_w) \mathbf{W}, \quad \text{tzn.} \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 \mathbf{W}^{-\frac{1}{2}} (\mathbf{I} - \mathbf{H}_w) \mathbf{W}^{\frac{1}{2}}$$

Důkaz.

- odhady parametrů β a σ^2 lze získat použitím transformovaného modelu (4.3)
- protože ale transformovaný model neobsahuje intercept (první sloupec $\mathbf{M}$ je $(\sqrt{w_1}, \dots, \sqrt{w_n})^T$), nefunguje klasický rozklad součtu čtverců a F a R^2 statistiku nelze definovat obvyklým způsobem (viz. regrese skrz počátek)
- nicméně princip „extra sum of squares“ funguje, ať má model intercept nebo ne
 - např. celkový F -test lze provést pomocí statistiky

$$F_w = \frac{\frac{SSE_R - SSE_F}{m}}{s_w^2},$$

kde SSE_F je reziduální součet čtverců s_w^2 plného modelu a SSE_R je reziduální součet čtverců redukovaného transformovaného modelu $\mathbf{Z} = \mathbf{M}_0\beta_0 + \mathbf{e}$, $\mathbf{M}_0 = (\sqrt{w_1}, \dots, \sqrt{w_n})^T$

- pokud mají chyby normální rozdělení, platí za $H_0 : \beta_1 = \dots = \beta_m = 0$, že $F_w \sim F(m, n - m - 1)$ a H_0 zamítáme, pokud $F_w > F_{1-\alpha}(m, n - m - 1)$
- přirozené je definovat $R^2 = \varrho^2(\hat{\mathbf{z}}, \mathbf{z})$, kde $\varrho(\hat{\mathbf{z}}, \mathbf{z})$ je výběrový korelační koeficient (pro $\mathbf{W} = \mathbf{I}$ dostaneme standardní R^2)

Pro analýzu reziduí je třeba uvažovat vhodné grafy reziduí:

- máme dva vektory reziduí:

$$\hat{e}_i \text{ v původním modelu (4.2)} \quad \hat{\varepsilon}_i \text{ v transformovaném modelu (4.3)}$$

a tedy dvě možnosti

- pro kontrolu konstantního rozptylu lze uvažovat i standardizovaná nebo studentizovaná rezidua (pomocí bodu 4) a 5) věty lze ukázat, že jsou v obou modelech stejná)
- je třeba být opatrný oproti jakým hodnotám budeme rezidua zobrazovat
- grafy $\hat{e}_i$ proti sloupcům $\mathbf{M}$ a predikovaným hodnotám $\hat{\mathbf{z}}$ jsou OK, neboť např.

$$\sum_{i=1}^n \hat{z}_i \hat{e}_i = 0$$

(jsou OG, měl by být vidět roztýlený oblak kolem osy x)

- dosazením $\hat{e}_i = \sqrt{w_i} \cdot \hat{e}_i$ a $\hat{z}_i = \sqrt{w_i} \cdot \hat{y}_i$ dostaneme $\sum_{i=1}^n w_i \hat{e}_i \hat{y}_i = 0$, tzn. graf $\hat{e}_i$ proti $\hat{y}_i$ bude zavádějící
- graf $\sqrt{w_i} \cdot \hat{e}_i$ proti $\sqrt{w_i} \cdot \hat{y}_i$ je ale v pořádku
- podobné závěry platí i pro grafy $\hat{e}_i$ proti $\mathbf{x}_j^c$, $j = 1, \dots, m$

POZNÁMKA 4.15

- pokud jsou váhy neznámé, bylo by třeba je odhadnout společně s β a σ^2 z dat
- to ale není obecně možné, protože máme více parametrů než dat
- někdy to možné je, pokud máme další informace o rozdělení chyb (tvar kovarianční matice atd.)

POZNÁMKA 4.16

- celý postup WLS lze použít i na případ $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{W})$, kde $\mathbf{W}$ je známá, ale není diagonální
- protože $\mathbf{W}$ je PD, ex. regulární $\mathbf{K}$ tak, že $\mathbf{W} = \mathbf{K}\mathbf{K}^T$
- stejná transformace jako u WLS opět vede na transformovaný model, kde $\varepsilon \sim N_m(\mathbf{0}, \sigma^2 \mathbf{I}_m)$

4.5 Korelované chyby

- zejména v časových nebo ekonomických datech se často objevuje korelace jednotlivých hodnot
- potom není splněn předpoklad nezávislosti chyb
- tento stav je třeba detekovat (někdy pomohou grafy reziduí)
- modely pro korelovaná data: **Analýza časových řad**

Pokud je přítomna autokorelace a chyby mají konstantní rozptyl, platí:

- 1) OLS odhad $\hat{\beta}$ je nestranný, ale neplatí Gauss-Markovova věta, tzn. $\hat{\beta}$ nemá nejmenší rozptyl
- 2) $MSE = \frac{1}{n-m-1}SSE$ (odhad σ^2) může být podstatně menší než skutečná hodnota σ^2
- 3) v důsledku bodu 2) mohou být zvětšeny hodnoty t -statistik, takže t -testy a IS nefungují
- 4) protože jsou chyby závislé, F -testy a t -testy nejsou přesně platné ani když jsou chyby normální

Durbin-Watson statistika

- omezíme se na pozorování získaná v čase $t = 1, 2, \dots, n$
- a případ, že chyby e_t splňují podmínky **autoregresního procesu 1. řádu** (AR1), tj.

$$e_t = \varrho e_{t-1} + u_t, \quad |\varrho| < 1,$$

kde ϱ je **autokorelační koeficient**, $u_t \sim N(0, \sigma_u^2)$ jsou nezávislé, $t = 1, \dots, n$,
a u_t je nezávislé na e_t , $t \geq 1$

- pro test $H_0 : \varrho = 0 \quad \times \quad H_1 : \varrho > 0$ se užívá **Durbinova-Watsonova statistika**

$$d = \frac{\sum_{t=2}^n (\hat{e}_t - \hat{e}_{t-1})^2}{\sum_{t=1}^n \hat{e}_t^2}, \quad \text{kde } \hat{e}_t \text{ jsou rezidua modelu LR}$$

- pokud zamítneme H_0 , odhadne se ϱ pomocí

$$\hat{\varrho} = \frac{\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1}}{\sum_{t=2}^n \hat{e}_t^2}$$

POZNÁMKA: Dá se ukázat, že $d \approx 2(1 - \hat{\varrho})$:

- kritické hodnoty určené Durbinem a Watsonem jsou tabelované

Test: ($H_0 : \rho = 0 \quad \times \quad H_1 : \rho > 0$)

- 1) spočítat hodnotu d
- 2) nalézt kritické hodnoty (d_L, d_U) pro dané n a $m + 1$
- 3)
 - a) zamítnout H_0 , pokud $d < d_L$
 - b) nezamítnout H_0 , pokud $d > d_U$
 - c) pro $d_L < d < d_U$ test nerozhodne

POZNÁMKA 4.17

- pro test $H_0 : \rho = 0 \quad \times \quad H_1 : \rho < 0$ lze použít popsany test pro $d' = 4 - d$
- metody pro korekci autokorelace: **Cochrane-Orcutt**

5. Výběr regresního modelu

- budeme se zabývat výběrem nejvhodnější množiny regresorů
- špatná specifikace modelu (použití jiného než skutečného modelu) má **dva hlavní důsledky**:
 - 1) při vynechání některých proměnných modelu, jsou odhady parametrů ostatních proměnných vychýlené
 - 2) pokud jsou v modelu nějaké proměnné navíc, jsou obecně rozptýly odhadů parametrů pro ostatní proměnné velké
- volba „nejlepšího“ modelu je hledání kompromisu mezi
 - a) **přesností modelu**
 - b) **jednoduchostí modelu** (parsimony)
- „ideální model“ by měl mít nejmenší možný počet regresorů, který umožňuje adekvátní interpretaci (nebo predikci)
- obvykle neexistuje jednoznačný nejlepší model
- ani jednoznačná statistická procedura, jak ho najít

POZNÁMKA 5.1

Důsledky vynechání proměnných ze skutečného, i když neznámého, modelu:

5.1 Kritéria pro porovnávání modelů

- předpokládejme, že máme k dispozici T proměnných (regresorů) včetně interceptu
- uvažujme podmnožinu p proměnných (včetně interceptu)

A) koeficient vícenásobné determinace R^2

$$R_p^2 = \frac{SSR_p}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{SSE_p}{SST}$$

- při použití je třeba si uvědomit, že R_p^2 je rostoucí funkcí p
- maxima tedy nabývá pro $p = T$
- hledáme model, ve kterém přidání dalšího regresoru už nezpůsobí podstatný nárůst R_p^2
- často se používá upravený koeficient determinace

$$\bar{R}_p^2 = 1 - \frac{\frac{SSE_p}{n-p}}{\frac{SST}{n-1}}$$

B) $(R)MSE$

$$MSE_p = \frac{SSE_p}{n-p} = s_n^2, \quad RMSE_p = s_n$$

- hledáme model s minimální hodnotou s_n^2

C) F -test pro vnořené modely

pro $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)$ a $\beta = (\beta_1^T, \beta_2^T)^T$ umíme otestovat $H_0 : \beta_2 = 0$ pomocí F -testu

-  **R**:

`anova(mod1, mod2)` - pozor na vnořenost modelů

`anova(mod)` - záleží na pořadí v jakém přidáváme proměnné do modelu

D) Mallows C_p , AIC , BIC

- kritéria beroucí více v potaz počet použitých regresorů
- lze je použít i pro **nevnořené modely**

- Mallows C_p

$$C_p = \frac{SSE_p}{\hat{\sigma}^2} - n + 2p, \quad \hat{\sigma}^2 = \frac{SSE_T}{n - T}$$

Vlastnosti C_p :

- 1) snadno se počítá, SSE_p a $\hat{\sigma}^2$ jsou implementované
- 2) pokud je $\hat{\sigma}^2$ konzistentní odhad σ^2 (nezávisající na p), má C_p následující interpretaci:
 - porovnává, co zbývá vysvětlit pomocí modelů s p a T parametry
 - zvýhodňuje počet dostupných dat
 - penalizuje počet parametrů, které je třeba odhadnout
- 3) při zvyšování počtu regresorů: $\hat{\sigma}^2$ je konst., SSE_p klesá, p roste
- 4) $C_T = T$
- 5) pokud je správný model s p parametry, dá se ukázat, že $C_p \approx p$ pro $n \gg T$
- 6) v praxi se volí model s nejmenším C_p ve skupině modelů splňujících $C_p \approx p$

POZNÁMKA 5.2

Nevýhoda: pro dobrou interpretaci je třeba spočítat C_p pro všechny nebo většinu podmnožin regresorů.

- Akaikeho informační kritérium AIC

- obecná definice je

$$AIC = -2\ell(\hat{\theta}) + 2p^*,$$

- $\hat{\theta}$ je MLE odhad parametru θ v modelu

- ℓ je logaritmus věrohodnostní funkce

- p^* je počet parametrů, které je třeba odhadnout $(p^* = p + 1, \text{ počítáme i } \sigma^2)$

Pro náš model LR:

- odvodili jsme

$$AIC = n \ln 2\pi + n + n \ln \frac{SSE}{n} + 2p^* \quad (\text{alt. } AIC = n \ln \frac{SSE}{n} + 2p^*)$$

- hledáme model s minimální hodnotou AIC
- AIC není mírou kvality modelu, je užitečná pro porovnávání modelů

AIC v R:

`AIC(.)` počítá $AIC = n \ln 2\pi + n + n \ln \frac{SSE}{n} + 2p^*$, kde p^* je počet parametrů β, σ^2

`extractAIC(.)` počítá $AIC = n \ln \frac{SSE}{n} + 2p$, kde p je jen počet parametrů β

- (Schwarzovo) bayesovské informační kritérium BIC

$$\text{BIC} = -2\ell(\hat{\theta}) + p^* \ln n$$

- více penalizuje počet parametrů $\implies$ vybírá jednodušší modely s jednodušší interpretací než AIC
- BIC vyžaduje významnější příspěvek proměnné, aby byla zařazena do modelu
- **R**: `BIC(.)` nebo `AIC(.)`, `extractAIC(.)` s volbou `k = log(nobs(fit))`

E) PRESS statistika

- pokud je pro nás důležitá kvalita predikce, lze použít pro srovnání modelů statistiku

$$\text{PRESS} = \sum_{i=1}^n \hat{e}_{(-i)}^2 = \sum_{i=1}^n \left(\frac{\hat{e}_i}{1 - h_{ii}} \right)^2$$

- vybírá se model s minimální hodnotou této statistiky

5.2 Metody výběru modelu

1) Vyhodnocení všech možných modelů

- pro T dostupných regresorů tzn. naladit 2^T modelů, pak je porovnat pomocí nějakého kritéria
- náročné pro velká T (například $T = 10$ znamená 1024 modelů)

2) Zpětná eliminace (backward elimination)

- začneme s plným modelem a v každém kroku odstraníme jednu proměnnou
- tu, která nejméně přispívá modelu (měřeno F stat)
- nebo jejíž odstranění znamená největší zlepšení modelu (měřeno AIC)

Algoritmus:

- 1) naladíme model se všemi proměnnými
- 2) pro každou proměnnou spočteme částečnou F statistiku (nebo t -statistiku) jako by právě byla přidána do modelu, tzn. za předpokladu, že ostatní proměnné tam už jsou
- 3) pokud je nějaká F -statistika menší, než kritická hodnota F_{out} , vynecháme z modelu proměnnou s nejnižší hodnotou F
($F_{out} = F_{1-\alpha_{out}}(1, n - p)$, kde p je aktuální počet regresorů v modelu, $\alpha_{out} = 0.05, 0.1, \dots$)
- 4) opakujeme kroky 2) a 3), dokud všechny částečné F statistiky nejsou větší, než příslušná kritická hodnota F_{out} , tzn. nelze už vyřadit žádnou proměnnou

POZNÁMKA: Místo F lze používat AIC.

3) Dopředná regrese (forward regression)

- začneme pouze s interceptem (nebo nutným minimálním modelem)
- v každém kroku přidáme jednu proměnnou, která má za následek největší zlepšení modelu (největší nárůst F nebo největší pokles AIC)
- tato metoda neumožňuje odstranit proměnnou, která už do modelu byla jednou přidána

Algoritmus:

- 1) naladíme minimální model
- 2) pro každou dostupnou proměnnou spočteme F statistiku pro test významnosti jejího přidání do modelu
- 3) pokud některá z těchto F statistik překračuje kritickou hodnotu F_{in} , přidáme do modelu proměnnou s nejvyšší hodnotou F statistiky
- 4) opakujeme kroky 2) a 3), dokud všechny F -statistiky pro zbývající proměnné nebudou menší než F_{in} nebo dokud nezbude žádná proměnná na přidání do modelu

POZNÁMKA: I když tento postup zjednodušuje výběr modelu, často bohužel vede na zařazení proměnných, které nemají významný příspěvek, jakmile jsou zařazeny další proměnné.

4) Postupná regrese (stepwise regression)

- kombinace dvou předchozích metod
- v každém kroku algoritmu přidáme jednu proměnnou a poté zkontrolujeme, zda není možné nějakou odebrat
- budeme potřebovat dvě kritické hodnoty F_{in} , F_{out} (pro použití F statistiky)

Algoritmus:

- 1) naladíme minimální model
- 2) zjistíme, zda přidání nějaké další proměnné může zlepšit model (F nebo AIC)
pokud ano, přidáme do modelu proměnnou, která má za následek největší zlepšení modelu
(největší pokles AIC)
- 3) v novém modelu zjistíme, zda nelze některou proměnnou vynechat (opět pomocí AIC nebo F)
pokud ano, vynecháme proměnnou, jejíž vyřazení má za následek největší zlepšení modelu
(největší pokles AIC)
- 4) opakujeme kroky 2) a 3) do té doby, až nebude možné přidat ani ubrat žádnou proměnnou

POZNÁMKA 5.3 (Princip marginality)

- pokud jsou v modelu vyšší mocniny nějakého regressoru, měly by tam být obsaženy i všechny jeho nižší mocniny (i když jsou případně nevýznamné)
- pokud je v modelu obsažena interakce dvou regressorů, měly by tam být i oba individuální regresory
- s každou interakcí vyššího řádu by měl model obsahovat i všechny interakce řádu nižšího
($a : b : c \rightarrow a : b, a : c, b : c$)

POZNÁMKA 5.4

Jakmile nalezneme optimální model, je třeba řádně ověřit adekvátnost.

Příklad: data cement - backward elimination

```
drop1(lm(y ~ x1 + x2 + x3 + x4), test="F")
```

```
## Model: y ~ x1 + x2 + x3 + x4
##           Df Sum of Sq    RSS      AIC F value    Pr(>F)
## <none>                47.864 26.944
## x1           1    25.9509 73.815 30.576   4.3375 0.07082 .
## x2           1     2.9725 50.836 25.728   0.4968 0.50090
## x3           1     0.1091 47.973 24.974   0.0182 0.89592
## x4           1     0.2470 48.111 25.011   0.0413 0.84407
```

```
drop1(lm(y ~ x1 + x2 + x4), test="F")
```

```
## Model: y ~ x1 + x2 + x4
##           Df Sum of Sq    RSS      AIC  F value    Pr(>F)
## <none>                47.97 24.974
## x1           1    820.91 868.88 60.629 154.0076 5.781e-07 ***
## x2           1     26.79  74.76 28.742   5.0259  0.05169 .
## x4           1      9.93  57.90 25.420   1.8633  0.20540
```

```
drop1(lm(y ~ x1 + x2), test="F")
```

```
## Model: y ~ x1 + x2
##           Df Sum of Sq    RSS      AIC  F value    Pr(>F)
## <none>                57.90 25.420
## x1           1    848.43 906.34 59.178  146.52 2.692e-07 ***
## x2           1   1207.78 1265.69 63.519  208.58 5.029e-08 ***
```

```
min.model <- lm(y ~ 1)
```

```
max.model <- lm(y ~ x1 + x2 + x3 + x4)
```

```
auto.backward <- step(max.model, direction = "backward",
                      scope = list(lower=min.model, upper=max.model))
```

```
## Start:  AIC=26.94
```

```
## y ~ x1 + x2 + x3 + x4
```

```
##           Df Sum of Sq    RSS      AIC
## - x3        1     0.1091 47.973 24.974
## - x4        1     0.2470 48.111 25.011
## - x2        1     2.9725 50.836 25.728
## <none>                47.864 26.944
## - x1        1    25.9509 73.815 30.576
```

```
## Step:  AIC=24.97
```

```
## y ~ x1 + x2 + x4
```

```
##           Df Sum of Sq    RSS      AIC
## <none>                47.97 24.974
## - x4        1      9.93  57.90 25.420
## - x2        1     26.79  74.76 28.742
## - x1        1    820.91 868.88 60.629
```

Příklad: data cement - forward selection

```
add1(min.model, max.model, test = "F")
```

```
## Model: y ~ 1
```

##		Df	Sum of Sq	RSS	AIC	F value	Pr(>F)
##	<none>			2715.76	71.444		
##	x1	1	1450.08	1265.69	63.519	12.6025	0.0045520 **
##	x2	1	1809.43	906.34	59.178	21.9606	0.0006648 ***
##	x3	1	776.36	1939.40	69.067	4.4034	0.0597623 .
##	x4	1	1831.90	883.87	58.852	22.7985	0.0005762 ***

```
add1(lm(y ~ x4), max.model, test = "F")
```

```
## Model: y ~ x4
```

##		Df	Sum of Sq	RSS	AIC	F value	Pr(>F)
##	<none>			883.87	58.852		
##	x1	1	809.10	74.76	28.742	108.2239	1.105e-06 ***
##	x2	1	14.99	868.88	60.629	0.1725	0.6867
##	x3	1	708.13	175.74	39.853	40.2946	8.375e-05 ***

```
add1(lm(y ~ x1 + x4), max.model, test = "F")
```

```
## Model: y ~ x1 + x4
```

##		Df	Sum of Sq	RSS	AIC	F value	Pr(>F)
##	<none>			74.762	28.742		
##	x2	1	26.789	47.973	24.974	5.0259	0.05169 .
##	x3	1	23.926	50.836	25.728	4.2358	0.06969 .

```
add1(lm(y ~ x1 + x2 + x4), max.model, test = "F")
```

```
## Model: y ~ x1 + x2 + x4
```

##		Df	Sum of Sq	RSS	AIC	F value	Pr(>F)
##	<none>			47.973	24.974		
##	x3	1	0.10909	47.864	26.944	0.0182	0.8959

```
auto.forward <- step(min.model, direction = "forward",  
  scope = list(lower=min.model, upper=max.model))
```

Příklad: data cement - stepwise regression

```
auto.both <- step(min.model, direction = "both",
  scope = list(lower=min.model, upper=max.model),
  k=log(nobs(max.model)))
```

```
signif(coef(auto.both), 3)
```

```
## (Intercept)          x1          x2
##      52.600      1.470      0.662
```

```
## Start:  AIC=72.01
```

```
## y ~ 1
##      Df Sum of Sq    RSS    AIC
## + x4   1   1831.90  883.87 59.982
## + x2   1   1809.43  906.34 60.308
## + x1   1   1450.08 1265.69 64.649
## + x3   1    776.36 1939.40 70.197
## <none>          2715.76 72.009
```

```
## Step:  AIC=59.98
```

```
## y ~ x4
##      Df Sum of Sq    RSS    AIC
## + x1   1    809.10   74.76 30.437
## + x3   1    708.13  175.74 41.547
## <none>          883.87 59.982
## + x2   1     14.99  868.88 62.324
## - x4   1   1831.90 2715.76 72.009
```

```
## Step:  AIC=30.44
```

```
## y ~ x4 + x1
##      Df Sum of Sq    RSS    AIC
## + x2   1     26.79   47.97 27.234
## + x3   1     23.93   50.84 27.987
## <none>          74.76 30.437
## - x1   1    809.10  883.87 59.982
## - x4   1   1190.92 1265.69 64.649
```

```
## Step:  AIC=27.23
```

```
## y ~ x4 + x1 + x2
##      Df Sum of Sq    RSS    AIC
## - x4   1      9.93   57.90 27.115
## <none>          47.97 27.234
## + x3   1      0.11   47.86 29.769
## - x2   1     26.79   74.76 30.437
## - x1   1    820.91  868.88 62.324
```

```
## Step:  AIC=27.11
```

```
## y ~ x1 + x2
##      Df Sum of Sq    RSS    AIC
## <none>          57.90 27.115
## + x4   1      9.93   47.97 27.234
## + x3   1      9.79   48.11 27.271
## - x1   1    848.43  906.34 60.308
## - x2   1   1207.78 1265.69 64.649
```

6. Kolinearita (multikolinearita)

- budeme předpokládat, že $\mathbf{X}$ má **plnou hodnost** a studovat situaci, kdy je $\mathbf{X}^T \mathbf{X}$ na pokraji singularity
- v tomto případě mluvíme o **špatně podmíněné matici $\mathbf{X}$**
- např. výpočet $(\mathbf{X}^T \mathbf{X})^{-1}$ může být problematický
- nejsou to však jediné potíže, které může špatná podmíněnost $\mathbf{X}$ způsobit
- **kolinearita**: alespoň jeden ze sloupců matice $\mathbf{X}$ je „skoro“ LK ostatních

POZNÁMKA 6.1

Jak to vyjádřit? Jedno přiblížení:

$$\exists \mathbf{c} = (c_1, \dots, c_{m+1})^T, \quad \|\mathbf{c}\| = 1, \quad \text{tak, že} \quad \sum_{i=1}^{m+1} c_i \mathbf{x}_i \approx \boldsymbol{\varepsilon}, \quad \text{kde } \|\boldsymbol{\varepsilon}\| \text{ je malá}$$

Dá se ukázat, že: kolinearita je přítomna $\iff \mathbf{X}^T \mathbf{X}$ má alespoň jedno vlastní číslo malé

Zdroje kolinearity:

- způsob sběru dat
- omezení v populaci, ze které byla data vybírána
- špatná specifikace modelu (přeurčení)

Jak kolinearitu rozpoznat?

- první nápad: determinant $\mathbf{X}^T \mathbf{X}$ blízko 0 (nevhodné!!!)
- např. poměr největšího ku nejmenšímu vlastnímu číslu $\mathbf{X}^T \mathbf{X}$ lze použít jako charakteristiku
- pokud je matice singulární, alespoň jedno vl. číslo je nulové
- matice na pokraji singularity bude mít jedno vlastní číslo výrazně menší než to největší
- $h(\mathbf{X}) = m + 1 \Rightarrow \mathbf{X}^T \mathbf{X}$ je PD a tedy vl. čísla $\lambda_i > 0, \forall i \in \widehat{m+1}$
- předpokládejme, že $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{m+1} > 0$ a položíme $s_i = \sqrt{\lambda_i}$

DEFINICE 6.1

j -tým indexem podmíněnosti matice $\mathbf{X}$ rozumíme veličinu $\eta_j = \frac{s_1}{s_j}, j = 1, \dots, m + 1$.

Index podmíněnosti matice $\mathbf{X}$ definujeme jako $\kappa(\mathbf{X}) = \eta_{m+1} = \frac{s_1}{s_{m+1}}$.

VĚTA 6.1

Nechť $\mathbf{P}\mathbf{S}\mathbf{Q}^T$ je singulární rozklad matice $\mathbf{X}$. Potom pro $j \in \widehat{m+1}$ platí

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \sum_{i=1}^{m-1} \frac{q_{ji}^2}{s_i^2},$$

kde q_{ij} je i, j -tý prvek matice $\mathbf{Q}$ a $\hat{\beta} = (\hat{\beta}_1, \dots, \hat{\beta}_{m+1})^T$ je OLS odhad parametru β v modelu (**).

Důkaz.

Lemma (singulární rozklad matice):

Nechť matice $\mathbf{A} \in \mathbb{R}^{n,m}$, $n \geq m$, má hodnotu $r \leq m$. Potom existují matice $\mathbf{P} \in \mathbb{R}^{n,m}$, $\mathbf{S} \in \mathbb{R}^{m,m}$ a $\mathbf{Q} \in \mathbb{R}^{m,m}$ takové, že platí

$$\mathbf{A} = \mathbf{P}\mathbf{S}\mathbf{Q}^T, \quad \mathbf{S} \text{ je diagonální,} \quad \mathbf{P}^T\mathbf{P} = \mathbf{I}_m, \quad \text{a} \quad \mathbf{Q}^T\mathbf{Q} = \mathbf{Q}\mathbf{Q}^T = \mathbf{I}_m.$$

Důsledky:

- pokud je alespoň jedno s_i malé, rozptyl $\hat{\beta}$ může být velký
- pokud je jedno s_i malé ve srovnání s ostatními s_j , bude mít i -tý člen sumy velkou váhu a může destabilizovat odhad

VĚTA 6.2

V modelu $\mathbf{Y} \sim (\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ platí

$$E\|\hat{\mathbf{Y}}\|^2 = \|\mathbf{X}\beta\|^2 + \sigma^2 h(\mathbf{X}).$$

Má-li $\mathbf{X}$ lineárně nezávislé sloupce, platí

$$E\|\hat{\beta}\|^2 = \|\beta\|^2 + \sigma^2 \text{tr}(\mathbf{X}^T \mathbf{X})^{-1}.$$

Důkaz.

POZNÁMKA 6.2

- $E\|\hat{\mathbf{Y}}\|^2$ závisí pouze na $h(\mathbf{X})$, nikoli na tom, jak dobře jsou sloupce $\mathbf{X}$ LN
kolinearita tu tedy nehraje významnou roli
- to neplatí pro $E\|\hat{\boldsymbol{\beta}}\|^2$, protože $E\|\hat{\boldsymbol{\beta}}\|^2 = \|\boldsymbol{\beta}\|^2 + \sum_{j=0}^m \text{Var}\hat{\beta}_j$ a $\text{Var}\hat{\beta}_j$ může být velké
- kolinearita ovlivňuje více interpretaci než predikci

POZNÁMKA 6.3

- pozor na změnu $\kappa(\mathbf{X})$ při různém škálování různých sloupců matice $\mathbf{X}$!
(např. změna jednotek jedné proměnné)
- proto se mnohdy jednotlivé regresory centrují a škálují, aby měly stejnou délku
(pokud je délka 1, bude $\mathbf{X}_{sc}^T \mathbf{X}_{sc}$ matice výběrová korelační matice původních regresorů)
- centrování není vhodné, pokud má intercept vlastní věcnou interpretaci

Příklad: data Trees

```
mod <- lm(Volume ~ Girth + Height)
summary(mod)
## Coeff:      Estimate Std. Error t value Pr(>|t|)
## (Intercept) -57.9877      8.6382  -6.713 2.75e-07 ***
## Girth        4.7082      0.2643  17.816 < 2e-16 ***
## Height       0.3393      0.1302   2.607  0.0145 *
## ---
## Residual standard error: 3.882 on 28 degrees of freedom
## Multiple R-squared:  0.948, Adjusted R-squared:  0.9442
## F-statistic:   255 on 2 and 28 DF,  p-value: < 2.2e-16

vif(mod)
##   Girth  Height
## 1.36921 1.36921

# jednotky XX palce, stopy
C <- model.matrix(mod)
kappa(C,exact = TRUE)

## 959.377

# jednotky XX cm, metry
Cm <- cbind(rep(1,31), 2.54*Girth, 0.305*Height)
kappa(Cm,exact = TRUE)

## 514.5681
```

```
mod.scale <- lm(scale(Volume) ~ scale(Girth)
                  + scale(Height))
summary(mod.scale)
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -3.813e-16  4.241e-02   0.000   1.0000
## scale(Girth)  8.988e-01  5.045e-02  17.816 <2e-16 ***
## scale(Height) 1.315e-01  5.045e-02   2.607  0.0145 *
## ---
## Residual standard error: 0.2362 on 28 degrees of freedom
## Multiple R-squared:  0.948, Adjusted R-squared:  0.9442
## F-statistic:   255 on 2 and 28 DF,  p-value: < 2.2e-16

D <- model.matrix(mod.scale)
kappa(D,exact = TRUE)

## 1.777759
```

Regrese standardizovaných veličin (regression in correlation form)

- uvažujme model s interceptem, $h(\mathbf{X}) = m + 1$ a $\mathbf{e} \sim (\mathbf{0}, \sigma^2 \mathbf{I}_n)$, tzn. pro $i = 1, \dots, n$

$$Y_i = \beta_0 + \sum_{j=1}^m x_{ij} \beta_j + e_i = \left(\beta_0 + \sum_{j=1}^m \bar{x}_j \beta_j \right) + \sum_{j=1}^m (x_{ij} - \bar{x}_j) \beta_j + e_i$$

- podělením zatím neurčeným T_0 dostaneme

$$\frac{Y_i}{T_0} = \frac{\beta_0 + \sum_{j=1}^m \bar{x}_j \beta_j}{T_0} + \sum_{j=1}^m \frac{x_{ij} - \bar{x}_j}{T_j} \frac{T_j}{T_0} \beta_j + \frac{e_i}{T_0} = \frac{\beta_0^0}{T_0} + \sum_{j=1}^m x_{ij}^* \beta_j^* + e_i^*,$$

kde

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad T_j = \sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}, \quad x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{T_j}, \quad \beta_j^* = \frac{T_j}{T_0} \beta_j, \quad \beta_0^0 = \beta_0 + \sum_{j=1}^m \bar{x}_j \beta_j \quad \text{a} \quad e_i^* = \frac{e_i}{T_0}$$

- ozn. $\mathbf{X}^* = \mathbf{X}_{sc} = (x_{ij}^*)_{n \times m}$ (sloupce $\mathbf{X}^*$ jsou OG vůči $\mathbf{1}_n$ a mají délku 1)

- normální rovnice budou

$$\begin{pmatrix} n & \mathbf{0}^T \\ \mathbf{0} & (\mathbf{X}^*)^T \mathbf{X}^* \end{pmatrix} \begin{pmatrix} \frac{\beta_0^0}{T_0} \\ \boldsymbol{\beta}^* \end{pmatrix} = \begin{pmatrix} \frac{n\bar{y}}{T_0} \\ \frac{(\mathbf{X}^*)^T \mathbf{y}}{T_0} \end{pmatrix} \quad \Rightarrow \quad \begin{aligned} \hat{\beta}_0^0 &= \bar{y} \\ \hat{\boldsymbol{\beta}}^* &= ((\mathbf{X}^*)^T \mathbf{X}^*)^{-1} (\mathbf{X}^*)^T \frac{\mathbf{y}}{T_0} \end{aligned}$$

- snadno se ukáže, že $(\mathbf{X}^*)^T \mathbf{X}^* = \mathbf{R}_{xx}$ je výběrová korelační matice původních regresorů
- pokud zvolíme $T_0 = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}$, bude vektor $(\mathbf{X}^*)^T \frac{\mathbf{y}}{T_0} = r_{xy}$ vektorem výběrových korelačních koeficientů mezi původními $\mathbf{x}_j$ a $\mathbf{y}$
- tzn. $\hat{\boldsymbol{\beta}}^* = \mathbf{R}_{xx}^{-1} r_{xy}$
- formálně lze postup chápat tak, že jsme od x_{ij}, y_i přešli k $x_{ij}^*, y_i^* = \frac{y_i - \bar{y}}{T_0}$
- model bude:

$$Y_i^* = \sum_{j=1}^m x_{ij}^* \beta_j^* + e_i^*, \quad \text{kde} \quad \beta_j^* = \frac{T_j}{T_0} \beta_j, \quad e_i^* = \frac{e_i}{T_0}$$

- odhad původních parametrů: $\hat{\beta}_j = \frac{T_0}{T_j} \hat{\beta}_j^*, \quad \hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \hat{\beta}_j \bar{x}_j$

POZNÁMKA: pro volbu $T_0 = 1$ dostaneme pouze centrované proměnné Y

POZNÁMKA 6.4

- odhady $\hat{\beta}_j^*$ se někdy nazývají **beta weights**
- mají důležitou interpretaci: **ukazují relativní vliv jednotlivých regresorů na y**
(vztahují se k regresorům vyjádřeným bezrozměrně a ve stejném měřítku)

- vztah mezi SSE^* a R^2 původního modelu (R^2 je stejná i ve stand. modelu)

$$SSE^* = \sum_{i=1}^n (\hat{e}_i^*)^2 = \sum_{i=1}^n \left(\frac{\hat{e}_i}{T_0} \right)^2 = \frac{SSE}{T_0^2} = 1 - \left(1 - \frac{SSE}{T_0^2} \right) = 1 - R^2$$

- víme $\text{Cov}(\hat{\beta}^*) = \sigma^{*2} ((\mathbf{X}^*)^T \mathbf{X}^*)^{-1} = \sigma^{*2} R_{xx}^{-1}$
- při použití odhadu σ^{*2} ve tvaru $s_n^{*2} = \frac{SSE^*}{n-m-1}$ dostaneme odhad

$$\widehat{\text{Cov}}(\hat{\beta}^*) = \frac{SSE^*}{n-m-1} R_{xx}^{-1} = \frac{1-R^2}{n-m-1} R_{xx}^{-1} \quad \text{a} \quad \widehat{\text{Var}}(\hat{\beta}_j^*) = \frac{1-R^2}{n-m-1} r_{jj},$$

kde r_{jj} je j -tý diagonální prvek R_{xx}^{-1}

- dá se ukázat, že $r_{jj} = \frac{1}{1-R_j^2}$, kde R_j^2 je koeficient determinace v modelu pro j -tý sloupec matice $\mathbf{X}$ v závislosti na ostatních
- celkem tedy

$$\widehat{\text{Var}}(\hat{\beta}_j^*) = \frac{1 - R^2}{n - m - 1} \frac{1}{1 - R_j^2}$$

- charakteristika $VIF_j = \frac{1}{1 - R_j^2}$ se nazývá **inflační faktor** (*variance inflation factor*)
 - udává, kolikrát se zhorší rozptyl odhadu $\hat{\beta}_j^*$ v důsledku korelovanosti j -tého regresoru s ostatními regresory
- stejný význam má i pro odhad $\hat{\beta}_j$, neboť

$$\hat{\beta}_j = \frac{T_0}{T_j} \hat{\beta}_j^* \quad \Rightarrow \quad \widehat{\text{Var}}(\hat{\beta}_j) = \frac{1 - R^2}{n - m - 1} \left(\frac{T_0}{T_j} \right)^2 \frac{1}{1 - R_j^2}$$

POZNÁMKA 6.5

- testovací statistika pro test $H_0 : \beta_j = 0$ je

$$T_j = \frac{\hat{\beta}_j}{\sqrt{\widehat{\text{Var}}\hat{\beta}_j}} = \frac{\frac{T_0}{T_j}\hat{\beta}_j^*}{\sqrt{\widehat{\text{Var}}\left(\frac{T_0}{T_j}\hat{\beta}_j^*\right)}} = \frac{\hat{\beta}_j^*}{\sqrt{\widehat{\text{Var}}\hat{\beta}_j^*}} = T_j^*$$

- t -testy jsou tedy stejné v původním i standardizovaném modelu
- velký VIF_j vyžaduje pro zamítnutí H_0 větší hodnotu $|\hat{\beta}_j^*|$

POZNÁMKA 6.6

- při výpočtu $\hat{\beta}_j^*$ si v **R** můžeme pomoci funkcí `scale()`, která provádí centrování a škálování vektoru $\mathbf{x}$ pomocí $\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$
- při použití funkce `scale()` se v modelu ponechává intercept, aby byly zachovány potřebné stupně volnosti

Zjišťování (detekce) kolinearity

A) pomocí indexu podmíněnosti $\kappa(\mathbf{X}^*) = \kappa(\mathbf{X}_{sc})$:

$\kappa(\mathbf{X}^*) > 100$ silná kolinearita (vypuštění nějakého sloupce)

$\kappa(\mathbf{X}^*) > \kappa$, kde $\kappa \in (10, 30)$ → použití metody na potlačení kolinearity

B) pomocí hodnoty *VIF*: $VIF_j > 10$ může indikovat problémy

- $VIF_j \geq 10 \Leftrightarrow R_j^2 \geq 0.9$
- R_j^2 nemusí být jednoznačně svázán s mírou LZ, *VIF* nemusí být vždy spolehlivý
- má ale jednoduchou stat. interpretaci a snadno se počítá
- většinou představuje spolehlivou náhradu $\kappa(\mathbf{X}^*)$

C) další možné příznaky:

- velké hodnoty odhadnutých parametrů $\hat{\beta}$
- velké směrodatné odchylky $\hat{\beta}$
- jeden nebo více odhadnutých regresních koeficientů se špatným znaménkem

Potlačení kolinearity

- získání dalších dat
- změna formulace modelu
 - někdy pomůže centrování proměnných
 - vynechání proměnných (může vést k vychýleným odhadům)
- kolinearita $\Rightarrow$ velké rozptyly odhadů
 - Gauss-Markov říká, že OLS je BLUE parametru β
 - tzn. zmenšené rozptyly $\hat{\beta}$ je možné jen použitím **nelineárních** nebo **vychýlených** odhadů

Hřebenová regrese (Ridge regression)

- zůstaneme u standardizovaného modelu, tzn. uvažujeme $\mathbf{X}^*$, $\mathbf{Y}^*$
- pro jednoduchost značení budeme používat $\mathbf{X}$, $\mathbf{Y}$ a předpokládat $h(\mathbf{X}) = m$
- hřebenová regrese - uměle se zvedne diagonála $\mathbf{X}^T \mathbf{X}$ a tím se potlačí kolinearita

- uvažujme $\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m$, kde $\delta > 0$ je malé
 - $\mathbf{X}^T \mathbf{X}$ je symetrická, tzn. ex. OG matice $\mathbf{Q}$ taková, že $\mathbf{X}^T \mathbf{X} = \mathbf{Q} \mathbf{S}^2 \mathbf{Q}^T$,
kde $\mathbf{S}^2$ je diagonální matice, mající na diagonále vlastní čísla, λ_i , matice $\mathbf{X}^T \mathbf{X}$
 - protože $h(\mathbf{X}^T \mathbf{X}) = m$, je $\mathbf{X}^T \mathbf{X}$ PD a $\lambda_i > 0, \forall i \in \hat{m}$
 - $\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m = \mathbf{Q}(\mathbf{S}^2 + \delta \mathbf{I}_m) \mathbf{Q}^T$ to je ale regulární matice
 - odtud plyne

$$(\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m) \mathbf{Q} = \mathbf{Q}(\mathbf{S}^2 + \delta \mathbf{I}_m)$$

tzn. čísla na diagonále $\mathbf{S}^2 + \delta \mathbf{I}_m$ jsou vlastní čísla matice $\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m$

- neboli $\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m$ je regulární a má vlastní čísla $\lambda_i + \delta$
- jejich velikost i poměry lze měnit volbou δ - hlavní myšlenka HR
- místo odhadu $\hat{\beta}^{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ budeme studovat odhad

$$\hat{\beta}^{R,\delta} = (\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m)^{-1} \mathbf{X}^T \mathbf{Y}$$

VĚTA 6.3

Vychýlení odhadu $\hat{\beta}^{R,\delta}$ je

$$\text{bias}(\hat{\beta}^{R,\delta}) = -\delta(\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m)^{-1} \beta.$$

Pro střední kvadratickou chybu odhadu $\hat{\beta}^{R,\delta}$ platí

$$MSE(\hat{\beta}^{R,\delta}) = (\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m)^{-1} \left[\sigma^2 \mathbf{X}^T \mathbf{X} + \delta^2 \beta \beta^T \right] (\mathbf{X}^T \mathbf{X} + \delta \mathbf{I}_m)^{-1}.$$

Důkaz.

VĚTA 6.4

Ve standardizovaném modelu s plnou hodnotí pro $0 < \delta < \frac{2\sigma^2}{\|\beta\|^2}$ platí, že

$$\text{Cov}\hat{\beta}^{LS} - \text{MSE}(\hat{\beta}^{R,\delta}) \text{ je PD matice.}$$

POZNÁMKA 6.7

- ukázali jsme $E\|\hat{\beta}\|^2 > \|\beta\|^2$ $(+\sigma^2\text{tr}(\mathbf{X}^T\mathbf{X})^{-1})$
- můžeme se snažit $\hat{\beta}$ nějak zkrátit (za cenu ztráty nestrannosti)
- jiná interpretace hřebenového odhadu:
 - hledejme β , které pro dané δ minimalizuje

$$\varphi(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \delta\|\beta\|^2$$

- dá se ukázat, že řešením je $\hat{\beta}^{R,\delta}$

VĚTA 6.5

Nechť $\mathbf{PSQ}^T$ je singulární rozklad matice $\mathbf{X}$. Potom platí

$$\text{Cov}(\hat{\boldsymbol{\beta}}^{R,\delta}) = \sigma^2 \sum_{i=1}^m \left(\frac{s_i}{s_i^2 + \delta} \right)^2 \mathbf{q}_i \mathbf{q}_i^T = \sigma^2 \sum_{i=1}^m \frac{\lambda_i}{(\lambda_i + \delta)^2} \mathbf{q}_i \mathbf{q}_i^T.$$

Důkaz.

POZNÁMKA 6.8

- pokud je $\mathbf{X}$ špatně podmíněná, bude min. jedno s_i^2 malé, tedy $\frac{1}{s_i^2}$ vystupující ve $\text{Var}(\hat{\beta}_j^{LS})$ bude velké
- ale $\frac{s_i^2}{(s_i^2 + \delta)^2}$ může být zase malé!

Volba parametru δ

1) Hřebenová stopa (ridge trace):

- vypočítají se $\hat{\beta}^{R,\delta}$ pro různé hodnoty δ
- vykreslí se graf jednotlivých složek $\hat{\beta}^{R,\delta}$ v závislosti na δ
- doporučuje se volit takové δ , pro které se grafy „stabilizují“ (subjektivní)

2) Harmonic mean estimator: $\hat{\delta} = \frac{ms_n^2}{\|\hat{\beta}\|^2}$,

kde $\hat{\beta}$ a s_n^2 jsou klasické (OLS) odhady parametrů β, σ^2

POZNÁMKA 6.9

- existuje spousta dalších metod pro odhad δ , vlastnosti většinou zkoumány jen pomocí simulačních studií
- pokud nemáme nějakou apriorní informaci o β , použití hřebenové regrese nezaručí zlepšení OLS

PŘÍKLAD 6.1 (Data Cement)

```
XX <- cbind(scale(x1),scale(x2),scale(x3),scale(x4))
kappa(XX,exact = TRUE)

## 37.10634

ridge <- lm.ridge(scale(y) ~ XX, lambda = seq(0,0.3,0.001))

plot(ridge)

select(ridge)

## modified HKB estimator is 0.08499604
## modified L-W estimator is 0.05830686
## mallest value of GCV at 0.3
```

