

## VĚTA 3.9

Nechť v modelu  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$  tvaru (\*\*) platí  $h(\mathbf{X}) = m + 1$  a  $e_1, \dots, e_n$  jsou i.i.d.  $N(0, \sigma^2)$ . Pokud  $\boldsymbol{\beta}_s = \mathbf{0}$ , tj.  $\beta_1 = \beta_2 = \dots = \beta_m = 0$ , potom

$$F \sim F(m, n - m - 1).$$

Důkaz.

**TEST:** zamítnout  $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$  pokud  $F > F_{1-\alpha}(m, n - m - 1)$

**POZNÁMKA:** Odvozeno pro  $e_i \sim N(0, \sigma^2)$ . Obecně se používá, i když to nevíme, pro velké  $n$  může být často zdůvodněno pomocí CLV.

### Tabulka ANOVA

Source	df	SS	MS	$F$
Regression	$m$	$SSR$	$MSR = \frac{SSR}{m}$	$\frac{MSR}{MSE}$
Residual	$n - m - 1$	$SSE$	$MSE = \frac{SSE}{n - m - 1} = s_n^2$	
Total	$n - 1$	$SST$		
		$R^2$	$\bar{R}^2$	

**Koeficient (vícenásobné) determinace  $R^2$ :**

Podobně jako u jednorozměrné regrese, lze F-test chápat jako test významnosti  $R^2$ , definovaného jako

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (SST = SSR + SSE)$$

### POZNÁMKA 3.6

- $R^2$  je možno zvětšovat přidáváním nových proměnných  $x$ , i když jsou statisticky nevýznamné (Pro  $n$  LN proměnných  $x$  a  $n$  pozorování dostaneme "perfect fit") (overfitting)
- Vysvětlení:  $R^2 = 1 - \frac{SSE}{SST}$ , kde
  - $SST$  je pevně dáno daty  $y$ , ale  $SSE$  může být snížena přidáním proměnných  $x$
  - minimalizujeme totiž  $(\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta)$  přes větší množinu  $\beta$
  - to znamená, že  $\frac{SSE}{SST}$  je nerostoucí funkce a  $R^2$  je neklesající funkce počtu proměnných

Upravený koeficient determinace (adjusted coefficient of determination):

$$\bar{R}^2 = R_{adj}^2 = 1 - \frac{\frac{SSE}{n - m - 1}}{\frac{SST}{n - 1}} = 1 - \frac{n - 1}{n - m - 1} \frac{SSE}{SST}.$$

### PŘÍKLAD 3.3 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)

##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age          111.98      29.05   3.855 0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl   18.42      41.76   0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101

SSR <- sum((predict(mod)-mean(Weight))^2)
SSE <- sum((predict(mod)-(Weight))^2)
F <- (SSR/3)/(SSE/(24-3-1)); F

## 12.03152

anova(mod)

## Analysis of Variance Table
## Response: Weight
##      Df Sum Sq Mean Sq F value    Pr(>F)
## Age    1 1013799 1013799 31.0779 1.862e-05 ***
## Sex     1  157304  157304  4.8221  0.04006 *
## Age:Sex 1    6346    6346  0.1945  0.66389
## Residuals 20 652425    32621
## ---
```

### 3.4 Intervaly spolehlivosti a $t$ -testy pro parametry

- pokud se model ukáže jako významný, bude nás zajímat, které koeficienty přispívají
- lze použít IS a TH stejně, jako u jednorozměrné regrese
- výsledky jsou odvozeny pro normální chyby
- v praxi se používají i pro jiné typy chyb

Pro konstrukci použijeme dokázanou vlastnost

$$T_j = \frac{\hat{\beta}_j - \beta_j}{s_n \sqrt{v_j}} \sim t(n - m - 1), \quad \text{kde} \quad v_j = (\mathbf{X}^T \mathbf{X})_{jj}^{-1}$$

100(1 -  $\alpha$ )% IS pro  $\beta_j$  je

$$(\hat{\beta}_j - t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j}, \hat{\beta}_j + t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j})$$

S pomocí IS lze odvodit kritický obor pro test  $H_0 : \beta_j = b_j \times H_1 : \beta_j \neq b_j$  ve tvaru

$$\frac{|\hat{\beta}_j - b_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

Pro  $b_j = 0$  dostaneme test významnosti  $\beta_j$ , tzn.  $H_0 : \beta_j = 0$  zamítneme, pokud

$$\frac{|\hat{\beta}_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

### POZNÁMKA 3.7

- pokud nejsou porušeny předpoklady modelu nebo není přítomna kolinearita, lze zvážit odstranění všech nevýznamných proměnných (dle t-testu)
- v případě kolinearit, může být model významný (dle celkového F-testu), ale všechny nebo téměř všechny proměnné se mohou jevit jako nevýznamné (dle t-testů)
- naopak, pokud má model velký počet možných proměnných, některé proměnné se mohou jevit významné, i když jsou náhodným šumem
- při použití t-testů je třeba postupovat obezřetně

## PŘÍKLAD 3.4 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age         111.98      29.05    3.855 0.000986 ***
## Sexgirl     -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl  18.42      41.76    0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101
```

```
vif(mod)
## Age      Sex      Age:Sex
## 1.96444 477.55172 483.47306
```

```
mod0 <- lm(Weight ~ Age + Sex)
summary(mod0)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1610.28     786.08  -2.049  0.0532 .
## Age         120.89      20.46    5.908 7.28e-06 ***
## Sexgirl     -163.04      72.81   -2.239  0.0361 *
## ---
## Residual standard error: 177.1 on 21 degrees of freedom
## Multiple R-squared:  0.64,    Adjusted R-squared:  0.6057
## F-statistic: 18.67 on 2 and 21 DF,  p-value: 2.194e-05
```

```
vif(mod0)
## Age      Sex
## 1.013904 1.013904
```

## PŘÍKLAD 3.5 (Data cement)

	x1	x2	x3	x4	y
1	7	26	6	60	78.5
2	1	29	15	52	74.3
3	11	56	8	20	104.3
4	11	31	8	47	87.6
5	7	52	6	33	95.9
6	11	55	9	22	109.2
7	3	71	17	6	102.7
8	1	31	22	44	72.5
9	2	54	18	22	93.1
10	21	47	4	26	115.9
11	1	40	23	34	83.8
12	11	66	9	12	113.3
13	10	68	8	12	109.4

```
mod <- lm(y ~ x1 + x2 + x3 + x4)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  62.4054    70.0710   0.891   0.3991
## x1           1.5511     0.7448   2.083   0.0708 .
## x2           0.5102     0.7238   0.705   0.5009
## x3           0.1019     0.7547   0.135   0.8959
## x4          -0.1441     0.7091  -0.203   0.8441
## ---
## Residual standard error: 2.446 on 8 degrees of freedom
## Multiple R-squared:  0.9824,    Adjusted R-squared:  0.9736
## F-statistic: 111.5 on 4 and 8 DF,  p-value: 4.756e-07
```

```
vif(mod)
##           x1           x2           x3           x4
## 38.49621 254.42317  46.86839 282.51286
```

```
mod1 <- lm(y ~ x1)
summary(mod1)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  81.4793     4.9273  16.54 4.07e-09 ***
## x1           1.8687     0.5264   3.55 0.00455 **
## ---
## Residual standard error: 10.73 on 11 degrees of freedom
## Multiple R-squared:  0.5339,    Adjusted R-squared:  0.4916
## F-statistic: 12.6 on 1 and 11 DF,  p-value: 0.004552
```



```

mod12 <- lm(y ~ x1 + x2)
summary(mod12)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 52.57735    2.28617   23.00 5.46e-10 ***
## x1          1.46831    0.12130   12.11 2.69e-07 ***
## x2          0.66225    0.04585   14.44 5.03e-08 ***
## ---
## Residual standard error: 2.406 on 10 degrees of freedom
## Multiple R-squared:  0.9787,    Adjusted R-squared:  0.9744
## F-statistic: 229.5 on 2 and 10 DF,  p-value: 4.407e-09

vif(mod12)
##          x1          x2
## 1.055129 1.055129

```

## POZNÁMKA 3.8

- statistiky  $F$ ,  $R^2$  a  $t$  jsou užitečné pro rozkrytí efektů jednotlivých proměnných
- nemohou být ale používány úplně automaticky

## 3.5 Obecná lineární hypotéza

Hypotézy uvažované v F-testu a t-testech jsou speciálním případem **obecné lineární hypotézy**

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{b} \quad \times \quad H_1 : \mathbf{C}\boldsymbol{\beta} \neq \mathbf{b},$$

kde  $\mathbf{C} \in \mathbb{R}^{r \times (m+1)}$  a  $h(\mathbf{C}) = r$  (tzn.  $r \leq m+1$ )

Rovnice  $\mathbf{C}\boldsymbol{\beta} = \mathbf{b}$  reprezentuje  $r$  lineárně nezávislých podmínek

$$\sum_{j=0}^m c_{ij}\beta_j = b_i, \quad i = 1, \dots, r.$$

### POZNÁMKA 3.9

a) volba  $\mathbf{b} = (0, \dots, 0)^T$  a  $\mathbf{C} = \left( \begin{array}{c|cccc} 0 & 1 & 0 & \dots & 0 \\ \hline 0 & 0 & 1 & & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 0 & 0 & \dots & 0 & 1 \end{array} \right)_{m \times (m+1)}$  vede na test

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{0} \quad \Leftrightarrow \quad H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0,$$

b) volba  $\mathbf{b} = \mathbf{0}$  a  $\mathbf{C} = (0, \dots, 0, 1, 0, \dots, 0)$  vede na test  $H_0 : \beta_j = 0$ ,

c) v modelu  $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + e$  chceme testovat zároveň, že  $\beta_2 = 0$  a  $\beta_3 = \beta_4$ ,

to lze udělat volbou  $\mathbf{C} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{pmatrix}$ ,  $\mathbf{b} = (0, 0)^T$ .

### Pro test $H_0$ naladíme 2 modely:

1) **plný model** (full model) - bez podmínek na  $\mathbf{C}\beta$ ,

2) **redukovaný model** (reduced model) - za předpokladu, že platí  $H_0 : \mathbf{C}\beta = \mathbf{b}$ .

Označme příslušné reziduální součty čtverců  $SSE_F$  a  $SSE_R$  ( $SSE_F \leq SSE_R$ )

- pokud neplatí  $H_0$ , dá se očekávat, že  $\Delta SSE = SSE_R - SSE_F$  bude významně větší, než náhodná chyba  $\sigma^2$
- $H_0$  tedy budeme zamítat, pokud  $\frac{\Delta SSE}{s_n^2}$  bude velké
- zobecnění F-testu, za platnosti  $H_0$  ukážeme pro normální chyby vztah

$$F = \frac{\frac{\Delta SSE}{r}}{s_n^2} \sim F(r, n - m - 1)$$

### PŘÍKLAD 3.6

Uvažujme F-test pro  $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$  v plném modelu (\*\*).