

4.4 Transformace

- pokud není splněn některý z předpokladů modelu - **linearita, normalita chyb, homoskedasticita**
- jednou z možností je pokusit se transformovat proměnné, aby transformovaný model předpoklady alespoň „přibližně“ splňoval

A) Transformace vysvětlované proměnné y

hledáme funkci $h(\cdot)$ tak, aby model $Y_i^* = h(Y_i) = \beta_0 + \sum_{j=1}^m x_{ij}\beta_j + e_j$ předpoklady splňoval

3 hlavní důvody pro transformaci y :

1) transformace škály měření tak, aby pokrývala celé **R**

(což může odstranit problémy spodemíkami na β)

- např. studie kapacity plic (FEV data, $FEV > 0$), chtěli bychom, aby model nepredikoval záporné hodnoty
- lze obejít modelováním $y^* = \ln FEV$
- pokud y jsou počty a 0 je možná hodnota, často se používá $y^* = \ln(y + 1)$ nebo obecně $y^* = \ln(y + c)$

2) transformace Y , aby její rozdělení bylo „více“ normální

- typicky se snažíme udělat rozdělení hodnot y více symetrické
- často se setkáváme s rozděleními vychýlenými vpravo
- transformace $y^* = \ln y$ nebo $y^* = y^\lambda$, $\lambda < 1$ budou redukovat toto vychýlení
- **typický postup:** začít s hodnotou $\lambda \approx 1$ a pak snižovat, dokud není dosaženo „přibližné“ symetrie reziduí

3) možná nejzásadnější motivace: pokusit se dosáhnout konstantní rozptyl

- např. pro fyzikální veličinu s kladnými hodnotami se často stane, že rozptyl bude malý pro $\mu \approx 0$ a větší pro μ velké (tzv. **positive mean-variance relationship**)
- nepřesnost měření kladných veličin se často vyjadřuje pomocí koeficientu variace $CV(Y) = \frac{s.d.Y}{EY}$
- bývá více konstantní než s.d. (variabilitu vyjadřujeme relativně)
- matematicky to znamená, že $\text{Var}Y = \varphi(EY)^2 = \varphi\mu^2$ pro nějaké φ
- pro odstranění vztahu mezi EY a $\text{Var}Y$ se často používají transformace $y^* = y^\lambda$ (pro $y > 0$)

Transformace:	\longleftarrow	\cdots	y^3	y^2	y	\sqrt{y}	$\ln y$	$\frac{1}{\sqrt{y}}$	$\frac{1}{y}$	$\frac{1}{y^2}$	\cdots	\longrightarrow
Box-Cox λ :			3	2	1	$\frac{1}{2}$	0	$-\frac{1}{2}$	-1	-2		

• pokud $\text{Var} Y$ klesá

• pokud $\text{Var} Y$ roste s rostoucí EY

s rostoucí EY

OBECNĚ: předpokládejme vztah $\text{Var} Y = \varphi V(\mu)$ a uvažujme transformaci $y^* = h(y)$

Taylorův rozvoj 1. řádu funkce $h(y)$ v bodě μ

$$y^* = h(y) \approx h(\mu) + h'(\mu)(y - \mu)$$

z čehož plyne, že $\text{Var} Y^* \approx (h'(\mu))^2 \cdot \text{Var} Y$

transformace $y^* = h(y)$ bude přibližně stabilizovat rozptyl, pokud $h'(\mu)$ je úměrné $(\text{Var} Y)^{-\frac{1}{2}} = V^{-\frac{1}{2}}(\mu)$

• pokud $V(\mu) = \mu^2 \Rightarrow$ transformace stabilizující rozptyl je $h(y) = \ln y$ ($h'(\mu) = \frac{1}{\mu}$)

• pokud $V(\mu) = \mu \Rightarrow$ transformace stabilizující rozptyl je $h(y) = \sqrt{y}$ ($h'(\mu) = \frac{1}{2\sqrt{\mu}}$)

- asi nejvíce užívanou transformací je $y^* = \ln y$ (dobrá interpretovatelnost parametrů β)

POZNÁMKA 4.11 (Interpretace parametrů lineárního modelu)

a) **klasický LM:** $EY = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$

jednotková změna proměnné $x_j \Rightarrow$ změnu EY o β_j jednotek
(při ostatních proměnných stejných)

b) **LM pro $\ln Y$:** $\ln Y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + e, \quad e \sim N(0, \sigma^2)$

- pokud je to správný model, $\ln Y \sim N(\mu, \sigma^2) \Rightarrow Y \sim LN(\mu, \sigma^2)$ a $EY = e^{\mu + \frac{\sigma^2}{2}}$

predikce pro $E \ln Y$ je $\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m$

predikce pro EY je $e^{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m + \frac{\sigma^2}{2}}$

- uvažujme opět jednotkovou změnu proměnné x_j ($x_j \rightarrow x_j + 1$)

$$\frac{EY_{\text{new}}}{EY} = \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j x_j + \beta_j + \dots + \beta_m x_m + \frac{\sigma^2}{2}}}{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \frac{\sigma^2}{2}}} = e^{\beta_j}$$

jednotková změna proměnné $x_j \Rightarrow$ multiplikativní změnu EY e^{β_j} -krát

jinak zapsáno: $100(e^{\beta_j} - 1)$ je procentní změna EY spojená s jednotkovou změnou x_j

Box-Cox transformace

- pokud chyby nemají normální rozdělení, hledáme transformaci Y , která by nejenom linearizovala model, ale také transformovala chyby, aby byly přibližně normální
- užitečná třída transformací (**power family**)

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \text{pokud } \lambda \neq 0 \\ \ln y, & \text{pokud } \lambda = 0 \end{cases}, \quad \left(\lim_{\lambda \rightarrow 0} \frac{y^\lambda - 1}{\lambda} = \ln y \right)$$

která předpokládá, že data y jsou kladná

- pro nalezení vhodného λ budeme předpokládat, že transformované veličiny $Y_i^{(\lambda)}$, $i = 1, \dots, n$, splňují podmínky RM, tj.

$$Y_i^{(\lambda)} = \mathbf{x}_i^T \boldsymbol{\beta} + \mathbf{e} \quad \text{kde} \quad \mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad (Y_i^{(\lambda)} \sim N(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma^2), \quad Y_i^{(\lambda)} \text{ nezávislé})$$

- úkol je odhadnout zároveň $\lambda, \boldsymbol{\beta}, \sigma^2$, použijeme MLE

Dostali jsme tedy tzv. **profile log - likelihood**

$$\ell_p^{(\lambda)} = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) - \frac{n}{2} + \ln J(\lambda) = C - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) + (\lambda - 1) \sum_{i=1}^n \ln y_i,$$

kde

$$\hat{\beta}(\lambda) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}^{(\lambda)}, \quad \hat{\sigma}^2(\lambda) = \frac{1}{n} \sum_{i=1}^n (y_i^{(\lambda)} - \hat{y}_i^{(\lambda)})^2,$$

a

$$\mathbf{y}^{(\lambda)} = (y_1^{(\lambda)}, \dots, y_n^{(\lambda)})^T, \quad \hat{y}_i^{(\lambda)} = \mathbf{x}_i^T \hat{\beta}(\lambda).$$

POZNÁMKA:

- kvůli komplikované závislosti $\ell_p^{(\lambda)}$ na λ bude třeba numerická metoda pro maximalizaci
- lze přepsat do tvaru, kde bude možné využít metody LR

Celkem: $\max_{\lambda} \ell_p(\lambda) \iff \min_{\lambda} s_{\lambda}^2,$

kde

$$s_{\lambda}^2 = \frac{\hat{\sigma}^2(\lambda)}{[(\dot{y})^{\lambda-1}]^2} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} - \frac{\hat{y}_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} \right)^2,$$

tzn. s_{λ}^2 je reziduální součet čtverců (SSE/n) v modelu $\frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}}$ v závislosti na \mathbf{x}_i^T
(tzn. s_{λ}^2 lze snadno získat pomocí funkce `lm()`)

Algoritmus:

- 1) zvolit oblast hodnot λ , $I = \langle \lambda_{min}, \lambda_{max} \rangle$, a body $\lambda \in I$
(typicky $I = \langle -2, 2 \rangle$ a 10-20 rovnoměrně rozdělených bodů)
- 2) naladit model $\frac{y^{(\lambda)}}{(\dot{y})^{\lambda-1}} \sim x$ a spočítat $\frac{1}{n} SSE = s_{\lambda}^2$.
- 3) z grafu (λ, s_{λ}^2) vybrat $\hat{\lambda}$, které minimalizuje s_{λ}^2
- 4) pro zvolené $\hat{\lambda}$ naladit model $y^{(\hat{\lambda})} \sim x$ a pokračovat standardní analýzou

Intervaly spolehlivosti pro λ :

- snadno lze odvodit LRT test pro test $H_0 : \lambda = \lambda_0$
($H_0 : \lambda = 1$ zda je třeba transformace, pokud zamítneme $H_0 \Rightarrow$ transformace pomocí $\hat{\lambda}$)
- LRT statistika: $\Lambda = -2 \ln \frac{L(\lambda_0)}{L(\hat{\lambda})} = 2(\ell_p(\hat{\lambda}) - \ell_p(\lambda_0))$, víme že $\Lambda \xrightarrow{L} \chi^2(1)$
- invertováním přípustné oblasti LRT testu, dostaneme **as. $100(1 - \alpha)\%$ IS pro λ**

$$\left\{ \lambda \in \mathbb{R} \mid n \cdot \ln \frac{s_{\hat{\lambda}}^2}{s_{\lambda}^2} \leq \chi_{1-\alpha}^2(1) \right\}, \quad \text{kde } \hat{\lambda} \text{ je MLE } \lambda$$



POZNÁMKA 4.12

Kvůli jednoduchosti interpretace se často doporučuje zaokrouhlit $\hat{\lambda}$ na nejbližší $\frac{1}{4}$ nebo $\frac{1}{3}$.

PŘÍKLAD 4.4 (Data TREES)

	Girth	Height	Volume
1	8	70	10
2	9	65	10
3	9	63	10
4	10	72	16
⋮	⋮	⋮	⋮

```
mod <- lm(Volume ~ Girth + Height)
summary(mod)
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -57.9877      8.6382  -6.713 2.75e-07 ***
## Girth         4.7082      0.2643  17.816 < 2e-16 ***
## Height        0.3393      0.1302   2.607  0.0145 *
## ---
## Residual standard error: 3.882 on 28 degrees of freedom
## Multiple R-squared:  0.948,    Adjusted R-squared:  0.9442
## F-statistic: 255 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat <- predict(mod)
st.res <- rstudent(mod)
plot(y.hat, st.res, pch = c(1), col = c("red"), lwd=2)
```



```
bc<- boxcox(mod, lambda = seq(-2,2,1/10))
```

```
lambda.hat <- bc$x[which.max(bc$y)]; lambda.hat
## 0.3030303
```

```
Vol.lambda <- (Volume^lambda.hat-1)/lambda.hat
```

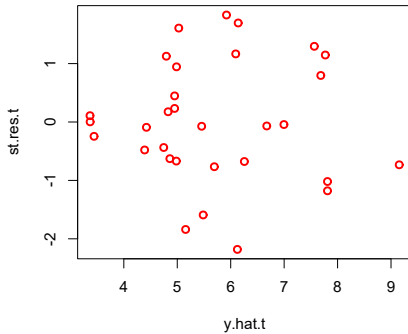
```
mod.t <- lm(Vol.lambda ~ Girth + Height)
summary(mod.t)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.733542   0.500080  -5.466 7.77e-06 ***
## Girth        0.409448   0.015299   26.764 < 2e-16 ***
## Height       0.039685   0.007535    5.267 1.34e-05 ***
## ---
## Residual standard error: 0.2247 on 28 degrees of freedom
## Multiple R-squared: 0.9775, Adjusted R-squared: 0.9759
## F-statistic: 609.6 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat.t <- predict(mod.t)
st.res.t <- rstudent(mod.t)

plot(y.hat.t, st.res.t, pch = c(1), col = c("red"), lwd=2)
```



B) Transformace vysvětlujících proměnných \mathbf{x}

- pokud diagnostika modelu naznačuje, že vztah mezi \mathbf{y} a \mathbf{X} není lineární pro jeden nebo více regresorů, může být vhodné přeformulovat model pomocí transformací proměnných \mathbf{x}
- předpokládejme, že v modelu $Y = \beta_0 + \sum_{j=1}^m \beta_j x_j + e$ máme podezření na nelinearitu v j -té proměnné x_j
- jednou z možností jak postupovat je nahrazení x_j proměnnou $z_j = f(x_j)$, model tedy bude

$$Y = \beta_0 + \beta_1 x_1 + \cdots + \beta_j z_j + \cdots + \beta_m x_m + e$$

- pokud je f známé, jedná se o model LR a lze ho analyzovat standardně, pokud je tato transformace vhodná, mělo by se to projevit ve zlepšení statistik R^2 , t , F a zlepšení grafu reziduí pro z_j oproti těm pro x_j
- bohužel f většinou známá není, možný přístup je parametrizovat nějak tuto funkci a pak odhadnout tyto parametry společně s β
 - **typická parametrizace:** $z_j = x_j^\lambda$, kde $\lambda \in \mathbb{R}$ vhodné
 - aproximace f pomocí polynomu vhodného stupně, tzn. $z_j = \sum_{k=1}^l r_k x_j^k$, kde r_k musí být odhadnuty
 - další možností je použití trigonometrických funkcí nebo splines (piecewise polynomials)

Zaměříme se na $z_j = x_j^\lambda$:

- možnost je opět zvolit jistou množinu hodnot λ , naladit modely pro všechna λ a vybrat model s nejlepší shodou s daty, např. s nejmenší SSE nebo největší R^2 nebo F
- může být časově náročné, můžeme minout vhodnou hodnotu λ , pokud nebyla v původní množině (nevíme jak R^2, F, SSE závisí na λ)

Box-Tidwell metoda

- předpokládejme, že λ se příliš neliší od $\lambda = 1$, Taylorův rozvoj 1. řádu kolem $\lambda = 1$ dává

$$x^\lambda \approx x^1 + (\lambda - 1) \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1}, \quad \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1} = x^\lambda \ln x \Big|_{\lambda=1} = x \ln x, \quad \text{tedy} \quad x^\lambda \approx x + (\lambda - 1)x \ln x$$

- dosazením do modelu

$$\begin{aligned} Y &= \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j (x_j + (\lambda - 1)x_j \ln x_j) + \dots + \beta_m x_m + e \\ &= \beta_0 + \sum_{k=1}^m \beta_k x_k + \underbrace{\beta_j (\lambda - 1)}_{\beta_{m+1}(\lambda)} x_j \ln x_j + e \end{aligned}$$

- máme lineární model pro parametry β_k , $0 \leq k \leq m+1$, protože $\beta_{m+1} = (\lambda - 1)\beta_j$, můžeme (λ, β_j) odhadnout následovně

- 1) naladíme původní model a spočteme $LSE \hat{\beta}_j$ parametru β_j
- 2) naladíme rozšířený model s $x_{m+1} = x_j \ln x_j$ a spočteme $\hat{\beta}_{m+1}$
- 3) z rovnosti $\hat{\beta}_{m+1} = (\hat{\lambda} - 1)\hat{\beta}_j$ dostaneme $\hat{\lambda} = \frac{\hat{\beta}_{m+1}}{\hat{\beta}_j} + 1$
 - tento postup umožňuje testovat potřebu transformace $H_0 : \lambda = 1 \quad \times \quad H_1 : \lambda \neq 1$
pomocí t-testu pro $H_0 : \beta_{m+1} = 0$

POZNÁMKA 4.13

- pokud model s $\hat{\lambda}$ vypadá neadekvátně, lze postupovat iterativně a získat posloupnost $\hat{\lambda}(l)$, $l \geq 1$
- $\hat{\lambda}(0) = \hat{\lambda}$ a rozvineme x_j^λ kolem $\hat{\lambda}(0)$, tzn. $x_j^\lambda \approx x_j^{\hat{\lambda}(0)} + (\lambda - \hat{\lambda}(0))x_j^{\hat{\lambda}(0)} \ln x_j$
- dosazením do rovnice modelu

$$Y = \beta_0 = \sum_{\substack{k=1 \\ k \neq j}}^m \beta_k x_k + \beta_j x_j^{\hat{\lambda}(0)} + \underbrace{\beta_j (\lambda - \hat{\lambda}(0))}_{\beta_{m+1}} x_j^{\hat{\lambda}(0)} \ln x_j + e$$

- naladíme tento model s a bez přidané proměnné $x_{m+1} = x_j^{\hat{\lambda}(0)} \ln x_j$, označíme $\hat{\beta}_j(1)$ a $\hat{\beta}_{m+1}(1)$ příslušné odhady

- potom

$$\hat{\lambda}(1) = \hat{\lambda}(0) + \frac{\hat{\beta}_{m+1}(1)}{\hat{\beta}_j(1)}$$

- můžeme dále iterovat do konvergence nebo skončit po pevném počtu iterací

POZNÁMKA 4.14 (Další užívané transformace v \mathbf{x} , \mathbf{y})

a) centrované proměnné: \mathbf{X}_C a \mathbf{y}_C

$$(\mathbf{X}_C)_{ij} = x_{ij} - \bar{x}_j, \quad i \in \hat{n}, \quad j \in \hat{m}, \quad \text{kde } \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad (\mathbf{y}_C)_i = y_i - \bar{y}$$

$$1) \hat{\beta}_1, \dots, \hat{\beta}_m \text{ je řešením } \mathbf{X}_C^T \mathbf{X}_C \boldsymbol{\beta} = \mathbf{X}_C^T \mathbf{y}_C, \quad 2) \hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \hat{\beta}_j \bar{x}_j$$

b) centrované a škálované proměnné \mathbf{X}_{SC} a \mathbf{y}_C (\mathbf{y}_{SC}):

škálování sloupců tak, aby jejich norma byla 1,

tzn. každý prvek j -tého sloupce matice \mathbf{X} podělíme $s_j = \left(\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \right)^{\frac{1}{2}}$

centrovaná a škálovaná matice \mathbf{X}_{SC} pak bude $\mathbf{X}_{SC} = \mathbf{X}_C \mathbf{S}$, $\mathbf{S} = \text{diag}\left(\frac{1}{s_1}, \dots, \frac{1}{s_m}\right)$

model bude $\mathbf{Y}_C = \mathbf{X}_{SC} \boldsymbol{\beta}_s + \mathbf{e}$

(lze použít i \mathbf{Y}_{SC} , tedy centrované a škálované \mathbf{Y})

4.5 Vážené nejmenší čtverce (weighted least squares - WLS)

- budeme předpokládat, že chyby e_i jsou normální, nezávislé, ale $\text{Var}(e_i) = \sigma_i^2$ závisí na i
- konkrétně $\sigma_i^2 = \frac{\sigma^2}{w_i}$, kde $w_i > 0$, $i \in \hat{n}$, se nazývají **váhy**
- uvažujeme tedy model

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \text{kde} \quad \mathbf{e} \sim N_n(0, \sigma^2 \mathbf{W}) \quad \text{a} \quad \mathbf{W} = \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right) \quad (4.2)$$

- pokud jsou váhy w_i známé, lze MLE odhady parametru $\boldsymbol{\beta}$ a σ^2 nalézt následovně

$$\mathbf{W} = \mathbf{K}\mathbf{K}^T, \quad \text{kde} \quad \mathbf{K} = \mathbf{W}^{\frac{1}{2}} = \text{diag}\left(\frac{1}{\sqrt{w_1}}, \dots, \frac{1}{\sqrt{w_n}}\right)$$

- definujeme $\mathbf{Z} = \mathbf{K}^{-1}\mathbf{Y}$, $\mathbf{M} = \mathbf{K}^{-1}\mathbf{X}$ a $\boldsymbol{\varepsilon} = \mathbf{K}^{-1}\mathbf{e}$
- dostaneme model

$$\mathbf{Z} = \mathbf{M}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \text{kde} \quad \boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{I}_n), \quad (4.3)$$

$$(\text{protože } \text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{K}^{-1}\sigma^2\mathbf{W}(\mathbf{K}^{-1})^T = \sigma^2\mathbf{K}^{-1}\mathbf{K}\mathbf{K}^T(\mathbf{K}^T)^{-1} = \sigma^2\mathbf{I}_n)$$

- to už je standardní model LR, ve kterém platí

$$\begin{aligned}\hat{\beta}_w &= (\mathbf{M}^T \mathbf{M})^{-1} \mathbf{M}^T \mathbf{z} = (\mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{y} \\ &= (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{y}\end{aligned}$$

$$\hat{\sigma}_w^2 = \frac{1}{n} \sum_{i=1}^n (z_i - \hat{z}_i)^2 = \frac{1}{n} \sum_{i=1}^n w_i (y_i - \hat{y}_i)^2 = \frac{1}{n} SSE_w,$$

kde SSE_w je vážený součet čtverců, $z_i = \sqrt{w_i} y_i$ a $\hat{z}_i = \sqrt{w_i} \mathbf{x}_i^T \hat{\beta}_w = \sqrt{w_i} \hat{y}_i$

- dále platí

a) $E\hat{\beta}_w = (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} E\mathbf{Y} = \beta$, tzn. $\hat{\beta}_w$ je nestranný odhad β

b) $E\left(\frac{SSE_w}{n-m-1}\right) = \sigma^2$, tedy $s_w^2 = \frac{SSE_w}{n-m-1}$ je nestranný odhad σ^2

VĚTA 4.4

Nechť $\hat{\beta}_w$ je WLS odhad β , jestliže $\text{Cov}(\mathbf{e}) = \sigma^2 \mathbf{W} = \sigma^2 \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right)$. Potom platí:

- 1) $\text{Cov}(\hat{\beta}_w) = \sigma^2 (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$
- 2) nechť δ_i je i -tý diagonální prvek $(\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$, jestliže $e_i \sim N\left(0, \frac{\sigma^2}{w_i}\right)$, $i \in \hat{n}$, potom

$$T_i = \frac{\hat{\beta}_{w,i} - \beta_i}{s_w \sqrt{\delta_i}} \sim t(n - m - 1)$$

- 3) pro $\hat{\mathbf{Y}}_w = \mathbf{X} \hat{\beta}_w$ platí $E \hat{\mathbf{Y}}_w = \mathbf{X} \beta$ a $\text{Cov}(\hat{\mathbf{Y}}_w) = \sigma^2 \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T$
- 4) Nechť $\hat{\mathbf{e}}_w = \mathbf{Y} - \hat{\mathbf{Y}}_w$ jsou rezidua v modelu (4.2) a $\hat{\mathbf{e}}_w = \mathbf{Z} - \hat{\mathbf{Z}} = \mathbf{Z} - \mathbf{M} \hat{\beta}_w$ jsou rezidua v transformovaném modelu (4.3). Potom

$$\hat{\mathbf{e}}_w = \sqrt{\mathbf{W}^{-1}} \hat{\mathbf{e}}_w = \mathbf{W}^{-\frac{1}{2}} \hat{\mathbf{e}}_w \quad \text{a} \quad E(\hat{\mathbf{e}}_w) = E(\hat{\mathbf{e}}_w) = \mathbf{0}.$$

- 5) nechť $\mathbf{H}_w = \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1}$ je vážená projekční matice, potom

$$\hat{\mathbf{e}}_w = (\mathbf{I} - \mathbf{H}_w) \mathbf{e}, \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 (\mathbf{I} - \mathbf{H}_w) \mathbf{W}, \quad \text{tzn.} \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 \mathbf{W}^{-\frac{1}{2}} (\mathbf{I} - \mathbf{H}_w) \mathbf{W}^{\frac{1}{2}}$$

Důkaz.

- odhady parametrů β a σ^2 lze získat použitím transformovaného modelu (4.3)
- protože ale transformovaný model neobsahuje intercept (první sloupec \mathbf{M} je $(\sqrt{w_1}, \dots, \sqrt{w_n})^T$), nefunguje klasický rozklad součtu čtverců a F a R^2 statistiku nelze definovat obvyklým způsobem (viz. regrese skrz počátek)
- nicméně princip „extra sum of squares“ funguje, ať má model intercept nebo ne
 - např. celkový F -test lze provést pomocí statistiky

$$F_w = \frac{\frac{SSE_R - SSE_F}{m}}{s_w^2},$$

kde SSE_F je reziduální součet čtverců s_w^2 plného modelu a SSE_R je reziduální součet čtverců redukovaného transformovaného modelu $\mathbf{Z} = \mathbf{M}_0\beta_0 + \mathbf{e}$, $\mathbf{M}_0 = (\sqrt{w_1}, \dots, \sqrt{w_n})^T$

- pokud mají chyby normální rozdělení, platí za $H_0 : \beta_1 = \dots = \beta_m = 0$, že $F_w \sim F(m, n - m - 1)$ a H_0 zamítáme, pokud $F_w > F_{1-\alpha}(m, n - m - 1)$
- přirozené je definovat $R^2 = \varrho^2(\hat{\mathbf{z}}, \mathbf{z})$, kde $\varrho(\hat{\mathbf{z}}, \mathbf{z})$ je výběrový korelační koeficient (pro $\mathbf{W} = \mathbf{I}$ dostaneme standardní R^2)

Pro analýzu reziduí je třeba uvažovat vhodné grafy reziduí:

- máme dva vektory reziduí:

$$\hat{e}_i \text{ v původním modelu (4.2)} \quad \hat{\varepsilon}_i \text{ v transformovaném modelu (4.3)}$$

a tedy dvě možnosti

- pro kontrolu konstantního rozptylu lze uvažovat i standardizovaná nebo studentizovaná rezidua (pomocí bodu 4) a 5) věty lze ukázat, že jsou v obou modelech stejná)
- je třeba být opatrný oproti jakým hodnotám budeme rezidua zobrazovat
- grafy \hat{e}_i proti sloupcům \mathbf{M} a predikovaným hodnotám $\hat{\mathbf{z}}$ jsou OK, neboť např.

$$\sum_{i=1}^n \hat{z}_i \hat{e}_i = 0$$

(jsou OG, měl by být vidět roztýlený oblak kolem osy x)

- dosazením $\hat{e}_i = \sqrt{w_i} \cdot \hat{e}_i$ a $\hat{z}_i = \sqrt{w_i} \cdot \hat{y}_i$ dostaneme $\sum_{i=1}^n w_i \hat{e}_i \hat{y}_i = 0$, tzn. graf \hat{e}_i proti \hat{y}_i bude zavádějící
- graf $\sqrt{w_i} \cdot \hat{e}_i$ proti $\sqrt{w_i} \cdot \hat{y}_i$ je ale v pořádku
- podobné závěry platí i pro grafy \hat{e}_i proti \mathbf{x}_j^c , $j = 1, \dots, m$

POZNÁMKA 4.15

- pokud jsou váhy neznámé, bylo by třeba je odhadnout společně s β a σ^2 z dat
- to ale není obecně možné, protože máme více parametrů než dat
- někdy to možné je, pokud máme další informace o rozdělení chyb (tvar kovarianční matice atd.)

POZNÁMKA 4.16

- celý postup WLS lze použít i na případ $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{W})$, kde \mathbf{W} je známá, ale není diagonální
- protože \mathbf{W} je PD, ex. regulární \mathbf{K} tak, že $\mathbf{W} = \mathbf{K}\mathbf{K}^T$
- stejná transformace jako u WLS opět vede na transformovaný model, kde $\varepsilon \sim N_m(\mathbf{0}, \sigma^2 \mathbf{I}_m)$