

VĚTA 3.9

Nechť v modelu $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ tvaru (**) platí $h(\mathbf{X}) = m + 1$ a e_1, \dots, e_n jsou i.i.d. $N(0, \sigma^2)$. Pokud $\boldsymbol{\beta}_s = \mathbf{0}$, tj. $\beta_1 = \beta_2 = \dots = \beta_m = 0$, potom

$$F \sim F(m, n - m - 1).$$

Důkaz.

TEST: zamítnout $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$ pokud $F > F_{1-\alpha}(m, n - m - 1)$

POZNÁMKA: Odvozeno pro $e_i \sim N(0, \sigma^2)$. Obecně se používá, i když to nevíme, pro velké n může být často zdůvodněno pomocí CLV.

Tabulka ANOVA

Source	df	SS	MS	F
Regression	m	SSR	$MSR = \frac{SSR}{m}$	$\frac{MSR}{MSE}$
Residual	$n - m - 1$	SSE	$MSE = \frac{SSE}{n - m - 1} = s_n^2$	
Total	$n - 1$	SST		
		R^2	\bar{R}^2	

Koeficient (vícenásobné) determinace R^2 :

Podobně jako u jednorozměrné regrese, lze F-test chápat jako test významnosti R^2 , definovaného jako

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (SST = SSR + SSE)$$

POZNÁMKA 3.6

- R^2 je možno zvětšovat přidáváním nových proměnných x , i když jsou statisticky nevýznamné (Pro n LN proměnných x a n pozorování dostaneme "perfect fit") (overfitting)
- Vysvětlení: $R^2 = 1 - \frac{SSE}{SST}$, kde
 - SST je pevně dáno daty y , ale SSE může být snížena přidáním proměnných x
 - minimalizujeme totiž $(\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta)$ přes větší množinu β
 - to znamená, že $\frac{SSE}{SST}$ je nerostoucí funkce a R^2 je neklesající funkce počtu proměnných

Upravený koeficient determinace (adjusted coefficient of determination):

$$\bar{R}^2 = R_{adj}^2 = 1 - \frac{\frac{SSE}{n - m - 1}}{\frac{SST}{n - 1}} = 1 - \frac{n - 1}{n - m - 1} \frac{SSE}{SST}.$$

PŘÍKLAD 3.3 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age          111.98      29.05   3.855 0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl   18.42      41.76   0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101

SSR <- sum((predict(mod)-mean(Weight))^2)
SSE <- sum((predict(mod)-(Weight))^2)
F <- (SSR/3)/(SSE/(24-3-1)); F

## 12.03152

anova(mod)

## Analysis of Variance Table
## Response: Weight
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Age       1 1013799 1013799 31.0779 1.862e-05 ***
## Sex       1  157304  157304  4.8221  0.04006 *
## Age:Sex   1    6346    6346  0.1945  0.66389
## Residuals 20  652425    32621
## ---
```

3.4 Intervaly spolehlivosti a t -testy pro parametry

- pokud se model ukáže jako významný, bude nás zajímat, které koeficienty přispívají
- lze použít IS a TH stejně, jako u jednorozměrné regrese
- výsledky jsou odvozeny pro normální chyby
- v praxi se používají i pro jiné typy chyb

Pro konstrukci použijeme dokázanou vlastnost

$$T_j = \frac{\hat{\beta}_j - \beta_j}{s_n \sqrt{v_j}} \sim t(n - m - 1), \quad \text{kde} \quad v_j = (\mathbf{X}^T \mathbf{X})_{jj}^{-1}$$

100(1 - α)% IS pro β_j je

$$(\hat{\beta}_j - t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j}, \hat{\beta}_j + t_{1-\frac{\alpha}{2}}(n - m - 1)s_n \sqrt{v_j})$$

S pomocí IS lze odvodit kritický obor pro test $H_0 : \beta_j = b_j \times H_1 : \beta_j \neq b_j$ ve tvaru

$$\frac{|\hat{\beta}_j - b_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

Pro $b_j = 0$ dostaneme test významnosti β_j , tzn. $H_0 : \beta_j = 0$ zamítneme, pokud

$$\frac{|\hat{\beta}_j|}{s_n \sqrt{v_j}} > t_{1-\frac{\alpha}{2}}(n - m - 1).$$

POZNÁMKA 3.7

- pokud nejsou porušeny předpoklady modelu nebo není přítomna kolinearita, lze zvážit odstranění všech nevýznamných proměnných (dle t-testu)
- v případě kolinearit, může být model významný (dle celkového F-testu), ale všechny nebo téměř všechny proměnné se mohou jevit jako nevýznamné (dle t-testů)
- naopak, pokud má model velký počet možných proměnných, některé proměnné se mohou jevit významné, i když jsou náhodným šumem
- při použití t-testů je třeba postupovat obezřetně

PŘÍKLAD 3.4 (Porodní váha a gestační stáří)

```
mod <- lm(Weight ~ Age + Sex + Age:Sex)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1268.67    1114.64  -1.138 0.268492
## Age          111.98      29.05   3.855 0.000986 ***
## Sexgirl      -872.99    1611.33  -0.542 0.593952
## Age:Sexgirl   18.42      41.76   0.441 0.663893
## ---
## Residual standard error: 180.6 on 20 degrees of freedom
## Multiple R-squared:  0.6435,    Adjusted R-squared:  0.59
## F-statistic: 12.03 on 3 and 20 DF,  p-value: 0.000101
```

```
vif(mod)
## Age      Sex      Age:Sex
## 1.96444 477.55172 483.47306
```

```
mod0 <- lm(Weight ~ Age + Sex)
summary(mod0)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1610.28     786.08  -2.049  0.0532 .
## Age          120.89      20.46   5.908 7.28e-06 ***
## Sexgirl      -163.04      72.81  -2.239  0.0361 *
## ---
## Residual standard error: 177.1 on 21 degrees of freedom
## Multiple R-squared:  0.64,    Adjusted R-squared:  0.6057
## F-statistic: 18.67 on 2 and 21 DF,  p-value: 2.194e-05
```

```
vif(mod0)
## Age      Sex
## 1.013904 1.013904
```

PŘÍKLAD 3.5 (Data cement)

	x1	x2	x3	x4	y
1	7	26	6	60	78.5
2	1	29	15	52	74.3
3	11	56	8	20	104.3
4	11	31	8	47	87.6
5	7	52	6	33	95.9
6	11	55	9	22	109.2
7	3	71	17	6	102.7
8	1	31	22	44	72.5
9	2	54	18	22	93.1
10	21	47	4	26	115.9
11	1	40	23	34	83.8
12	11	66	9	12	113.3
13	10	68	8	12	109.4

```
mod <- lm(y ~ x1 + x2 + x3 + x4)
summary(mod)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  62.4054    70.0710   0.891   0.3991
## x1           1.5511     0.7448   2.083   0.0708 .
## x2           0.5102     0.7238   0.705   0.5009
## x3           0.1019     0.7547   0.135   0.8959
## x4          -0.1441     0.7091  -0.203   0.8441
## ---
## Residual standard error: 2.446 on 8 degrees of freedom
## Multiple R-squared:  0.9824,    Adjusted R-squared:  0.9736
## F-statistic: 111.5 on 4 and 8 DF,  p-value: 4.756e-07
```

```
vif(mod)
##           x1           x2           x3           x4
## 38.49621 254.42317  46.86839 282.51286
```

```
mod1 <- lm(y ~ x1)
summary(mod1)
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  81.4793     4.9273  16.54 4.07e-09 ***
## x1           1.8687     0.5264   3.55 0.00455 **
## ---
## Residual standard error: 10.73 on 11 degrees of freedom
## Multiple R-squared:  0.5339,    Adjusted R-squared:  0.4916
## F-statistic: 12.6 on 1 and 11 DF,  p-value: 0.004552
```



```

mod12 <- lm(y ~ x1 + x2)
summary(mod12)

##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 52.57735    2.28617   23.00 5.46e-10 ***
## x1          1.46831    0.12130   12.11 2.69e-07 ***
## x2          0.66225    0.04585   14.44 5.03e-08 ***
## ---
## Residual standard error: 2.406 on 10 degrees of freedom
## Multiple R-squared:  0.9787,    Adjusted R-squared:  0.9744
## F-statistic: 229.5 on 2 and 10 DF,  p-value: 4.407e-09

vif(mod12)
##           x1           x2
## 1.055129 1.055129

```

POZNÁMKA 3.8

- statistiky F , R^2 a t jsou užitečné pro rozkrytí efektů jednotlivých proměnných
- nemohou být ale používány úplně automaticky

3.5 Obecná lineární hypotéza

Hypotézy uvažované v F-testu a t-testech jsou speciálním případem **obecné lineární hypotézy**

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{b} \quad \times \quad H_1 : \mathbf{C}\boldsymbol{\beta} \neq \mathbf{b},$$

kde $\mathbf{C} \in \mathbb{R}^{r \times (m+1)}$ a $h(\mathbf{C}) = r$ (tzn. $r \leq m+1$)

Rovnice $\mathbf{C}\boldsymbol{\beta} = \mathbf{b}$ reprezentuje r lineárně nezávislých podmínek

$$\sum_{j=0}^m c_{ij}\beta_j = b_i, \quad i = 1, \dots, r.$$

POZNÁMKA 3.9

a) volba $\mathbf{b} = (0, \dots, 0)^T$ a $\mathbf{C} = \left(\begin{array}{c|cccc} 0 & 1 & 0 & \dots & 0 \\ \hline 0 & 0 & 1 & & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 0 & 0 & \dots & 0 & 1 \end{array} \right)_{m \times (m+1)}$ vede na test

$$H_0 : \mathbf{C}\boldsymbol{\beta} = \mathbf{0} \quad \Leftrightarrow \quad H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0,$$

b) volba $\mathbf{b} = \mathbf{0}$ a $\mathbf{C} = (0, \dots, 0, 1, 0, \dots, 0)$ vede na test $H_0 : \beta_j = 0$,

c) v modelu $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + e$ chceme testovat zároveň, že $\beta_2 = 0$ a $\beta_3 = \beta_4$,

to lze udělat volbou $\mathbf{C} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{pmatrix}$, $\mathbf{b} = (0, 0)^T$.

Pro test H_0 naladíme 2 modely:

1) **plný model** (full model) - bez podmínek na $\mathbf{C}\beta$,

2) **redukovaný model** (reduced model) - za předpokladu, že platí $H_0 : \mathbf{C}\beta = \mathbf{b}$.

Označme příslušné reziduální součty čtverců SSE_F a SSE_R ($SSE_F \leq SSE_R$)

- pokud neplatí H_0 , dá se očekávat, že $\Delta SSE = SSE_R - SSE_F$ bude významně větší, než náhodná chyba σ^2
- H_0 tedy budeme zamítat, pokud $\frac{\Delta SSE}{s_n^2}$ bude velké
- zobecnění F-testu, za platnosti H_0 ukážeme pro normální chyby vztah

$$F = \frac{\frac{\Delta SSE}{r}}{s_n^2} \sim F(r, n - m - 1)$$

PŘÍKLAD 3.6

Uvažujme F-test pro $H_0 : \beta_1 = \beta_2 = \dots = \beta_m = 0$ v plném modelu (**).