

## 4.4 Transformace

- pokud není splněn některý z předpokladů modelu - **linearita, normalita chyb, homoskedasticita**
- jednou z možností je pokusit se transformovat proměnné, aby transformovaný model předpoklady alespoň „přibližně“ splňoval

### A) Transformace vysvětlované proměnné $y$

hledáme funkci  $h(\cdot)$  tak, aby model  $Y_i^* = h(Y_i) = \beta_0 + \sum_{j=1}^m x_{ij}\beta_j + e_j$  předpoklady splňoval

3 hlavní důvody pro transformaci  $y$ :

#### 1) transformace škály měření tak, aby pokrývala celé **$R$**

(což může odstranit problémy spodemíkami na  $\beta$ )

- např. studie kapacity plic (FEV data,  $FEV > 0$ ), chtěli bychom, aby model nepredikoval záporné hodnoty
- lze obejít modelováním  $y^* = \ln FEV$
- pokud  $y$  jsou počty a 0 je možná hodnota, často se používá  $y^* = \ln(y + 1)$  nebo obecně  $y^* = \ln(y + c)$

## 2) transformace $Y$ , aby její rozdělení bylo „více“ normální

- typicky se snažíme udělat rozdělení hodnot  $y$  více symetrické
- často se setkáváme s rozděleními vychýlenými vpravo
- transformace  $y^* = \ln y$  nebo  $y^* = y^\lambda$ ,  $\lambda < 1$  budou redukovat toto vychýlení
- **typický postup:** začít s hodnotou  $\lambda \approx 1$  a pak snižovat, dokud není dosaženo „přibližné“ symetrie reziduí

## 3) možná nejzásadnější motivace: pokusit se dosáhnout konstantní rozptyl

- např. pro fyzikální veličinu s kladnými hodnotami se často stane, že rozptyl bude malý pro  $\mu \approx 0$  a větší pro  $\mu$  velké (tzv. **positive mean-variance relationship**)
- nepřesnost měření kladných veličin se často vyjadřuje pomocí koeficientu variace  $CV(Y) = \frac{s.d.Y}{EY}$
- bývá více konstantní než s.d. (variabilitu vyjadřujeme relativně)
- matematicky to znamená, že  $\text{Var}Y = \varphi(EY)^2 = \varphi\mu^2$  pro nějaké  $\varphi$
- pro odstranění vztahu mezi  $EY$  a  $\text{Var}Y$  se často používají transformace  $y^* = y^\lambda$  (pro  $y > 0$ )

Transformace:	$\longleftarrow$	$\cdots$	$y^3$	$y^2$	$y$	$\sqrt{y}$	$\ln y$	$\frac{1}{\sqrt{y}}$	$\frac{1}{y}$	$\frac{1}{y^2}$	$\cdots$	$\longrightarrow$
Box-Cox $\lambda$ :			3	2	1	$\frac{1}{2}$	0	$-\frac{1}{2}$	-1	-2		

• pokud  $\text{Var} Y$  klesá

• pokud  $\text{Var} Y$  roste s rostoucí  $EY$

s rostoucí  $EY$

**OBECNĚ:** předpokládejme vztah  $\text{Var} Y = \varphi V(\mu)$  a uvažujme transformaci  $y^* = h(y)$

Taylorův rozvoj 1. řádu funkce  $h(y)$  v bodě  $\mu$

$$y^* = h(y) \approx h(\mu) + h'(\mu)(y - \mu)$$

z čehož plyne, že  $\text{Var} Y^* \approx (h'(\mu))^2 \cdot \text{Var} Y$

transformace  $y^* = h(y)$  bude přibližně stabilizovat rozptyl, pokud  $h'(\mu)$  je úměrné  $(\text{Var} Y)^{-\frac{1}{2}} = V^{-\frac{1}{2}}(\mu)$

• pokud  $V(\mu) = \mu^2 \Rightarrow$  transformace stabilizující rozptyl je  $h(y) = \ln y$  ( $h'(\mu) = \frac{1}{\mu}$ )

• pokud  $V(\mu) = \mu \Rightarrow$  transformace stabilizující rozptyl je  $h(y) = \sqrt{y}$  ( $h'(\mu) = \frac{1}{2\sqrt{\mu}}$ )

- asi nejvíce užívanou transformací je  $y^* = \ln y$  (dobrá interpretovatelnost parametrů  $\beta$ )

#### POZNÁMKA 4.11 (Interpretace parametrů lineárního modelu)

a) **klasický LM:**  $EY = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$

jednotková změna proměnné  $x_j \Rightarrow$  změnu  $EY$  o  $\beta_j$  jednotek  
(při ostatních proměnných stejných)

b) **LM pro  $\ln Y$ :**  $\ln Y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + e, \quad e \sim N(0, \sigma^2)$

- pokud je to správný model,  $\ln Y \sim N(\mu, \sigma^2) \Rightarrow Y \sim LN(\mu, \sigma^2)$  a  $EY = e^{\mu + \frac{\sigma^2}{2}}$

predikce pro  $E \ln Y$  je  $\hat{\mu} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m$

predikce pro  $EY$  je  $e^{\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_m x_m + \frac{\sigma^2}{2}}$

- uvažujme opět jednotkovou změnu proměnné  $x_j$  ( $x_j \rightarrow x_j + 1$ )

$$\frac{EY_{\text{new}}}{EY} = \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j x_j + \beta_j + \dots + \beta_m x_m + \frac{\sigma^2}{2}}}{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \frac{\sigma^2}{2}}} = e^{\beta_j}$$

jednotková změna proměnné  $x_j \Rightarrow$  multiplikativní změnu  $EY$   $e^{\beta_j}$ -krát

jinak zapsáno:  $100(e^{\beta_j} - 1)$  je procentní změna  $EY$  spojená s jednotkovou změnou  $x_j$

# Box-Cox transformace

- pokud chyby nemají normální rozdělení, hledáme transformaci  $Y$ , která by nejenom linearizovala model, ale také transformovala chyby, aby byly přibližně normální
- užitečná třída transformací (**power family**)

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \text{pokud } \lambda \neq 0 \\ \ln y, & \text{pokud } \lambda = 0 \end{cases}, \quad \left( \lim_{\lambda \rightarrow 0} \frac{y^\lambda - 1}{\lambda} = \ln y \right)$$

která předpokládá, že data  $y$  jsou kladná

- pro nalezení vhodného  $\lambda$  budeme předpokládat, že transformované veličiny  $Y_i^{(\lambda)}$ ,  $i = 1, \dots, n$ , splňují podmínky RM, tj.

$$Y_i^{(\lambda)} = \mathbf{x}_i^T \boldsymbol{\beta} + \mathbf{e} \quad \text{kde} \quad \mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad (Y_i^{(\lambda)} \sim N(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma^2), \quad Y_i^{(\lambda)} \text{ nezávislé})$$

- úkol je odhadnout zároveň  $\lambda, \boldsymbol{\beta}, \sigma^2$ , použijeme MLE



Dostali jsme tedy tzv. **profile log - likelihood**

$$\ell_p^{(\lambda)} = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) - \frac{n}{2} + \ln J(\lambda) = C - \frac{n}{2} \ln \hat{\sigma}^2(\lambda) + (\lambda - 1) \sum_{i=1}^n \ln y_i,$$

kde

$$\hat{\beta}(\lambda) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}^{(\lambda)}, \quad \hat{\sigma}^2(\lambda) = \frac{1}{n} \sum_{i=1}^n (y_i^{(\lambda)} - \hat{y}_i^{(\lambda)})^2,$$

a

$$\mathbf{y}^{(\lambda)} = (y_1^{(\lambda)}, \dots, y_n^{(\lambda)})^T, \quad \hat{y}_i^{(\lambda)} = \mathbf{x}_i^T \hat{\beta}^{(\lambda)}.$$

**POZNÁMKA:**

- kvůli komplikované závislosti  $\ell_p^{(\lambda)}$  na  $\lambda$  bude třeba numerická metoda pro maximalizaci
- lze přepsat do tvaru, kde bude možné využít metody LR

**Celkem:**  $\max_{\lambda} \ell_p(\lambda) \iff \min_{\lambda} s_{\lambda}^2,$

kde

$$s_{\lambda}^2 = \frac{\hat{\sigma}^2(\lambda)}{[(\dot{y})^{\lambda-1}]^2} = \frac{1}{n} \sum_{i=1}^n \left( \frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} - \frac{\hat{y}_i^{(\lambda)}}{(\dot{y})^{\lambda-1}} \right)^2,$$

tzn.  $s_{\lambda}^2$  je reziduální součet čtverců (SSE/n) v modelu  $\frac{y_i^{(\lambda)}}{(\dot{y})^{\lambda-1}}$  v závislosti na  $\mathbf{x}_i^T$   
(tzn.  $s_{\lambda}^2$  lze snadno získat pomocí funkce `lm()`)

### Algoritmus:

- 1) zvolit oblast hodnot  $\lambda, I = \langle \lambda_{min}, \lambda_{max} \rangle$ , a body  $\lambda \in I$   
(typicky  $I = \langle -2, 2 \rangle$  a 10-20 rovnoměrně rozdělených bodů)
- 2) naladit model  $\frac{y^{(\lambda)}}{(\dot{y})^{\lambda-1}} \sim x$  a spočítat  $\frac{1}{n} SSE = s_{\lambda}^2$ .
- 3) z grafu  $(\lambda, s_{\lambda}^2)$  vybrat  $\hat{\lambda}$ , které minimalizuje  $s_{\lambda}^2$
- 4) pro zvolené  $\hat{\lambda}$  naladit model  $y^{(\hat{\lambda})} \sim x$  a pokračovat standardní analýzou



### Intervaly spolehlivosti pro $\lambda$ :

- snadno lze odvodit LRT test pro test  $H_0 : \lambda = \lambda_0$   
( $H_0 : \lambda = 1$  zda je třeba transformace, pokud zamítneme  $H_0 \Rightarrow$  transformace pomocí  $\hat{\lambda}$ )
- LRT statistika:  $\Lambda = -2 \ln \frac{L(\lambda_0)}{L(\hat{\lambda})} = 2(\ell_p(\hat{\lambda}) - \ell_p(\lambda_0))$ , víme že  $\Lambda \xrightarrow{L} \chi^2(1)$
- invertováním přípustné oblasti LRT testu, dostaneme **as.  $100(1 - \alpha)\%$  IS pro  $\lambda$**

$$\left\{ \lambda \in \mathbb{R} \mid n \cdot \ln \frac{s_{\hat{\lambda}}^2}{s_{\lambda}^2} \leq \chi_{1-\alpha}^2(1) \right\}, \quad \text{kde } \hat{\lambda} \text{ je MLE } \lambda$$



### POZNÁMKA 4.12

Kvůli jednoduchosti interpretace se často doporučuje zaokrouhlit  $\hat{\lambda}$  na nejbližší  $\frac{1}{4}$  nebo  $\frac{1}{3}$ .

## PŘÍKLAD 4.4 (Data TREES)

	Girth	Height	Volume
1	8	70	10
2	9	65	10
3	9	63	10
4	10	72	16
⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮

```
mod <- lm(Volume ~ Girth + Height)
summary(mod)
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -57.9877      8.6382  -6.713 2.75e-07 ***
## Girth         4.7082      0.2643  17.816 < 2e-16 ***
## Height        0.3393      0.1302   2.607  0.0145 *
## ---
## Residual standard error: 3.882 on 28 degrees of freedom
## Multiple R-squared:  0.948,    Adjusted R-squared:  0.9442
## F-statistic: 255 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat <- predict(mod)
st.res <- rstudent(mod)
plot(y.hat, st.res, pch = c(1), col = c("red"), lwd=2)
```



```
bc<- boxcox(mod, lambda = seq(-2,2,1/10))
```

```
lambda.hat <- bc$x[which.max(bc$y)]; lambda.hat
## 0.3030303
```

```
Vol.lambda <- (Volume^lambda.hat-1)/lambda.hat
```


```
mod.t <- lm(Vol.lambda ~ Girth + Height)
summary(mod.t)
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.733542    0.500080  -5.466 7.77e-06 ***
## Girth         0.409448    0.015299  26.764 < 2e-16 ***
## Height        0.039685    0.007535   5.267 1.34e-05 ***
## ---
## Residual standard error: 0.2247 on 28 degrees of freedom
## Multiple R-squared: 0.9775, Adjusted R-squared: 0.9759
## F-statistic: 609.6 on 2 and 28 DF,  p-value: < 2.2e-16
```



```
y.hat.t <- predict(mod.t)
st.res.t <- rstudent(mod.t)

plot(y.hat.t, st.res.t, pch = c(1), col = c("red"), lwd=2)
```



## B) Transformace vysvětlujících proměnných $\mathbf{x}$

- pokud diagnostika modelu naznačuje, že vztah mezi  $\mathbf{y}$  a  $\mathbf{X}$  není lineární pro jeden nebo více regresorů, může být vhodné přeformulovat model pomocí transformací proměnných  $\mathbf{x}$
- předpokládejme, že v modelu  $Y = \beta_0 + \sum_{j=1}^m \beta_j x_j + e$  máme podezření na nelinearitu v  $j$ -té proměnné  $x_j$
- jednou z možností jak postupovat je nahrazení  $x_j$  proměnnou  $z_j = f(x_j)$ , model tedy bude

$$Y = \beta_0 + \beta_1 x_1 + \cdots + \beta_j z_j + \cdots + \beta_m x_m + e$$

- pokud je  $f$  známé, jedná se o model LR a lze ho analyzovat standardně, pokud je tato transformace vhodná, mělo by se to projevit ve zlepšení statistik  $R^2$ ,  $t$ ,  $F$  a zlepšení grafu reziduí pro  $z_j$  oproti těm pro  $x_j$
- bohužel  $f$  většinou známá není, možný přístup je parametrizovat nějak tuto funkci a pak odhadnout tyto parametry společně s  $\beta$ 
  - **typická parametrizace:**  $z_j = x_j^\lambda$ , kde  $\lambda \in \mathbb{R}$  vhodné
  - aproximace  $f$  pomocí polynomu vhodného stupně, tzn.  $z_j = \sum_{k=1}^l r_k x_j^k$ , kde  $r_k$  musí být odhadnuty
  - další možností je použití trigonometrických funkcí nebo splines (piecewise polynomials)

Zaměříme se na  $z_j = x_j^\lambda$ :

- možnost je opět zvolit jistou množinu hodnot  $\lambda$ , naladit modely pro všechna  $\lambda$  a vybrat model s nejlepší shodou s daty, např. s nejmenší  $SSE$  nebo největší  $R^2$  nebo  $F$
- může být časově náročné, můžeme minout vhodnou hodnotu  $\lambda$ , pokud nebyla v původní množině (nevíme jak  $R^2, F, SSE$  závisí na  $\lambda$ )

### Box-Tidwell metoda

- předpokládejme, že  $\lambda$  se příliš neliší od  $\lambda = 1$ , Taylorův rozvoj 1. řádu kolem  $\lambda = 1$  dává

$$x^\lambda \approx x^1 + (\lambda - 1) \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1}, \quad \frac{dx^\lambda}{d\lambda} \Big|_{\lambda=1} = x^\lambda \ln x \Big|_{\lambda=1} = x \ln x, \quad \text{tedy} \quad x^\lambda \approx x + (\lambda - 1)x \ln x$$

- dosazením do modelu

$$\begin{aligned} Y &= \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j (x_j + (\lambda - 1)x_j \ln x_j) + \dots + \beta_m x_m + e \\ &= \beta_0 + \sum_{k=1}^m \beta_k x_k + \underbrace{\beta_j (\lambda - 1)}_{\beta_{m+1}(\lambda)} x_j \ln x_j + e \end{aligned}$$

- máme lineární model pro parametry  $\beta_k$ ,  $0 \leq k \leq m+1$ , protože  $\beta_{m+1} = (\lambda - 1)\beta_j$ , můžeme  $(\lambda, \beta_j)$  odhadnout následovně

- 1) naladíme původní model a spočteme  $LSE \hat{\beta}_j$  parametru  $\beta_j$
- 2) naladíme rozšířený model s  $x_{m+1} = x_j \ln x_j$  a spočteme  $\hat{\beta}_{m+1}$
- 3) z rovnosti  $\hat{\beta}_{m+1} = (\hat{\lambda} - 1)\hat{\beta}_j$  dostaneme  $\hat{\lambda} = \frac{\hat{\beta}_{m+1}}{\hat{\beta}_j} + 1$ 
  - tento postup umožňuje testovat potřebu transformace  $H_0 : \lambda = 1 \quad \times \quad H_1 : \lambda \neq 1$   
pomocí t-testu pro  $H_0 : \beta_{m+1} = 0$

#### POZNÁMKA 4.13

- pokud model s  $\hat{\lambda}$  vypadá neadekvátně, lze postupovat iterativně a získat posloupnost  $\hat{\lambda}(l)$ ,  $l \geq 1$
- $\hat{\lambda}(0) = \hat{\lambda}$  a rozvineme  $x_j^\lambda$  kolem  $\hat{\lambda}(0)$ , tzn.  $x_j^\lambda \approx x_j^{\hat{\lambda}(0)} + (\lambda - \hat{\lambda}(0))x_j^{\hat{\lambda}(0)} \ln x_j$
- dosazením do rovnice modelu

$$Y = \beta_0 = \sum_{\substack{k=1 \\ k \neq j}}^m \beta_k x_k + \beta_j x_j^{\hat{\lambda}(0)} + \underbrace{\beta_j (\lambda - \hat{\lambda}(0))}_{\beta_{m+1}} x_j^{\hat{\lambda}(0)} \ln x_j + e$$

- naladíme tento model s a bez přidané proměnné  $x_{m+1} = x_j^{\hat{\lambda}(0)} \ln x_j$ , označíme  $\hat{\beta}_j(1)$  a  $\hat{\beta}_{m+1}(1)$  příslušné odhady

- potom

$$\hat{\lambda}(1) = \hat{\lambda}(0) + \frac{\hat{\beta}_{m+1}(1)}{\hat{\beta}_j(1)}$$

- můžeme dále iterovat do konvergence nebo skončit po pevném počtu iterací

POZNÁMKA 4.14 (Další užívané transformace v  $\mathbf{x}$ ,  $\mathbf{y}$ )

a) centrované proměnné:  $\mathbf{X}_C$  a  $\mathbf{y}_C$

$$(\mathbf{X}_C)_{ij} = x_{ij} - \bar{x}_j, \quad i \in \hat{n}, \quad j \in \hat{m}, \quad \text{kde } \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad (\mathbf{y}_C)_i = y_i - \bar{y}$$

$$1) \hat{\beta}_1, \dots, \hat{\beta}_m \text{ je řešením } \mathbf{X}_C^T \mathbf{X}_C \boldsymbol{\beta} = \mathbf{X}_C^T \mathbf{y}_C, \quad 2) \hat{\beta}_0 = \bar{y} - \sum_{j=1}^m \hat{\beta}_j \bar{x}_j$$

b) centrované a škálované proměnné  $\mathbf{X}_{SC}$  a  $\mathbf{y}_C$  ( $\mathbf{y}_{SC}$ ):

škálování sloupců tak, aby jejich norma byla 1,

tzn. každý prvek  $j$ -tého sloupce matice  $\mathbf{X}$  podělíme  $s_j = \left( \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \right)^{\frac{1}{2}}$

centrovaná a škálovaná matice  $\mathbf{X}_{SC}$  pak bude  $\mathbf{X}_{SC} = \mathbf{X}_C \mathbf{S}$ ,  $\mathbf{S} = \text{diag}\left(\frac{1}{s_1}, \dots, \frac{1}{s_m}\right)$

model bude  $\mathbf{Y}_C = \mathbf{X}_{SC} \boldsymbol{\beta}_s + \mathbf{e}$

(lze použít i  $\mathbf{Y}_{SC}$ , tedy centrované a škálované  $\mathbf{Y}$ )



## 4.5 Vážené nejmenší čtverce (weighted least squares - WLS)

- budeme předpokládat, že chyby  $e_i$  jsou normální, nezávislé, ale  $\text{Var}(e_i) = \sigma_i^2$  závisí na  $i$
- konkrétně  $\sigma_i^2 = \frac{\sigma^2}{w_i}$ , kde  $w_i > 0$ ,  $i \in \hat{n}$ , se nazývají **váhy**
- uvažujeme tedy model

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \text{kde} \quad \mathbf{e} \sim N_n(0, \sigma^2 \mathbf{W}) \quad \text{a} \quad \mathbf{W} = \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right) \quad (4.2)$$

- pokud jsou váhy  $w_i$  známé, lze MLE odhady parametru  $\boldsymbol{\beta}$  a  $\sigma^2$  nalézt následovně

$$\mathbf{W} = \mathbf{K}\mathbf{K}^T, \quad \text{kde} \quad \mathbf{K} = \mathbf{W}^{\frac{1}{2}} = \text{diag}\left(\frac{1}{\sqrt{w_1}}, \dots, \frac{1}{\sqrt{w_n}}\right)$$

- definujeme  $\mathbf{Z} = \mathbf{K}^{-1}\mathbf{Y}$ ,  $\mathbf{M} = \mathbf{K}^{-1}\mathbf{X}$  a  $\boldsymbol{\varepsilon} = \mathbf{K}^{-1}\mathbf{e}$
- dostaneme model

$$\mathbf{Z} = \mathbf{M}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \text{kde} \quad \boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{I}_n), \quad (4.3)$$

$$(\text{protože } \text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{K}^{-1}\sigma^2\mathbf{W}(\mathbf{K}^{-1})^T = \sigma^2\mathbf{K}^{-1}\mathbf{K}\mathbf{K}^T(\mathbf{K}^T)^{-1} = \sigma^2\mathbf{I}_n)$$

- to už je standardní model LR, ve kterém platí

$$\begin{aligned}\hat{\beta}_w &= (\mathbf{M}^T \mathbf{M})^{-1} \mathbf{M}^T \mathbf{z} = (\mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{y} \\ &= (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{y}\end{aligned}$$

$$\hat{\sigma}_w^2 = \frac{1}{n} \sum_{i=1}^n (z_i - \hat{z}_i)^2 = \frac{1}{n} \sum_{i=1}^n w_i (y_i - \hat{y}_i)^2 = \frac{1}{n} SSE_w,$$

kde  $SSE_w$  je vážený součet čtverců,  $z_i = \sqrt{w_i} y_i$  a  $\hat{z}_i = \sqrt{w_i} \mathbf{x}_i^T \hat{\beta}_w = \sqrt{w_i} \hat{y}_i$

- dále platí

a)  $E\hat{\beta}_w = (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} E\mathbf{Y} = \beta$ , tzn.  $\hat{\beta}_w$  je nestranný odhad  $\beta$

b)  $E\left(\frac{SSE_w}{n-m-1}\right) = \sigma^2$ , tedy  $s_w^2 = \frac{SSE_w}{n-m-1}$  je nestranný odhad  $\sigma^2$

## VĚTA 4.4

Nechť  $\hat{\beta}_w$  je WLS odhad  $\beta$ , jestliže  $\text{Cov}(\mathbf{e}) = \sigma^2 \mathbf{W} = \sigma^2 \text{diag}\left(\frac{1}{w_1}, \dots, \frac{1}{w_n}\right)$ . Potom platí:

- 1)  $\text{Cov}(\hat{\beta}_w) = \sigma^2 (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$
- 2) nechť  $\delta_i$  je  $i$ -tý diagonální prvek  $(\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1}$ , jestliže  $e_i \sim N\left(0, \frac{\sigma^2}{w_i}\right)$ ,  $i \in \hat{n}$ , potom

$$T_i = \frac{\hat{\beta}_{w,i} - \beta_i}{s_w \sqrt{\delta_i}} \sim t(n - m - 1)$$

- 3) pro  $\hat{\mathbf{Y}}_w = \mathbf{X} \hat{\beta}_w$  platí  $E \hat{\mathbf{Y}}_w = \mathbf{X} \beta$  a  $\text{Cov}(\hat{\mathbf{Y}}_w) = \sigma^2 \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T$
- 4) Nechť  $\hat{\mathbf{e}}_w = \mathbf{Y} - \hat{\mathbf{Y}}_w$  jsou rezidua v modelu (4.2) a  $\hat{\mathbf{e}}_w = \mathbf{Z} - \hat{\mathbf{Z}} = \mathbf{Z} - \mathbf{M} \hat{\beta}_w$  jsou rezidua v transformovaném modelu (4.3). Potom

$$\hat{\mathbf{e}}_w = \sqrt{\mathbf{W}^{-1}} \hat{\mathbf{e}}_w = \mathbf{W}^{-\frac{1}{2}} \hat{\mathbf{e}}_w \quad \text{a} \quad E(\hat{\mathbf{e}}_w) = E(\hat{\mathbf{e}}_w) = \mathbf{0}.$$

- 5) nechť  $\mathbf{H}_w = \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1}$  je vážená projekční matice, potom

$$\hat{\mathbf{e}}_w = (\mathbf{I} - \mathbf{H}_w) \mathbf{e}, \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 (\mathbf{I} - \mathbf{H}_w) \mathbf{W}, \quad \text{tzn.} \quad \text{Cov}(\hat{\mathbf{e}}_w) = \sigma^2 \mathbf{W}^{-\frac{1}{2}} (\mathbf{I} - \mathbf{H}_w) \mathbf{W}^{\frac{1}{2}}$$

Důkaz.

- odhady parametrů  $\beta$  a  $\sigma^2$  lze získat použitím transformovaného modelu (4.3)
- protože ale transformovaný model neobsahuje intercept (první sloupec  $\mathbf{M}$  je  $(\sqrt{w_1}, \dots, \sqrt{w_n})^T$ ), nefunguje klasický rozklad součtu čtverců a  $F$  a  $R^2$  statistiku nelze definovat obvyklým způsobem (viz. regrese skrz počátek)
- nicméně princip „extra sum of squares“ funguje, ať má model intercept nebo ne
  - např. celkový  $F$ -test lze provést pomocí statistiky

$$F_w = \frac{\frac{SSE_R - SSE_F}{m}}{s_w^2},$$

kde  $SSE_F$  je reziduální součet čtverců  $s_w^2$  plného modelu a  $SSE_R$  je reziduální součet čtverců redukovaného transformovaného modelu  $\mathbf{Z} = \mathbf{M}_0\beta_0 + \mathbf{e}$ ,  $\mathbf{M}_0 = (\sqrt{w_1}, \dots, \sqrt{w_n})^T$

- pokud mají chyby normální rozdělení, platí za  $H_0 : \beta_1 = \dots = \beta_m = 0$ , že  $F_w \sim F(m, n - m - 1)$  a  $H_0$  zamítáme, pokud  $F_w > F_{1-\alpha}(m, n - m - 1)$

- přirozené je definovat  $R^2 = \varrho^2(\hat{\mathbf{z}}, \mathbf{z})$ , kde  $\varrho(\hat{\mathbf{z}}, \mathbf{z})$  je výběrový korelační koeficient (pro  $\mathbf{W} = \mathbf{I}$  dostaneme standardní  $R^2$ )

Pro analýzu reziduí je třeba uvažovat vhodné grafy reziduí:

- máme dva vektory reziduí:

$$\hat{e}_i \text{ v původním modelu (4.2)} \quad \hat{\varepsilon}_i \text{ v transformovaném modelu (4.3)}$$

a tedy dvě možnosti

- pro kontrolu konstantního rozptylu lze uvažovat i standardizovaná nebo studentizovaná rezidua (pomocí bodu 4) a 5) věty lze ukázat, že jsou v obou modelech stejná)
- je třeba být opatrný oproti jakým hodnotám budeme rezidua zobrazovat
- grafy  $\hat{e}_i$  proti sloupcům  $\mathbf{M}$  a predikovaným hodnotám  $\hat{\mathbf{z}}$  jsou OK, neboť např.

$$\sum_{i=1}^n \hat{z}_i \hat{e}_i = 0$$

(jsou OG, měl by být vidět roztýlený oblak kolem osy x)

- dosazením  $\hat{e}_i = \sqrt{w_i} \cdot \hat{e}_i$  a  $\hat{z}_i = \sqrt{w_i} \cdot \hat{y}_i$  dostaneme  $\sum_{i=1}^n w_i \hat{e}_i \hat{y}_i = 0$ , tzn. graf  $\hat{e}_i$  proti  $\hat{y}_i$  bude zavádějící
- graf  $\sqrt{w_i} \cdot \hat{e}_i$  proti  $\sqrt{w_i} \cdot \hat{y}_i$  je ale v pořádku
- podobné závěry platí i pro grafy  $\hat{e}_i$  proti  $\mathbf{x}_j^c$ ,  $j = 1, \dots, m$

#### POZNÁMKA 4.15

- pokud jsou váhy neznámé, bylo by třeba je odhadnout společně s  $\beta$  a  $\sigma^2$  z dat
- to ale není obecně možné, protože máme více parametrů než dat
- někdy to možné je, pokud máme další informace o rozdělení chyb (tvar kovarianční matice atd.)

#### POZNÁMKA 4.16

- celý postup WLS lze použít i na případ  $\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{W})$ , kde  $\mathbf{W}$  je známá, ale není diagonální
- protože  $\mathbf{W}$  je PD, ex. regulární  $\mathbf{K}$  tak, že  $\mathbf{W} = \mathbf{K}\mathbf{K}^T$
- stejná transformace jako u WLS opět vede na transformovaný model, kde  $\varepsilon \sim N_m(\mathbf{0}, \sigma^2 \mathbf{I}_m)$